

TUẦN 3 · KIỂM TRA PIPELINE

Chạy thử SMLP4Rec trên Expedia

những gì đã đổi, đã chạy và đã thấy

Topic C1 · Next-Best-Product Recommendation · 30/09/2026

Pipeline end-to-end

1 epoch · CPU

Chưa phải benchmark

Chạy pipeline một lần trên Expedia

Chỉ kiểm tra luồng chạy và đọc kết quả, không tối ưu

Trong phạm vi

- Chuyển mã SMLP4Rec vào `src/`
- Chỉnh tối thiểu để chạy với Expedia
- Huấn luyện, validate, test một lần
- Lưu kết quả vào `reports/summary/week3/`

Ngoài phạm vi

- Xử lý dữ liệu, feature engineering
- Viết mô hình mới từ đầu
- Tinh chỉnh siêu tham số
- Query token và cold-start hybrid (bước sau)

Kết quả chỉ nhằm xác nhận pipeline chạy được. Mọi con số trong bộ slide này lấy từ `smlprec_expedia_run.json`.

Các file mới trong repo

Không sửa dữ liệu gốc, không sửa thư viện ngoài repo này

FILE	VAI TRÒ
src/models/smlprec.py	SMLP4Rec chép từ fork, 2 chỉnh sửa nhỏ (đánh dấu # ADAPTED)
scripts/expedia_to_recbole.py	Xuất đặt phòng ra file .inter của RecBole: chỉ user, cụm khách sạn, thời gian
configs/smlprec_expedia.yaml	Cấu hình mô hình, huấn luyện, đánh giá
scripts/run_smlprec_expedia.py	Chạy train, valid, test và hai heuristic trên cùng dòng test
reports/summary/week3/	README, JSON kết quả, log RecBole

Cập nhật thêm: PROGRESS.md (mục Phase 3) và sơ đồ thư mục trong CLAUDE.md .

Chỉnh sửa mô hình: chỉ hai điểm

Còn lại giữ nguyên như bản gốc của fork

Đã chỉnh

1. **Độ dài chuỗi** lấy từ `MAX_ITEM_LIST_LENGTH` thay vì cố định 50
2. **Cho phép danh sách feature rỗng**: cụm khách sạn không có thuộc tính, nên bỏ lớp embedding feature

Giữ nguyên (đã biết là vấn đề)

- Một khối SMLP dùng lại cho mọi lớp, trọng số chung
- Không có kết nối residual quanh khối
- Còn code thừa chưa dùng
- Repo gốc không có file license: chỉ dùng nội bộ, gắn nhãn “research adaptation”

ĐÃ CHẠY

Tuần 3 · Pipeline

Luồng pipeline và thiết lập

Một lần chạy, seed 2022, CPU



Mô hình: 2 lớp, hidden 64, dropout 0.0, lr 0.001, batch 1024, 1 epoch, lịch sử tối đa 20 lần đặt. Thời gian: dựng dữ liệu 42.2s · train + valid 156.9s · test 6.4s.

Cách chia dữ liệu


Chia theo thời gian 80/10/10 trên các mục tiêu, không chia ngẫu nhiên

TẬP	SỐ MỤC TIÊU	TỪ NGÀY	ĐẾN NGÀY	LỊCH SỬ TRUNG BÌNH
Train	1.749.368	07/01/2013	08/10/2014	5,853
Valid	218.670	08/10/2014	19/11/2014	7,391
Test	218.670	19/11/2014	01/01/2015	7,255

- Mục tiêu = mọi lần đặt phòng trừ lần đặt đầu tiên của mỗi người dùng; lịch sử = các lần đặt trước đó của người đó.
- Đánh giá xếp hạng đầy đủ trên 100 cụm, không lấy mẫu âm.
- Người dùng chưa từng đặt (cold-start) **không** nằm trong tập test của lần chạy này.

Kết quả trên tập test

Xếp hạng đầy đủ trên 100 cụm · cùng các dòng test cho cả ba phương pháp



SMLP4REC, TEST

Recall@5 33,50%

NDCG@10 0,2836 · MRR@10 0,2290

SO VỚI LẶP LẠI CỤM CUỐI

+7,80 điểm %

Recall@5

SO VỚI POPULARITY TOÀN CỤC

+18,72 điểm %

Recall@5

Đọc kết quả

1

Pipeline chạy thông suốt

Xuất dữ liệu, dựng chuỗi, chia theo thời gian, huấn luyện, xếp hạng đầy đủ và nạp lại checkpoint đều chạy không lỗi, tổng cộng khoảng 3.4 phút trên CPU.

2

Lịch sử đặt phòng tự nó có tín hiệu

SMLP4Rec vượt lặp-lại-cụm-cuối +7,80 điểm % và popularity +18,72 điểm % ở Recall@5. Valid (33,25%) và test gần nhau, không thấy lệch giữa hai tập.

3

Còn thấp hơn mốc tuần 2 (53,07%)

Mô hình chỉ thấy các cụm đã đặt, chưa thấy điểm đến của lần tìm kiếm hiện tại, tức tín hiệu mạnh nhất. Đây chính là chỗ query token cần lấp.

!

Chưa so sánh trực tiếp với tuần 2

Tuần 2 cắt theo phân vị 80% của thời gian đặt và có cả người dùng mới; lần chạy này chia 80/10/10 trên các mục tiêu và bỏ lần đặt đầu của mỗi người.

Lỗi đã gặp và cách xử lý

Bốn lỗi, đều đã xử lý; lỗi thứ tư có thể làm sai kết quả nếu bỏ sót

VẤN ĐỀ	NGUYÊN NHÂN	XỬ LÝ
Torch không nạp được DLL	Đường dẫn workspace quá dài trên Windows	Venv Python 3.11 đặt ở đường dẫn ngắn
Huấn luyện rất chậm	<code>sine.py</code> bật anomaly detection khi import	Tắt trong script chạy
Bước test lỗi khi nạp checkpoint	PyTorch ≥ 2.6 mặc định <code>weights_only=True</code>	Nạp với <code>weights_only=False</code> (file do chính lần chạy tạo ra)
Sai đơn vị thời gian	pandas 3 đọc ngày ra micro giây, chia 10^9 làm các lần đặt cách nhau dưới ~17 phút trùng thời điểm	Đổi sang tính giây tường minh, chạy lại; số liệu ở đây là của lần chạy đã sửa

Hạn chế và việc cần làm

Hạn chế của lần chạy này

- 1 epoch, chưa tinh chỉnh, một seed duy nhất
- Chưa có ngữ cảnh tìm kiếm (điểm đến, ngày, số người, gói)
- Chưa có cold-start hybrid
- RecBole 1.0.1 buộc dùng numpy 1.23 / pandas 1.5 trong venv riêng

Đề xuất

1. Thêm query token cho ngữ cảnh tìm kiếm hiện tại
2. Thêm cold-start hybrid (prior theo điểm đến, cổng học theo độ dài lịch sử)
3. Căn chỉnh cách chia với tuần 2 để so với mốc 57,85%
4. Quyết định: giữ RecBole hay chuyển sang PyTorch thuần
5. Sửa lỗi kiến trúc: trọng số riêng mỗi lớp, thêm residual