

TUẦN 2 · LỰA CHỌN METHODOLOGY

Lựa chọn methodology

cho gợi ý hotel cluster trên Expedia

Next-Best-Product Recommendation · Vinpearl × GSM · Bối cảnh (a): du lịch

Dữ liệu công khai

Split theo thời gian

Xếp hạng đầy đủ 100 cluster

Mạch trình bày

1

Bài toán & dữ liệu

Đặc điểm Expedia và yêu cầu đặt ra cho mô hình

2

Ba ứng viên

SMLP4Rec, AdaGIN, LightGBM – phiên bản gốc

3

Chọn SMLP4Rec

Ý tưởng, kiến trúc, lý do phù hợp

4

Điểm yếu & đề xuất hybrid

Lịch sử user ngắn → bổ sung prior theo context, ngưỡng từ dữ liệu

5

Tổng kết

Quyết định, mốc cần vượt, bước tiếp theo

Bài toán

01

Mục tiêu

Gợi ý **1 trong 100 hotel cluster** cho một lượt search. Cluster là proxy cho hạng phòng / gói nghỉ dưỡng của Vinpearl.

02

Đầu vào

Lịch sử booking của user và **context**
lượt search: destination, số người, ngày nhận phòng, package, kênh.

03

Đánh giá

Split **theo thời gian**, xếp hạng **toàn bộ** 100 cluster. Recall / NDCG / MRR @5, 10, 20, cắt theo độ dài lịch sử.

Câu hỏi nghiên cứu RQ1: trên dữ liệu du lịch thưa, có mùa vụ, phụ thuộc context – mô hình context-aware / tuần tự có vượt CF truyền thống?

Expedia Hotel Recommendations

3.000.693

booking (nhấn)

813.985


user có booking

100

hotel cluster

59.455

destination


Số booking theo tháng, 2013-01-07 → 2014-12-31

nghìn booking / tháng · tăng mạnh năm 2014

- **92,03%** dòng là click, chỉ dùng booking làm nhãn
- Mỗi dòng có đủ context: party, ngày, package, channel
- Cluster ẩn danh, không có thuộc tính item
- Không có cột giá

Tín hiệu nằm ở context của lượt search

Recall@5 của popularity theo từng điều kiện (test sau 2014-09-29)



53,1%

chỉ cần biết **destination** đang tìm


16,8%

lập lại cluster lần trước – lịch sử có tín hiệu nhưng yếu

Tháng và party gần như không đổi phân phối cluster (JSD 0,0019 và 0,0139 so với destination 0,4076).

Lịch sử ngắn, nhiều user mới

Phân bố số booking mỗi user (trung vị 2, p90 8)



30,14%

booking test thuộc user **chưa có trong train**

18,68%

booking test **không có booking nào trước đó** (kể cả trong test)

10.789

destination chỉ có 1 booking

Đặc điểm dữ liệu → yêu cầu với methodology

ĐẶC ĐIỂM	YÊU CẦU VỚI MÔ HÌNH
Context lượt search chi phối (destination)	Đưa context hiện tại vào mô hình, học tổ hợp giữa các trường
Có lịch sử booking theo thời gian	Khai thác thứ tự các booking trước đó
Lịch sử ngắn, nhiều user mới	Vấn dự đoán tốt khi không có lịch sử
Chỉ 100 cluster, không thuộc tính item	Xếp hạng toàn catalog, chi phí huấn luyện vừa phải
Dữ liệu theo thời gian, có mùa vụ	Split theo thời gian, không rò rỉ thông tin tương lai

Hướng tiếp cận phù hợp: **context-aware sequential recommendation**

Ba ứng viên (phiên bản gốc)

	SMLP4REC	ADAGIN	LIGHTGBM
Ý tưởng	MLP trộn thông tin theo 3 trục: chuỗi × feature × embedding	Đồ thị tương tác giữa các field (kiểu CTR)	Gradient boosting trên cây quyết định
Context lướt search	Qua trục feature	Tương tác field tường minh	Feature bảng, tương tác gián tiếp
Lịch sử user	Trục sequence, có thứ tự	Không mô hình hóa chuỗi	Chỉ qua feature tổng hợp thủ công
User ít lịch sử	Yếu – nhánh sequence rỗng	Ổn – không dùng user ID	Ổn nếu đủ feature context
Chi phí huấn luyện	1 dòng / booking, softmax 100 lớp	100 dòng / booking	1 dòng / booking, 100 cây mỗi vòng
Hạn chế chính	Lịch sử user ngắn	Tính toán nặng, code gốc có lỗi	Cách tiếp cận cũ, không học chuỗi

AdaGIN và LightGBM: vì sao không chọn làm chính

AdaGIN

context-aware

Đồ thị tương tác giữa các field kiểu CTR, học cạnh thích nghi.

- + Học tương tác field tường minh, không cần user ID
- **Khối lượng tính toán lớn**: mỗi booking chấm 100 cluster → **240.055.400** dòng train, **60.013.900** dòng test
- Loss BCE từng điểm, không tối ưu trực tiếp thứ hạng
- Code gốc có lỗi (nhiều Gumbel vẫn bật khi đánh giá)

LightGBM

tabular

Gradient boosting trên cây quyết định, feature dạng bảng.


- + Mạnh với dữ liệu bảng, nhanh, dễ giải thích
- **Cách tiếp cận cũ** (2017): không học biểu diễn, không mô hình hóa chuỗi
- Tương tác chỉ học gián tiếp qua nhánh cây
- Destination nhiều giá trị phải target-encode, dễ rò rỉ nhãn

Cả hai được giữ làm **mô hình so sánh**: AdaGIN cho context-aware (RQ1), LightGBM làm baseline dạng bảng.

Chọn SMLP4Rec: ý tưởng và kiến trúc

Gao et al., ACM TOIS 2024 – cài lại từ paper, thêm query token cho lượt search hiện tại

Tuần 2 · Methodology



- 1 Mỗi lượt dự đoán → khối $(S+1) \times F \times C$: chuỗi booking + query token của lượt search.
- 2 Ba MLP **song song** trộn thông tin theo **thời gian**, **context** và **chiều embedding**, cộng lại, lặp L lần.
- 3 Lấy hàng của query, so với 100 cluster → điểm xếp hạng.

Vì sao SMLP4Rec phù hợp

Đưa context chi phối vào mô hình

Query token + trực feature học tổ hợp như *family × package × destination*.

Khai thác lịch sử có thứ tự

MLP trên trực sequence nhận biết thứ tự sẵn, không cần positional embedding.

Nhẹ, nhanh

Chi phí tuyến tính theo độ dài chuỗi; softmax trên 100 cluster rẻ
→ đủ ngân sách cho nhiều seed và ablation.


Một khung thống nhất

Lịch sử, context và feature nằm trong cùng một khối, dễ ablation từng nhánh.

Kết luận: **SMLP4Rec là phương pháp chính** — đáp ứng cả context lẫn lịch sử với chi phí thấp nhất trong ba ứng viên.

Điểm yếu lớn nhất: lịch sử user ngắn

Tỉ lệ booking test theo số booking trước đó của user



18,68%

booking test **không có lịch sử** → nhánh sequence rỗng, mô hình chỉ còn context

33,34%


có **tối đa 1** booking trước đó → quá ít để học quy luật tuần tự

53,07%

chỉ bảng đếm theo destination đã đạt mức này – mô hình neural phải tự **ghi nhớ** bảng đếm với 59.455 destination, nhiều giá trị hiếm

Rủi ro: SMLP4Rec thuần có thể **thua bảng đếm popularity** ở nhóm user ít lịch sử → cần một thành phần bổ sung.

Đề xuất: hybrid cho user ít lịch sử



Ghi nhớ

Prior là bảng đếm cluster theo destination, làm mượt về market khi ít dữ liệu. Chỉ tính từ quá khứ – không rò rỉ nhãn.

Tự điều chỉnh

Gate học mức tin prior: user mới dựa vào prior, user nhiều lịch sử dựa vào SMLP4Rec.

Nối lịch sử với context

Mỗi booking lịch sử được đánh dấu “**cùng destination với lượt search**”.

User mới

0 booking trước đó

Prior dẫn dắt

Ít lịch sử

1–4 booking

Kết hợp prior + SMLP4Rec


Nhiều lịch sử

≥ 5 booking

SMLP4Rec dẫn dắt

Căn cứ chọn ngưỡng cho hybrid

Recall@5 của 3 luật đếm, theo số booking trước đó của user



NGŨỖNG LỊCH SỬ

0 | 1 | 2-4 | 5-9 | 10+

0 booking: lịch sử không có gì để dùng. Từ 5 booking: luật dùng lịch sử cùng destination hơn prior > 6 điểm.

NGŨỖNG DESTINATION (SỐ BOOKING TRAIN)

0 | 1-19 | 20+

Booking	% test	Prior thô	Prior mượt
0	0,6%	10,0%	10,0%
1-4	1,3%	47,7%	61,4%
5-19	3,2%	68,6%	71,1%
20-99	9,1%	70,4%	70,8%
100-999	29,1%	59,9%	59,9%
1000+	56,6%	46,5%	46,5%

Các số trên là luật xếp hạng bằng bảng đếm, không học tham số – chưa phải kết quả của SMLP4Rec hay hybrid. Dùng để (1) đặt ngưỡng, (2) làm mốc mà mô hình phải vượt. Kết quả mô hình có sau khi cài đặt.

Tổng kết

QUYẾT ĐỊNH

SMLP4Rec + hybrid cho user ít lịch sử

- SMLP4Rec: đưa context lượt search và lịch sử booking vào một mô hình nhẹ
- Hybrid: prior theo destination + gate theo độ dài lịch sử, bù cho 18,68% booking không có lịch sử
- AdaGIN (context-aware) và LightGBM (bảng) giữ làm mô hình so sánh

57,85%

Mốc Recall@5 cần vượt – luật đếm tốt nhất, **chưa phải kết quả mô hình**

52,18%

Mốc cho user mới – prior làm mượt theo destination

1

Pipeline dữ liệu

Chuỗi booking, query token, split theo thời gian

2

Baseline

Popularity, heuristic lịch sử, LightGBM

3

SMLP4Rec

Bản thuần, tuning trên validation

4

Hybrid

Prior + gate, chốt ngưỡng trên validation

5

So sánh

AdaGIN, ablation, cắt theo lịch sử và mùa