

Methodology

Phân tích LightGBM, AdaGIN và SMLP4Rec trước khi chọn methodology cho bài toán gợi ý hotel cluster theo ngữ cảnh chuyến đi.

Dữ liệu quyết định phương pháp

Xếp hạng 100 hotel cluster ẩn danh cho một lượt tìm kiếm, dựa trên ngữ cảnh chuyến đi và lịch sử booking nếu có. Chỉ booking làm nhãn dương; chia theo thời gian (2.400.554 train / 600.139 test).

01

Ngữ cảnh chi phối

JSD phân phối cluster: điểm đến 0,4076; market 0,3953; package 0,0386; đoàn khách 0,0139 bit.

02

Tín hiệu nằm ở tương tác

Recall@5: điểm đến 53,07%; điểm đến × tháng 46,55%; điểm đến × đoàn khách 51,59% — đếm theo tổ hợp bị phân mảnh.

03

Điểm đến nhiều mức giá trị

59.455 điểm đến; 10.789 chỉ có một booking. Market (2.118 giá trị) phủ 99,998% tập test.

04

User cold, lịch sử ngắn

30,14% sự kiện test thuộc user không có trong train. Trung vị 2 booking/user; 38,78% chỉ một booking.

- Yêu cầu: học **tương tác** giữa các trường ngữ cảnh, xử lý **trường nhiều mức giá trị**, và xếp hạng được **user cold** — không phụ thuộc chuỗi dài.

3 phương pháp, cùng 4 tiêu chí

Mỗi phương pháp đại diện một họ mô hình, được đánh giá theo cùng bốn tiêu chí trước khi kết luận lựa chọn ở mục 06.

1 · Ý tưởng	2 · Mạnh & yếu	3 · Điều kiện dùng	4 · Phù hợp Expedia
CÂY QUYẾT ĐỊNH · NEURIPS 2017 LightGBM Phân loại đa lớp 100 cluster, một dòng mỗi sự kiện, loss softmax cross-entropy.	TƯƠNG TÁC ĐẶC TRƯNG · TOIS 2024 AdaGIN Chấm điểm từng cặp (ngữ cảnh, cluster) qua đồ thị tương tác thích nghi theo mẫu; FuxiCTR.	TUẦN TỰ · TOIS 2024 SMLP4Rec Dự đoán cluster kế tiếp từ chuỗi booking có thứ tự, kiến trúc toàn MLP; RecBole.	

LightGBM

Ý TƯỞNG

Cộng dồn nhiều cây quyết định nhỏ; mỗi vòng dựng cho mỗi cluster một cây sửa phần sai của các cây trước. Điểm cluster = tổng điều chỉnh từ mọi cây.

MẠNH & YẾU

Mạnh: dữ liệu bảng, trường số và giá trị thiếu xử lý trực tiếp, nhanh, giải thích qua SHAP. Yếu: tương tác chỉ ngầm qua điểm chia; 59.455 điểm đến dễ overfit; đặc trưng lịch sử phải tạo thủ công.

ĐIỀU KIỆN DÙNG

CPU nhiều nhân, không cần GPU. Thư viện lightgbm (MIT), hoàn thiện. Target encoding có ngưỡng cho điểm đến.

PHÙ HỢP EXPEDIA

Mạnh và rẻ, nhưng giới hạn nằm đúng ở hai đặc tính quyết định của dữ liệu — tương tác và trường nhiều mức giá trị.

MỨC PHÙ HỢP THEO ĐẶC TÍNH

Ngữ cảnh; mùa vụ & đoàn khách nằm trong tương tác	Trung bình
Điểm đến 59.455 giá trị, đuôi dài	Trung bình
30,14% user test là cold	Cao
Tập item đóng 100 cluster	Cao
Ngữ cảnh số, 33,83% thiếu khoảng cách	Cao
Lịch sử ngắn (trung vị 2)	Trung bình
Tổng thể	Trung bình-cao

AdaGIN

Ý TƯỞNG

Mỗi trường ngữ cảnh là một nút; mô hình dựng đồ thị riêng cho từng mẫu, chỉ giữ cạnh mạnh nhất, truyền thông tin qua nhiều lớp để tạo tương tác bậc cao mà không liệt kê tổ hợp.

ĐIỀU KIỆN DÙNG

PyTorch + FuxiCTR, mã tác giả (Apache-2.0). Nên có GPU. 100 dòng mỗi sự kiện: 240 triệu dòng train trước lấy mẫu âm.

MẠNH & YẾU

Mạnh: tương tác tường minh, thích nghi theo kiểu chuyển đi; embedding cho trường nhiều mức giá trị; không cần user ID. Yếu: chi phí mở rộng 100 dòng; BCE theo điểm không tối ưu trực tiếp thứ hạng; bằng chứng gốc chỉ từ benchmark CTR.

PHÙ HỢP EXPEDIA

Đáp ứng đồng thời tương tác, trường nhiều mức giá trị và user cold mà không sửa kiến trúc.

MỨC PHÙ HỢP THEO ĐẶC TÍNH

Ngữ cảnh; mùa vụ & đoàn khách nằm trong tương tác

Cao

Điểm đến 59.455 giá trị, đuôi dài

Cao

30,14% user test là cold

Cao

Tập item đóng 100 cluster

Trung bình

Ngữ cảnh số, 33,83% thiếu khoảng cách

Trung bình

Lịch sử ngắn (trung vị 2)

Trung bình

Tổng thể

Cao

AdaGIN, 5 bước – không công thức



TRAIN Sigmoid + binary cross-entropy (1 cho cluster được đặt, 0 cho cluster âm lấy mẫu); gradient cập nhật cùng lúc embedding, cách dựng đồ thị và cộng.

SMLP4Rec

Ý TƯỞNG

Chuỗi booking thành khối ba trục (vị trí × đặc trưng × chiều ẩn); ba MLP trộn thông tin theo từng trục thay cho self-attention. Vector booking cuối so với 100 cluster.

MẠNH & YẾU

Mạnh: full softmax trên 100 cluster, mô hình nhẹ.
Yếu: không thấy ngưỡng cảnh lượt tìm kiếm hiện tại; user cold không có chuỗi; code cứng độ dài 50, không padding mask.

ĐIỀU KIỆN DÙNG

PyTorch + RecBole 1.0, một file mô hình; không thấy file giấy phép. CPU khả thi với chuỗi ngắn.

PHÙ HỢP EXPEDIA

Thấp ở dạng gốc. Cần hai điều chỉnh: ngưỡng cảnh theo từng vị trí và token truy vấn cho lượt hiện tại.

MỨC PHÙ HỢP THEO ĐẶC TÍNH

Ngưỡng cảnh chi phối	Thấp (gốc)
Điểm đến 59.455 giá trị	Thấp (gốc)
30,14% user test là cold	Thấp (gốc)
Tập item đóng 100 cluster	Cao
Lịch sử ngắn (trung vị 2)	Thấp
Tổng thể	Thấp (gốc)

Đối chiếu yêu cầu cốt lõi

YÊU CẦU	LIGHTGBM	ADAGIN	SMLP4REC
Mã nguồn công khai	Đạt	Đạt	Đạt; giấy phép chưa rõ
Tương tác giữa các trường ngữ cảnh	Một phần (ngầm qua điểm chia)	Đạt (tường minh, thích nghi)	Một phần (chỉ sau điều chỉnh)
Trường nhiều mức giá trị (59.455 điểm đến)	Một phần (target encoding)	Đạt (embedding, OOV)	Không (gốc)
Xếp hạng user cold	Đạt	Đạt	Chỉ với token truy vấn
Khả thi 2–3 tuần trên một máy trạm	Đạt	Đạt; cần GPU, lấy mẫu âm	Đạt sau khi sửa code
Rủi ro lớn nhất	Rò rỉ qua target encoding	Chi phí mở rộng; chênh lệch nhỏ so với DCNv2	Chuỗi ngắn; phải sửa code

Sau khi phân tích 3 method – AdaGIN được chọn

1

AdaGIN là phương pháp duy nhất đáp ứng đồng thời tương tác giữa các trường ngữ cảnh, trường nhiều mức giá trị và user cold mà không sửa kiến trúc.

SO VỚI LIGHTGBM

Mạnh và rẻ, nhưng tương tác chỉ ngàm qua điểm chia; recall điểm đến × tháng (46,55%) thấp hơn điểm đến (53,07%) cho thấy chia nhỏ dữ liệu làm mất tín hiệu.

SO VỚI SMLP4REC

Bản gốc bỏ qua ngữ cảnh lượt hiện tại và user cold (30,14% sự kiện test); trung vị 2 booking/user khiến thứ tự chuỗi ít tín hiệu.

RỦI RO & BIỆN PHÁP

100 dòng mỗi sự kiện → lấy mẫu âm, chạy thử trên mẫu con. BCE theo điểm → chọn mô hình theo NDCG trên validation. So với DeepFM, DCNV2 cùng FuxiCTR, ≥ 3 seed.

HẠN CHẾ CÒN LẠI

Bảng chứng của AdaGIN đến từ benchmark CTR; hiệu năng trên dữ liệu booking du lịch chưa được kiểm chứng. Hotel cluster chỉ là đại diện ẩn danh cho hạng phòng / gói.

⚠ Mức phù hợp là đánh giá định tính theo đặc tính dữ liệu Expedia; chưa có số đo huấn luyện của cả 3 phương pháp — số đo cụ thể được ghi ở Phase 2.

AdaGIN phải vượt các mốc này

Recall@5 của bảng tần suất trên cùng tập test chia theo thời gian — mốc tham chiếu trước khi so sánh mô hình.

14,06%

Tần suất toàn cục

Thấp hơn mức này: lỗi cài đặt



16,82%

Lắp lại cluster gần nhất

Giới hạn của riêng yếu tố lắp lại



46,55%

Điểm đến × tháng nhận phòng

Phần mất do phân mảnh cần khôi phục



53,07%

Tần suất điểm đến

Ngưỡng mô hình học máy phải vượt

EVAL Recall@K, NDCG@K, MRR (K = 5, 10, 20), xếp hạng toàn bộ 100 cluster; validation trên quý liền trước test; tối thiểu ba seed.