

TUẦN 3 · TRIỂN KHAI & THỬ NGHIỆM

Triển khai code gốc SMLP4Rec trên Expedia

và các thử nghiệm bổ sung

Next-Best-Product Recommendation · Vinpearl × GSM · Bối cảnh (a): du lịch

Lý thuyết

Chạy plain


Rút ra

Thử nghiệm

SMLP4Rec: đoán cụm khách sạn tiếp theo từ lịch sử booking

Chọn làm phương pháp chính ở tuần 2 (Gao et al., ACM TOIS 2024). Việc cần làm: chạy thử trên Expedia

Tuần 3 · Triển khai



- 1 Đầu vào: chuỗi các cụm đã đặt (và query token của lượt search).
- 2 Ba MLP song song trộn theo **thời gian, context, embedding**, lặp L lần.
- 3 Lấy hàng cuối, so với 100 cụm → điểm xếp hạng.


Từ code gốc đến bản chạy với Expedia

Chỉnh sửa tối thiểu để chạy được, chưa tối ưu

HẠNG MỤC	CODE GỐC	BẢN CHO EXPEDIA
Dữ liệu	MovieLens, item có feature	Booking Expedia: user, cụm (100), thời gian; cụm không có feature
Độ dài chuỗi	Cố định 50	Lấy từ cấu hình (= 20)
Feature item	Bắt buộc có	Cho phép rỗng, bỏ lớp feature
Chia và đánh giá	Leave-one-out, 100 mẫu theo popularity	Chia theo thời gian 80/10/10, xếp hạng đủ 100 cụm
Cấu hình	Cấu hình paper, quá chậm trên CPU	2 lớp, hidden 64, dropout 0
Môi trường	RecBole 1.0.1 (numpy 1.23, pandas 1.5)	Venv Python 3.11 riêng + 2 bản vá nhỏ

Giữ nguyên từ bản gốc: một khối dùng chung cho mọi lớp, không residual. Chỉ sửa 2 chỗ trong mã mô hình (đánh dấu ADAPTED).

Pipeline và chia dữ liệu



TẬP	SỐ MỤC TIÊU	TỪ NGÀY	ĐẾN NGÀY
Train	1.749.368	07/01/2013	08/10/2014
Valid	218.670	08/10/2014	19/11/2014
Test	218.670	19/11/2014	01/01/2015


813.985 người dùng · 100 cụm · 2.186.708 mục tiêu “đặt tiếp theo” (mọi booking trừ lần đầu của mỗi người). Chia theo thời gian, xếp hạng đầy đủ.

Chạy plain: chỉ dùng lịch sử booking

Câu hỏi: chỉ lịch sử có đủ để đoán cụm tiếp theo không?

Tuần 3 · Triển khai

NDCG@K, tập test, xếp hạng đầy đủ 100 cụm



SMLP4REC PLAIN, TEST

NDCG@5 0,2439

Recall@5 33,69% · NDCG@10 0,2850

NDCG@5 QUA 3 EPOCH

0,2426 → 0,2439

thêm epoch gần như không giúp (+0,13 điểm)

Rút ra: có tín hiệu (gấp 2,6 lần popularity) nhưng điểm thấp. Vì sao?

Vì sao plain thấp, và thử theo hướng nào

Rút ra từ top 5 của plain → hai hướng thử nghiệm

Tuần 3 · Triển khai

69%

lần đặt tiếp theo là **cụm mới**, lịch sử không đoán được

83%

dòng có **top 1 = cụm đặt gần nhất**: plain chủ yếu gợi lại

81,9% vs 12,3%

trùng khi đặt lại cụm cũ vs đặt cụm mới

Hướng A: chỉnh cách chọn top 5

Ép một phần top 5 dành cho cụm mới.

Hướng B: thêm thông tin điểm đến

Prior điểm đến, rồi tín hiệu “đặt lại tại cùng điểm đến” (sameDest).

Plain chưa thấy điểm đến của lần tìm kiếm, nên yếu ở nhóm cụm mới (12,3%, popularity top 5: 13,7%).

Hướng A: ép tỉ lệ cụm cũ / cụm mới trong top 5

Giả thuyết: top 5 thiên về cụm cũ, chia lại cho cụm mới sẽ tốt hơn? (% trúng tính trên toàn bộ dòng test)

Tuần 3 · Triển khai

CÁCH	NDCG@5	RECALL@5	CỤM CŨ TRÚNG	CỤM MỚI TRÚNG
Plain: 5 điểm cao nhất	0,2439	33,69%	25,17%	8,52%
Cố định 2 cũ + 3 mới	0,2338	31,43%	20,42%	11,01%
Tối đa 1 cũ nếu $L < 5$, 2 nếu $L \geq 5$	0,2283	30,43%	18,58%	11,84%

L = số booking trước đó. Rút ra: ép tỉ lệ làm **giảm** điểm; mỗi cụm mới trúng thêm làm mất khoảng 2 cụm cũ. Gọi cụm mới đang yếu, cần thêm thông tin → hướng B.


Hướng B1: thêm prior điểm đến

Giả thuyết: điểm đến đang tìm quyết định cụm được đặt. Không huấn luyện lại; w chọn trên valid

Tuần 3 · Triển khai

$$\text{điểm} = \log p_{\text{SMLP4Rec}} + w \cdot \log p_{\text{prior}}(\text{cụm} \mid \text{điểm đến})$$

NDCG@5 theo w (w = 0 là plain)



TEST	NDCG@5	RECALL@5
Plain	0,2439	33,69%
Prior một mình	0,3631	52,98%
SMLP4Rec + prior (w = 1,5)	0,4227	59,19%

Rút ra: prior là đòn bẩy lớn nhất (NDCG@5 0,2439 → 0,4227; +25,5 điểm Recall@5), chủ yếu ở cụm mới (NDCG@5 0,059 → 0,318; Recall@5 12% → 49%). Người dùng mới (18% sự kiện test) chỉ dùng prior: NDCG@5 0,3506, Recall@5 51,2%.

Hướng B2: thêm sameDest, hybrid ba tín hiệu

Giả thuyết: người dùng hay đặt lại cụm đã ở tại điểm đến này. Cột cuối: người dùng mới dùng prior

Tuần 3 · Triển khai

$$\text{điểm} = \log q_{\text{SMLP4Rec}} + w_p \cdot \log q_{\text{prior}} + w_s \cdot \log q_{\text{sameDest}}$$

trong đó mỗi q là xác suất p đã trộn với phân bố đều: $\log q = \log((1 - \alpha) \cdot p + \alpha/100)$

sameDest(cụm) = tổng $0,7^{\text{tuổi}}$ các lần người dùng đặt cụm đó **tại đúng điểm đến đang tìm** (tuổi 0 = lần gần nhất), chia cho tổng để thành phân bố. Ví dụ: cụm 12 đặt tại Cancún ở tuổi 0 và 3 $\rightarrow 1,343$; đặt ở điểm đến khác $\rightarrow 0$. Ba thành phần cùng một thang nên trọng số đọc được như mức tin cậy; chưa từng đặt tại điểm đến này $\rightarrow$ sameDest không tác động.

CÁCH (TEST)	NDCG@5	RECALL@5	NDCG@10	RECALL@10	NDCG@5 GỒM NGƯỜI DÙNG MỚI	R@5 GỒM NGƯỜI DÙNG MỚI
1. Plain SMLP4Rec	0,2439	33,69%	0,2850	46,45%	0,2139	29,90%
2. Prior điểm đến một mình	0,3631	52,98%	0,4251	72,12%	0,3608	52,66%
3. SMLP4Rec + prior	0,4227	59,19%	0,4791	76,57%	0,4094	57,72%
4. Hybrid: + sameDest	0,4539	61,06%	0,5070	77,41%	0,4349	59,25%

Rút ra: hybrid cao nhất ở mọi cột; so với SMLP4Rec + prior: NDCG@5 +3,13 điểm [3,03; 3,21], Recall@5 +1,87 điểm [1,76; 1,97] (bootstrap 95%). Tăng ở điểm đến đã đặt (NDCG@5 0,5188 $\rightarrow$ 0,6175; Recall@5 67,8% $\rightarrow$ 74,0%), điểm đến mới gần như giữ nguyên (NDCG@5 0,3817 $\rightarrow$ 0,3842; Recall@5 55,5% $\rightarrow$ 55,5%). Trọng số chọn trên valid (quy tắc 1-SE), $\alpha = 0,2$, 2 bộ: điểm đến mới w_p 2,00; đã đặt w_p 1,25, w_s 1,00.

Hướng B3: tách trọng số theo thói quen đặt lại

Giả thuyết: người hay đặt lại cụm cũ cần trọng số khác người hay đặt cụm mới. Công thức B2 giữ nguyên, chỉ đổi cách chia nhóm Tuần 3 · Triển khai

old_share

tỉ lệ booking trong lịch sử là **cụm đã đặt trước đó** (chỉ dùng lịch sử, không dùng mục tiêu)

0,25

ngưỡng chọn trên train: **thiên cũ** nếu old_share ≥ ngưỡng, còn lại **thiên mới**; L = 1 là nhóm riêng

≥ 10%

mỗi bộ trọng số phải phủ ít nhất 10% dòng, không tạo nhóm nhỏ

CÁCH CHIA TRỌNG SỐ (TEST)	NDCG@5	RECALL@5	NDCG@10	RECALL@10	NDCG@5 GỒM NGƯỜI DỪNG MỚI	R@5 GỒM NGƯỜI DỪNG MỚI
Hybrid B2: điểm đến mới / đã đặt (2 bộ)	0,4539	61,06%	0,5070	77,41%	0,4349	59,25%
Thêm thói quen: điểm đến × thiên cũ / còn lại (4 bộ)	0,4539	61,10%	0,5069	77,45%	0,4349	59,27%


Rút ra: tách theo thói quen **không** cải thiện: NDCG@5 -0,00 điểm [-0,02; 0,02], Recall@5 +0,03 điểm [-0,00; 0,07] (bootstrap 95%); quy tắc 1-SE trên valid vẫn chọn 2 bộ của B2. Thói quen đặt lại đã nằm sẵn trong sameDest, nên không cần trọng số riêng.

Đánh giá theo người dùng đã thấy và chưa thấy trong train

Chia tập valid và test thành hai tập con không giao nhau theo việc người dùng có mặt trong train

Tuần 3 · Triển khai

Tỉ lệ người dùng và sự kiện theo việc có mặt trong train



TEST: NGƯỜI DÙNG CHƯA THẤY

51,1%

84.687 / 165.833 người dùng

TRONG ĐÓ ĐÃ CÓ LỊCH SỬ ($L \geq 1$)

48.008

còn lại 36.679 chỉ có lần đặt đầu ($L = 0$)

ĐỘ DÀI LỊCH SỬ TRUNG BÌNH, TEST

9,8 vs 2,4

đã thấy vs chưa thấy ($L \geq 1$)


Đã thấy = có ít nhất một dòng trong tập train của RecBole. Chưa thấy gồm người có lịch sử nhưng toàn bộ booking nằm sau cửa sổ train, và người đặt lần đầu ($L = 0$). Số sự kiện test: 268.113.

Plain và hybrid trên người dùng đã thấy và chưa thấy


Cùng checkpoint và trọng số của notebook 04, không huấn luyện lại; chấm riêng từng tập con

Tuần 3 · Triển khai

NDCG@5, tập test



Recall@5, tập test



Rút ra: hybrid cao hơn plain ở mọi tập con (NDCG@5 đã thấy 0,243 → 0,464; chưa thấy 0,180 → 0,402). Plain gần như không phụ thuộc việc “đã thấy”: người chưa thấy nhưng có lịch sử đạt NDCG@5 0,245 so với 0,243, vì mô hình chỉ đọc chuỗi booking. Chênh lệch chính là độ dài lịch sử. * $L = 0$ (lần đặt đầu): plain không có đầu vào nên dùng popularity toàn cục; hybrid dùng prior điểm đến.

Hai baseline cơ bản trên cùng phép chia 8/1/1

Một mô hình chỉ đọc lịch sử, một mô hình chỉ đọc điểm đến và ngữ cảnh; mỗi mô hình bị chặn đúng một nguồn tín hiệu

BASELINE	THƯ VIỆN	THẤY	KHÔNG THẤY	CHỌN TRÊN VALID
ItemKNN (cosine, Sarwar 2001)	implicit · CosineRecommender	20 booking gần nhất của người dùng	điểm đến, mọi ngữ cảnh	K = 100 trong {5, 10, 20, 50, 100}
Hồi quy logistic đa lớp	scikit-learn · saga	điểm đến + ngữ cảnh lượt tìm (one-hot)	lịch sử, mọi trường của khách sạn đã đặt	C = 10 trong {0,1; 1; 10}; 3 epoch

2.186.700

mục tiêu “đặt tiếp theo”, chia theo thời gian 80/10/10 như bản plain

268.113

sự kiện test, bản plain có 268.113 (chênh 0)

0

dòng valid/test nằm trong dữ liệu huấn luyện của hai baseline

Mục đích: kiểm tra điểm cao của hybrid đến từ dữ liệu chứ không từ rò rỉ hay lỗi chia tập, bằng hai mô hình có sẵn trong thư viện, không dùng code của hybrid. Dữ liệu huấn luyện của cả hai: booking trước mốc cắt (cùng mốc cắt của prior). ItemKNN không có epoch, tính một lần theo công thức. K và C chọn trên valid theo Recall@5 + NDCG@5; test chấm một lần.

Hai baseline so với plain và hybrid, tập test

Cùng dòng test, cùng Recall@K và NDCG@K; hàng plain và hybrid lấy từ notebook 06

Tuần 3 · Triển khai

CÁCH	NDCG@5 (MỌI SỰ KIỆN)	RECALL@5 (MỌI SỰ KIỆN)	NDCG@5 ĐÃ THẤY	NDCG@5 CHƯA THẤY, L ≥ 1	NDCG@5 L = 0*
Popularity toàn cục (không học)	0,091	14,5%	0,096	0,090	0,081
ItemKNN (K = 100): chỉ lịch sử	0,194	28,2%	0,213	0,231	0,081
SMLP4Rec plain: chỉ lịch sử	0,214	29,9%	0,243	0,245	0,081
Hồi quy logistic (C = 10): điểm đến + ngữ cảnh	0,354	51,9%	0,365	0,340	0,345
Hybrid: lịch sử + prior + sameDest	0,435	59,2%	0,464	0,435	0,350

Rút ra: (1) ItemKNN, chỉ đọc lịch sử, nằm sát SMLP4Rec plain (NDCG@5 0,194 so với 0,214), nên plain không bị thổi phồng. (2) Hồi quy logistic, chỉ có điểm đến và ngữ cảnh, đạt 0,354; ở lần đặt đầu (L = 0) chỉ kém hybrid 0,005 điểm NDCG@5. (3) Hybrid cao hơn hồi quy logistic ở mọi cột. * L = 0: ItemKNN và plain dùng popularity toàn cục (cùng số). Số dòng mỗi tập con lệch bản plain tối đa 4 dòng.

Điểm cao đến từ đâu: điểm đến trước, lịch sử sau

Mỗi baseline chặn một nguồn tín hiệu; hybrid cộng cả hai

Tuần 3 · Triển khai

0,091

popularity toàn cục: không dùng thông tin gì

0,354

thêm điểm đến và ngữ cảnh (hồi quy logistic):
+0,263

0,435

thêm lịch sử cùng điểm đến và SMLP4Rec
(hybrid): **+0,081**

Đối chứng, test, người dùng có lịch sử (NDCG@5)

PHÉP THỬ	THẬT	XÁO TRỘN
Hồi quy logistic: xáo trộn đặc trưng lượt tìm	0,356	0,047
ItemKNN: xáo trộn lịch sử giữa các dòng	0,220	0,048

Mốc popularity toàn cục cùng tập: 0,094. Xáo trộn đưa cả hai về mức popularity, nên tín hiệu là thật.

Kiểm tra độc lập (scripts/verify_basic_baselines.py)

Dựng lại phép chia, lịch sử, độ tương tự cosine và đặc trưng bằng code riêng; chấm lại ItemKNN và hồi quy logistic; so với kết quả đã lưu: 0 sai khác về hạng. Hồi quy logistic không dùng trường nào của khách sạn đã đặt, thành phố hay vùng của khách (0 đặc trưng vi phạm). Huấn luyện kết thúc trước mục tiêu valid đầu tiên 147 giây.

Kết luận: phần lớn điểm của hybrid giải thích được bằng điểm đến của lượt tìm, thông tin có sẵn trước khi đặt; lịch sử thêm phần còn lại. Không thấy dấu hiệu rò rỉ hay lỗi chia tập. Giới hạn: một seed; C = 10 là giá trị lớn nhất trong lưới nên có thể còn tăng nhẹ; hồi quy logistic chỉ chạy 3 epoch.

Kết luận

Đã làm

Chạy SMLP4Rec gốc trên Expedia (plain), rút ra điểm yếu, thử hai hướng: chỉnh top 5 và thêm thông tin điểm đến (prior, rồi sameDest); cuối cùng thử tách trọng số theo thói quen.

Rút ra

Đa số đặt cụm mới; điểm đến là tín hiệu chủ đạo. Ép tỉ lệ làm giảm điểm; prior và sameDest tăng mạnh: NDCG@5 0,24 → 0,45, Recall@5 34% → 61%. Tách theo thói quen không thêm gì. Hồi quy logistic chỉ dùng điểm đến đạt NDCG@5 0,35 (mọi sự kiện test), ItemKNN chỉ dùng lịch sử đạt 0,19: điểm cao chủ yếu do điểm đến; hai baseline không cho thấy dấu hiệu rõ ràng.

Còn lại

Một seed, prior tĩnh; hai baseline cơ bản (ItemKNN, hồi quy logistic) đã chạy, chưa có MF, item2vec, AdaGIN, LightGBM. Tiếp: đưa điểm đến vào trong mô hình, chạy lại trên chia theo sự kiện (gồm người dùng mới).

Quyết định: SMLP4Rec + prior điểm đến + sameDest, 2 bộ trọng số (điểm đến mới / đã đặt); không tách theo thói quen.

Lưới trọng số của hai bản hybrid (B2 và B3)

Không gian tìm kiếm, quy tắc chọn và trọng số cuối cùng

B2: 2 bộ trọng số (điểm đến mới / đã đặt)

$\alpha \in \{0,05 \cdot 0,1 \cdot 0,2 \cdot 0,3 \cdot 0,5\}$ · $w_p \in \{0 \cdot 0,25 \cdot 0,5 \cdot 0,75 \cdot 1 \cdot 1,25 \cdot 1,5 \cdot 2 \cdot 2,5 \cdot 3\}$ · $w_s \in \{0 \cdot 0,25 \cdot 0,5 \cdot 0,75 \cdot 1 \cdot 1,25 \cdot 1,5 \cdot 2 \cdot 2,5 \cdot 3\}$ · $w_{SMLP4Rec} = 1 \rightarrow 500$ cấu hình, chấm trên valid.

BỘ TRỌNG SỐ (A = 0,2)	W _P	W _S
Điểm đến mới với người dùng	2,00	– (hằng số)
Điểm đến đã đặt trước đó	1,25	1,00

$\alpha = 0,2$ được chọn cùng lúc: 7 cấu hình nằm trong một sai số chuẩn của cấu hình tốt nhất.

B3: 4 bộ trọng số (điểm đến × thói quen)

Cùng lưới $w_p \times w_s$ (100 cặp) cho từng bộ, α cố định 0,2, ngưỡng old_share 0,25.

BỘ TRỌNG SỐ (A = 0,2)	W _P	W _S
Điểm đến mới · còn lại	2,00	– (hằng số)
Điểm đến mới · thiên cũ	1,50	– (hằng số)
Đã đặt · còn lại	1,25	1,25
Đã đặt · thiên cũ	1,25	1,00

Trọng số mỗi bộ chọn bằng cùng quy tắc; quy tắc 1-SE ở mức lược đồ vẫn giữ 2 bộ của B2.

Quy tắc chọn (chỉ dùng valid): điểm mỗi dòng = Recall@5 + NDCG@5; trong các cấu hình nằm trong một sai số chuẩn (gom theo người dùng) của cấu hình tốt nhất, lấy cấu hình đơn giản nhất = w lớn nhất nhỏ nhất, rồi tổng w nhỏ nhất, rồi α lớn nhất. w_s “hằng số”: điểm đến chưa từng đặt thì sameDest không tác động xếp hạng.