TUẦN 4 · LÀM SẠCH DỮ LIỆU

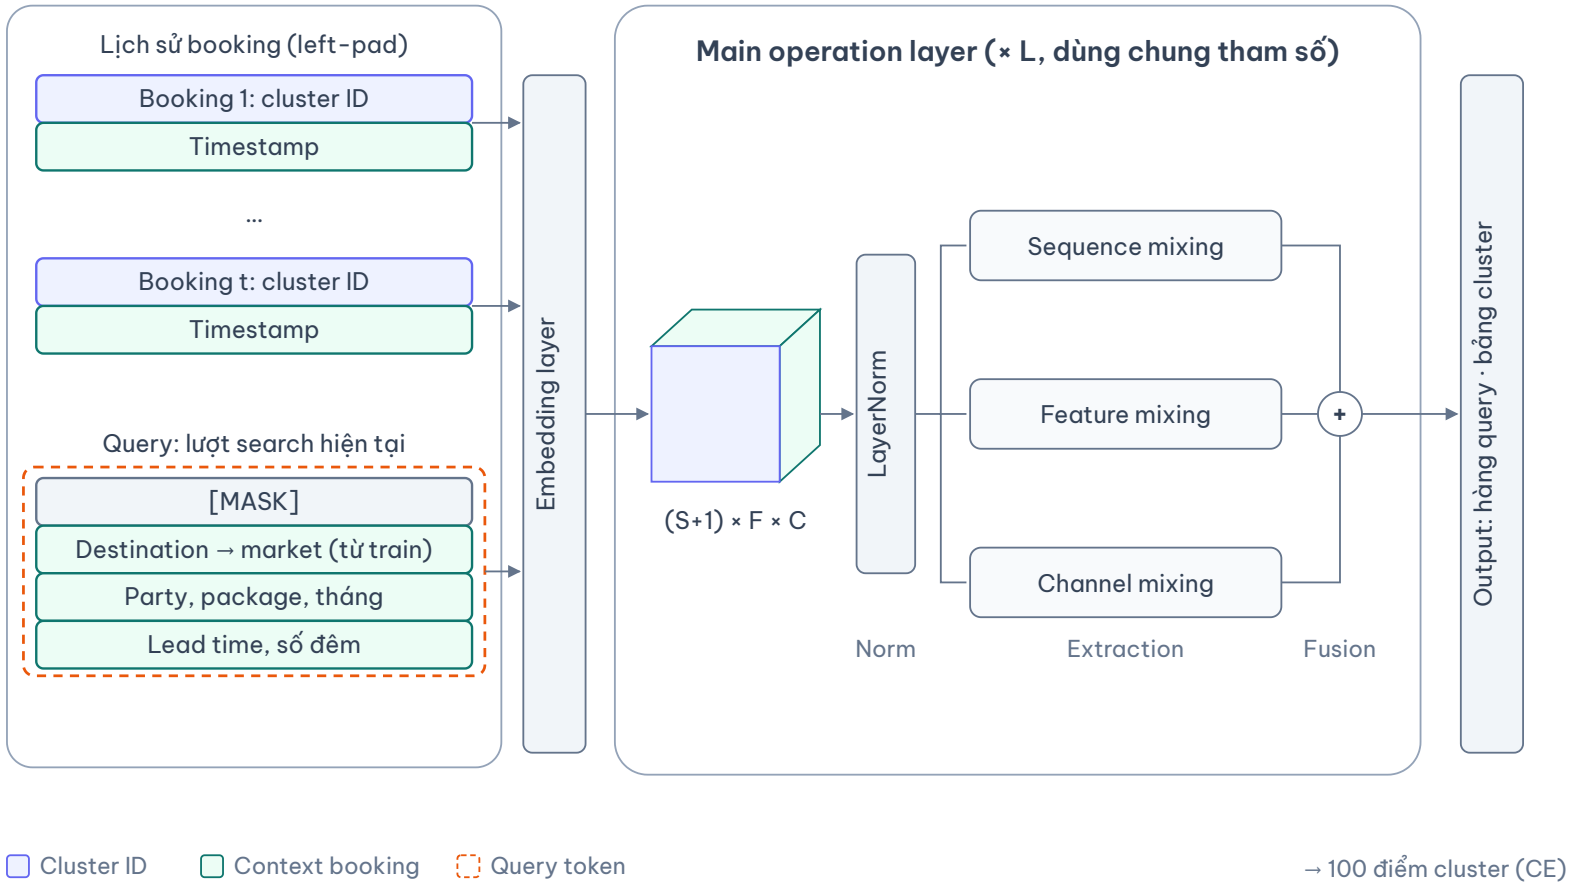
Làm sạch Expedia và chạy lại SMLP4Rec:

điểm của các mô hình dùng lịch sử giảm, thứ hạng giữ nguyên

Next-Best-Product Recommendation · Vinpearl × GSM · Bối cảnh (a): du lịch

SMLP4Rec: đoán cụm khách sạn tiếp theo từ lịch sử booking

Thuật toán không đổi so với tuần trước; tuần này chỉ đổi dữ liệu



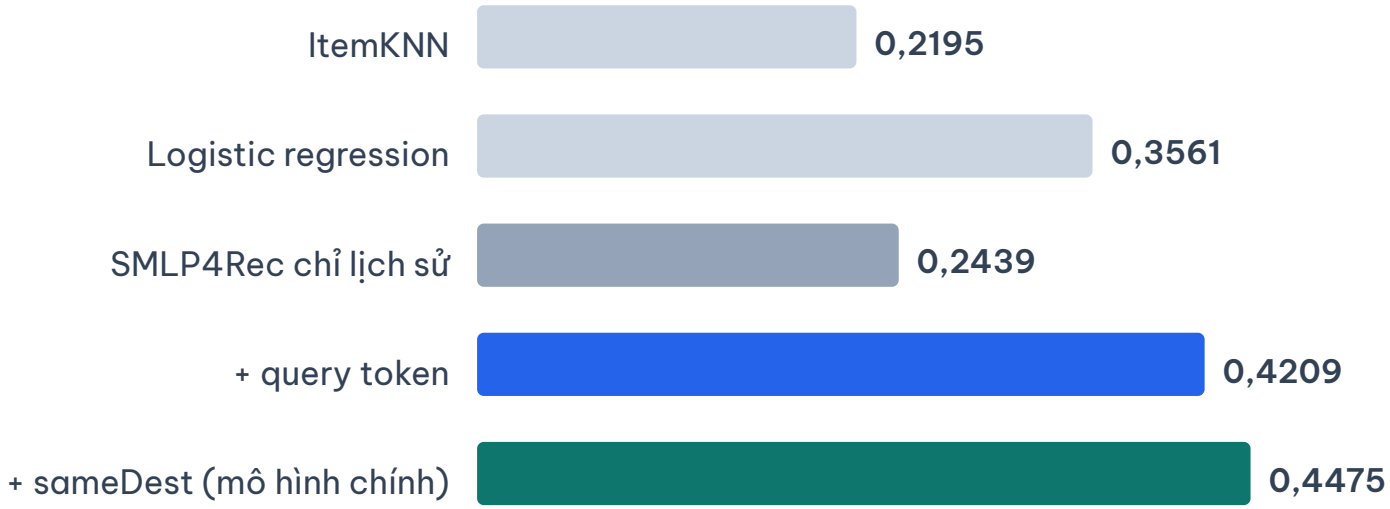
1. Đầu vào: chuỗi các cụm đã đặt, cộng query token là lượt tìm hiện tại.
2. Ba MLP song song trộn theo **thời gian**, **context**, **embedding**, lặp L lần.
3. Lấy hàng cuối, so với 100 cụm để xếp hạng; sameDest cộng điểm cho cụm đã đặt tại đúng destination đang tìm.

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

Query token nâng NDCG@5 từ 0,24 lên 0,42; sameDest thêm 0,027

Chia theo thời gian 80/10/10, xếp hạng đủ 100 cụm, seed 2022, 3 epoch

NDCG@5, dòng warm của tập test, dữ liệu thô, một seed



+0,177

NDCG@5 khi đưa lượt tìm hiện tại vào mô hình (query token so với chỉ lịch sử)

+0,027

NDCG@5 sameDest cộng thêm trên query token

218.670

dòng warm trong tập test (user đã có lịch sử)

Kết quả tuần trước chạy trên dữ liệu chưa kiểm tra lỗi; tuần này kiểm tra xem chúng còn đứng vững không.

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

48.010 booking lặp y hệt booking trước đó, 52% cách nhau dưới 1 giờ

Lặp = cùng user, destination, ngày check-in, ngày check-out và cluster với booking ngay trước

Khoảng cách giữa booking lặp và booking gốc cùng user (cùng destination, ngày, cluster)



2,24%

target của tập test là booking lặp; nếu bản gốc nằm trong lịch sử, mô hình chỉ cần chép lại đáp án

13%

số dòng mà sameDest có thể trúng chỉ nhờ booking lặp

1,6%

tổng số booking bị ảnh hưởng

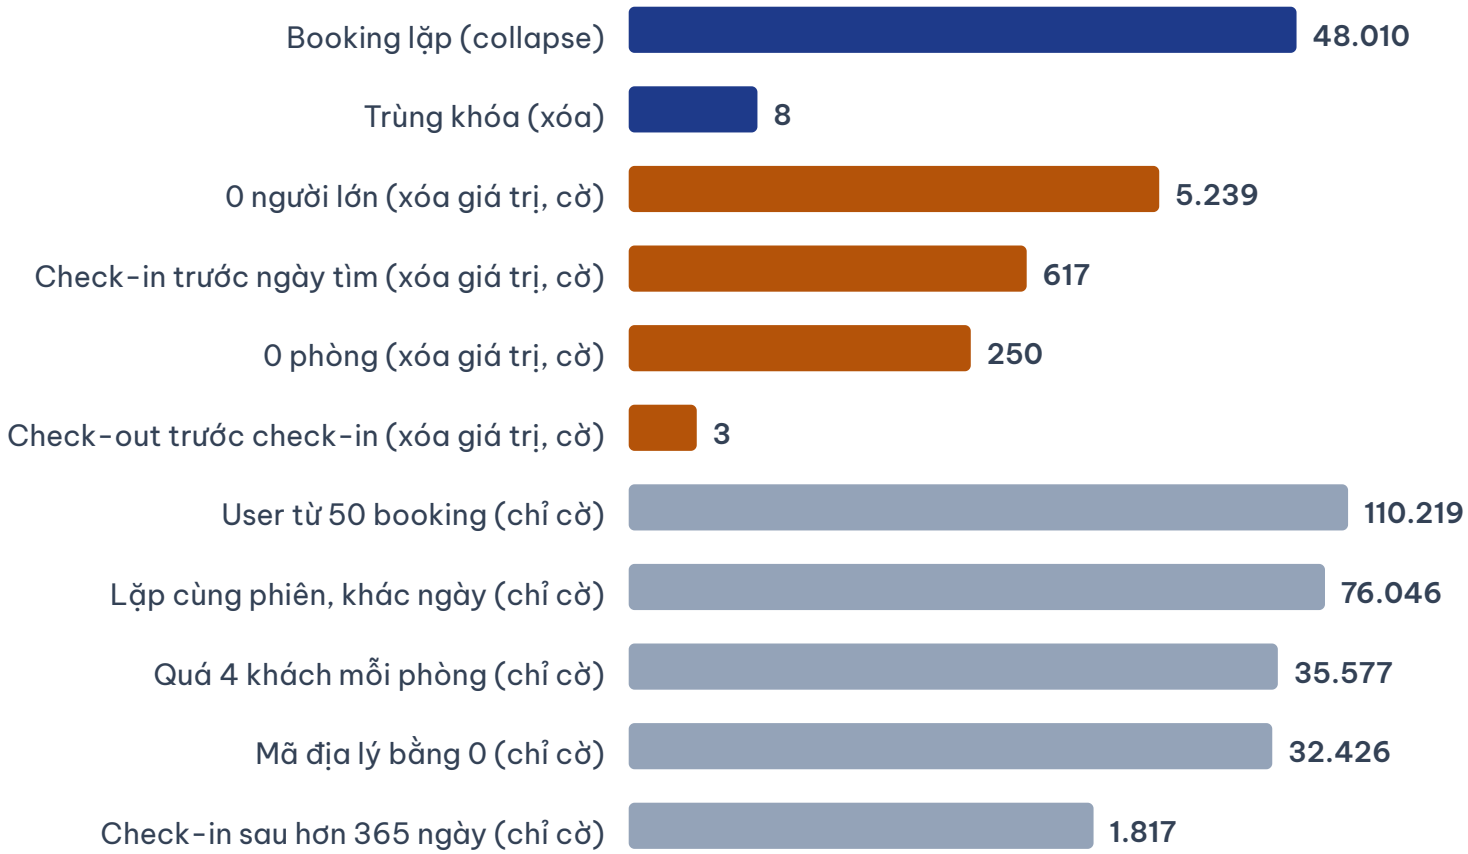
Hai đỉnh: lặp trong vài phút (tìm và đặt lại ngay) và lặp sau khoảng một ngày; cả hai đều ghi cùng một chuyến.

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

Chỉ bỏ dòng khi nó ghi cùng một sự kiện hai lần; mọi bất thường khác chỉ gắn cờ

Kênh số 0 là kênh hợp lệ và dữ liệu không có cột giá, nên hai mục này không cần xử lý

Số dòng chịu tác động của từng quy tắc (thang log)



3.000.685 → 2.952.675

booking sau khi bỏ trùng khóa và collapse; user giữ nguyên 813.985

76.046

lặp cùng phiên nhưng khác ngày vẫn giữ: có thể là đổi chuyến thật, sẽ đo riêng

Xanh đậm: bỏ khỏi dữ liệu · cam: xóa giá trị lỗi, giữ dòng · xám: chỉ gắn cờ để phân tích.

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

Sáu mô hình chạy lại: mọi mô hình dùng lịch sử đều giảm điểm

Cả các thí nghiệm tuần trước (quota top-5, prior, hybrid, tách trọng số theo hành vi) được chạy lại, cho cùng kết luận

NDCG@5, dòng warm của tập test



218.670 → 213.869

dòng warm của tập test: trước và sau khi bỏ booking lặp

1 thay đổi

chỉ dữ liệu: cùng cấu hình, seed 2022, 3 epoch

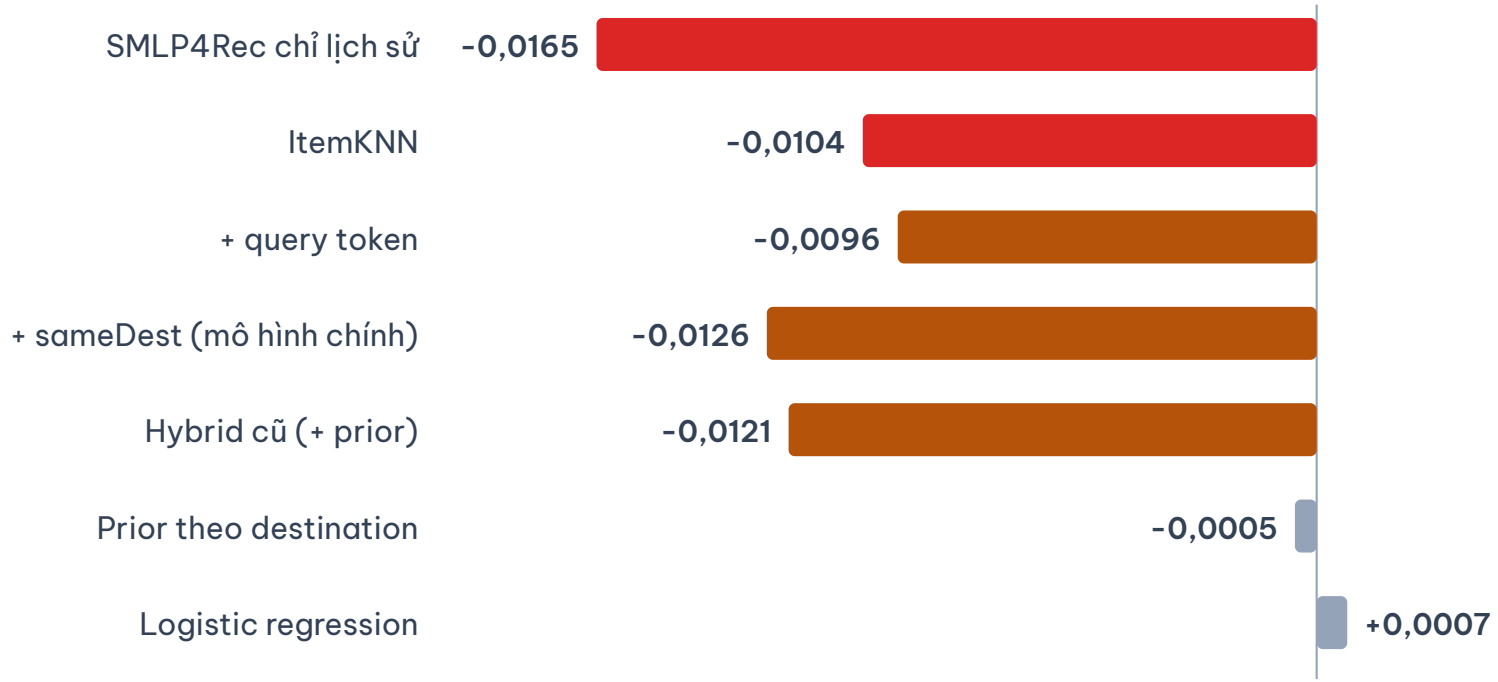
Thứ hạng giữa các mô hình không đổi; chỉ mức điểm của các mô hình dùng lịch sử thấp hơn.

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

Càng dựa vào lịch sử càng bị phồng điểm: -0,0165 NDCG@5, còn gần 0 khi không dùng lịch sử

Tuần 4

Thay đổi NDCG@5 sau khi làm sạch, dòng warm của tập test



-0,0165 · -0,0104

SMLP4Rec chỉ lịch sử và ItemKNN: mất nhiều nhất, vì chỉ có thể đoán lại các booking đã có

-0,0096 đến -0,0126

query token, mô hình chính, hybrid cũ: có cả lịch sử và ngữ cảnh, mất vừa

-0,0005 · +0,0007

prior theo destination và logistic regression: không dùng lịch sử, gần như không đổi

Hai mô hình không nhìn lịch sử không đổi: lỗi nằm ở dữ liệu trùng, không phải ở mô hình.

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

sameDest còn +0,0156 NDCG@5 sau khi bỏ các lần đặt lại trong 1 giờ

Gain NDCG@5 của sameDest so với query token (tập test)



28%

số dòng warm có destination đang tìm trong lịch sử; sameDest chỉ tác động ở đây

51,6%

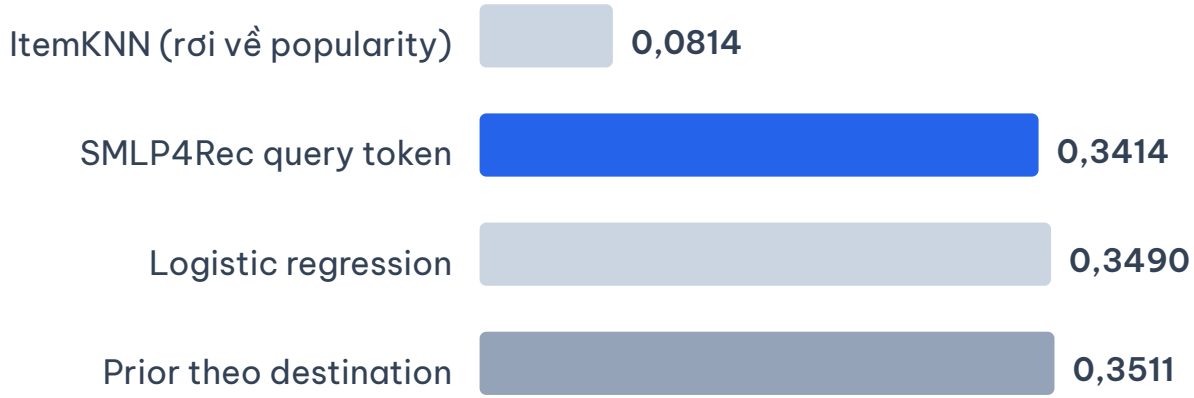
khi đó đáp án là một cluster đã đặt tại chính destination ấy

> **Tín hiệu thật nhưng hẹp, và khoảng 35–45% gain đến từ việc đặt lại trong phiên; số sau khi bỏ là cận dưới vì lọc theo đáp án. Giữ sameDest.**

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

User mới: query token thấp hơn logistic regression 0,0067 Recall@5

NDCG@5 trên dòng cold (lần đặt đầu của user, lịch sử rỗng)



-0,0067

Recall@5, query token trừ logistic regression, khoảng tin cậy [-0,0100; -0,0034]

2,2%

dòng cold có destination ngoài từ vựng: NDCG@5 chỉ 0,1564, trong khi prior đạt 0,3613

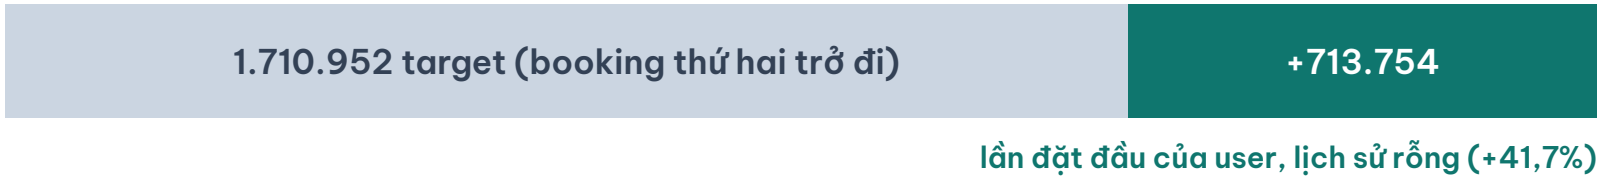
Nguyên nhân: mô hình chỉ học từ booking thứ hai trở đi nên chưa bao giờ thấy lịch sử rỗng, còn logistic regression được học cả lần đặt đầu. Không gắn prior vào mô hình chính vì khó giải thích; sửa ở dữ liệu huấn luyện.

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

Thêm 713.754 lần đặt đầu vào tập huấn luyện (+42%); mọi thứ khác giữ nguyên

Tuần 4

Dòng huấn luyện



lần đặt đầu của user, lịch sử rỗng (+41,7%)

- **Giữ nguyên:** mô hình, cấu hình, seed, 3 epoch, chia tập, cách chọn epoch và các dòng đánh giá.
- **Lịch sử rỗng:** toàn padding, query token vẫn đủ 14 trường; từ vựng query tính từ target train cộng các dòng này.
- **Không rò rỉ:** các dòng nằm hoàn toàn trước điểm cắt train và không trùng user với cold valid/test.

2,46% → 2,03%

target test có destination ngoài từ vựng, vì từ vựng thấy thêm các lần đặt đầu

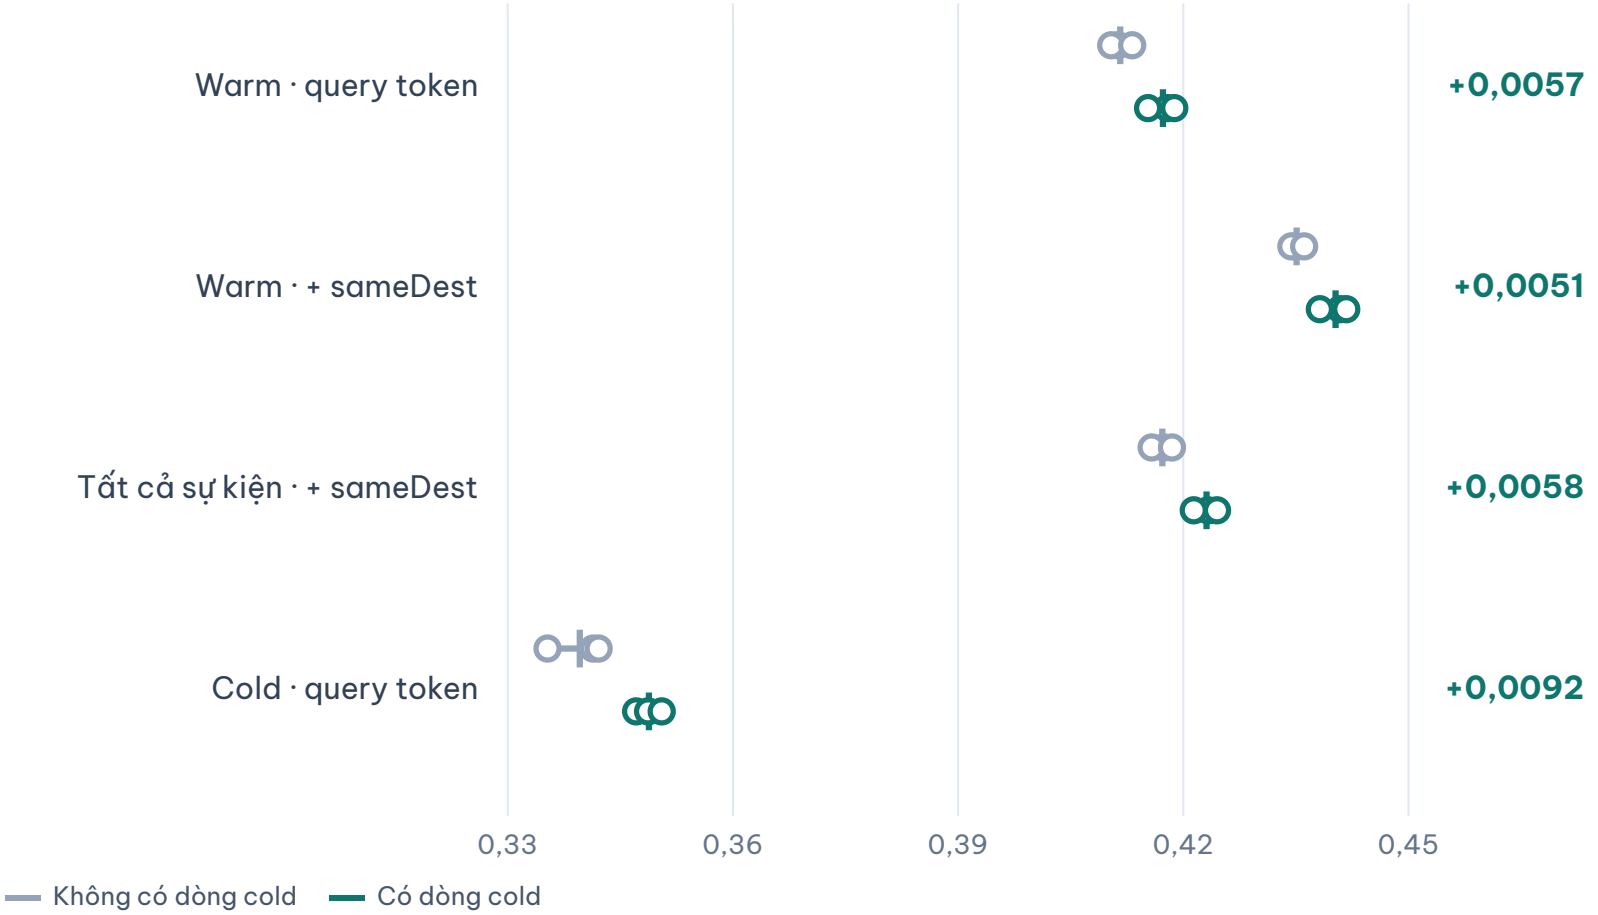
Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

5 · KẾT QUẢ CUỐI

Huấn luyện có lần đặt đầu cao hơn ở cả ba seed, trên mọi tập dòng

Tuần 4

NDCG@5, tập test. Chấm: từng seed; vạch: trung bình ± độ lệch chuẩn; bên phải: chênh trung bình



3/3

seed mà bản có dòng cold cao hơn, ở cả bốn chỉ số

0,0037 → 0,0017

độ lệch chuẩn giữa các seed ở dòng cold giảm khi có dòng cold trong huấn luyện

0,0235 / 0,0229

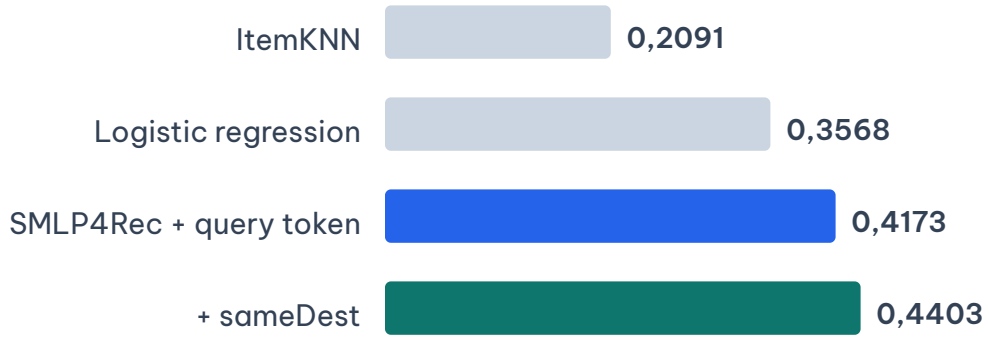
gain sameDest của hai bản gần như bằng nhau: không phụ thuộc cách huấn luyện

Chênh lệch +0,005 đến +0,009 lớn hơn nhiễu giữa các seed; với 3 seed, độ lệch chuẩn chỉ để tham khảo.

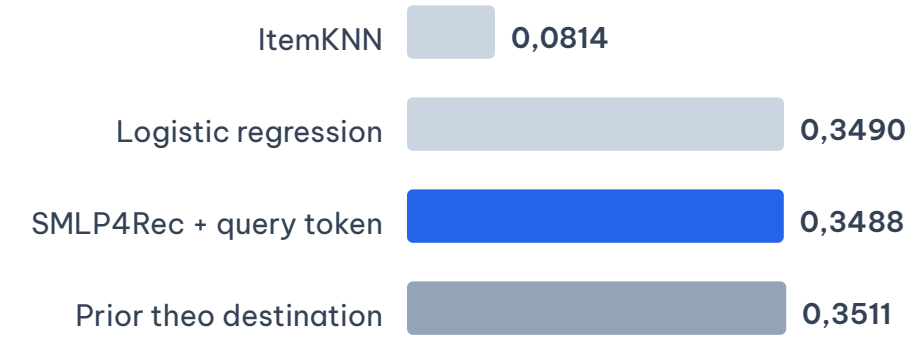
Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

Warm: hơn logistic regression +0,0605 NDCG@5; cold: ngang (-0,0002)

Dòng warm (user đã có lịch sử)



Dòng cold (lần đặt đầu)



NDCG@5, tập test; mô hình SMLP4Rec là trung bình 3 seed của bản có dòng cold. Query token trừ logistic regression: warm +0,0605 ± 0,0018, cold -0,0002 ± 0,0017.

> **Thêm sameDest, mô hình hơn logistic regression +0,0834 NDCG@5 ở dòng warm.**

Kết luận, giới hạn và bước tiếp

Đã chắc

- Dữ liệu trùng làm phồng điểm các mô hình dùng lịch sử; sau làm sạch, thứ hạng giữ nguyên.
- sameDest là tín hiệu thật dù hẹp (khoảng +0,016 NDCG@5 sau khi bỏ đặt lại trong 1 giờ).
- Huấn luyện có lần đặt đầu cải thiện ở 3/3 seed và đưa dòng cold về ngang logistic regression.
- Prior ngoài mạng không còn cần: khoảng cách NDCG@5 với hybrid cũ từ -0,0069 xuống -0,0009 (seed 2022).

Giới hạn và việc tiếp theo

- Chưa tuning: 3 epoch, chưa có lưới siêu tham số, cả sáu lần chạy đều chọn epoch 3.
- Cluster chỉ là proxy cho loại phòng; một tập dữ liệu; chỉ offline; chỉ hai baseline.
- Lặp cùng phiên (76.046 dòng) chưa quyết collapse hay không.
- Còn lại: lưới siêu tham số, lát cắt theo độ dài lịch sử và trip context, chỉ số đa dạng và thiên lệch phổ biến.

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild

Prior theo destination (dùng trong hybrid cũ và làm mốc đối chiếu)

Kết quả trên dòng cold: prior đạt Recall@5 0,5129; query token 0,5029; logistic regression 0,5096

$$p_{prior}(k \mid d) = \left(n(d, k) + m \cdot p_{mkt}(k \mid M(d)) \right) / \left(n(d) + m \right),\ m = 5$$

n(d, k): số booking cluster k tại destination d; $n(d) = \Sigma_k\, n(d, k)$; M(d): thị trường phổ biến nhất của d; p_{mkt}: phân phối cluster của thị trường đó

- **Chỉ dùng quá khứ:** các số đếm lấy từ những booking nằm trước booking cuối cùng của tập train; không dùng valid hay test.
- **Làm mượt theo thị trường:** chỉ có tác dụng với destination ít dữ liệu (n(d) nhỏ); với destination nhiều dữ liệu, p_{prior} gần bằng tần suất thực.
- **Destination chưa từng thấy:** dùng phân phối cluster toàn cục; khi lấy log có sàn 10^{-6}.
- **Ghép với mô hình (hybrid cũ):** điểm = $\log p_{model} + w \cdot \log p_{prior}$, w chọn trên valid. Mô hình chính không dùng số hạng này.

sameDest: điểm cộng cho cụm đã đặt tại đúng destination đang tìm

$$s(k) = \Sigma_{j:\ dest_j = q,\ cluster_j = k}\ 0{,}7^{tuổi_j}$$

$$p_s(k) = s(k) \ / \ \Sigma_{k'}\ s(k')$$

q: destination đang tìm; tuổi = 0 cho booking gần nhất; không có booking nào tại q thì p_s đều, hằng số, không đổi thứ hạng

$$điểm(k) = \log q_{model}(k) + w_s \cdot \log q_s(k)$$

$$\log q(k) = \log(\ (1 - \alpha) \cdot p(k) + \alpha \ / \ 100\ )$$

mọi thành phần cùng thang log bị chặn, nên w_s đọc như độ tin tưởng tương đối

Ví dụ: lịch sử có 4 booking, lượt tìm tại destination q

TUỔI	CLUSTER	DESTINATION	ĐÓNG GÓP
0	12	q	1,000
1	40	khác	0
3	12	q	0,343
4	7	q	0,240

$s(12) = 1{,}343$, $s(7) = 0{,}240 \rightarrow p_s(12) = 0{,}848$, $p_s(7) = 0{,}152$; cluster 40 không được cộng vì đặt ở destination khác.

Chọn tham số trên valid (quy tắc một sai số chuẩn, SE gom theo user): $\alpha \in \{0{,}05; 0{,}1; 0{,}2; 0{,}3; 0{,}5\}$, $w_s \in [0; 3]$. Hai ô: destination mới ($w_s = 0{,}00$) và đã biết ($w_s = 0{,}75$ ở seed 2022, $\alpha = 0{,}3$). Mô hình chính không có trọng số prior.

Query token: 14 trường của lượt tìm, mã hóa thành chỉ số embedding

Từ vựng của bản có dòng cold; tổng khoảng 1,05 triệu tham số, phần lớn ở bảng embedding của query

TRƯỜNG	CÁCH MÃ HÓA	GIÁ TRỊ TRONG TỪ VỰNG	XUẤT HIỆN TỐI THIỂU
Destination đang tìm	mã destination	15.509	≥ 5
Loại destination	mã loại	9	≥ 1
Tháng check-in	1–12; 0 nếu thiếu	12	≥ 1
Lead time	10 nhóm theo số ngày tới check-in; 0 nếu thiếu hoặc âm	11	≥ 1
Số đêm lưu trú	cắt tại 14; 0 nếu thiếu hoặc âm	14	≥ 1
Người lớn	cắt tại 9; 0 nếu bằng 0	10	≥ 1
Trẻ em	cắt tại 9	10	≥ 1
Số phòng	cắt tại 8; 0 nếu bằng 0	9	≥ 1
Gói	0 / 1	2	≥ 1
Thiết bị di động	0 / 1	2	≥ 1
Kênh	mã kênh	11	≥ 1
Site	mã site	41	≥ 1
Châu lục điểm bán	mã châu lục	5	≥ 1
Quốc gia của user	mã quốc gia	219	≥ 5

- **Cách đưa vào mô hình:** vector [MASK] học được cộng tổng 14 embedding, đặt ở vị trí cuối sau 20 vị trí lịch sử.
- **Lead time:** số ngày từ ngày tìm đến check-in, chia theo mốc 0 · 1–2 · 3–6 · 7–13 · 14–29 · 30–59 · 60–89 · 90–179 · 180–364 · 365+.
- **Giá trị lỗi** thành mã "không rõ" (0), không bỏ dòng.
- **Từ vựng chỉ lấy từ target train** (và lần đặt đầu của tập train); giá trị ngoài từ vựng dùng chung một embedding.
- **Không dùng:** mọi cột `hotel_*`, khoảng cách tới khách sạn, `cnt`, vùng và thành phố của user (thành phố cho thông tin âm trên valid vì là proxy của user).

Nguồn: Expedia Hotel Recommendations (Kaggle) · số liệu từ results/week4_rebuild