# Next-best-product Recommendation

Gợi ý cụm khách sạn tiếp theo cho đặt phòng nghỉ dưỡng

---

Sử dụng bộ dữ liệu Expedia công khai

# Đặc thù của bài toán gợi ý trong du lịch – khách sạn

**BÀI TOÁN NEXT-BEST-PRODUCT (NBP)**

Từ lịch sử giao dịch và ngữ cảnh tìm kiếm hiện tại, xếp hạng top K cụm khách sạn (hotel cluster) người dùng có xác suất đặt cao nhất ở lần tiếp theo.

### Tần suất mua rất thấp

Khách chỉ đặt phòng 1–2 lần mỗi năm; trung vị toàn bộ dữ liệu là 2 lượt đặt/người dùng. Tín hiệu tương tác giữa người dùng và item cực kỳ thưa.

### Ngữ cảnh chuyến đi quyết định

Cùng một người dùng nhưng nhu cầu thay đổi theo từng chuyến: đi một mình, cặp đôi hay gia đình; đi vào mùa nào, lưu trú bao nhiêu đêm.

### Hành vi mang tính khám phá

72% lượt đặt là cụm khách sạn mới chưa từng đặt trong lịch sử. Khách có xu hướng tìm kiếm trải nghiệm mới thay vì chỉ lặp lại item cũ.

### Cold-start người dùng phổ biến

39% người dùng chỉ xuất hiện đúng một lần (lịch sử rỗng). Mô hình không thể chỉ dựa vào lịch sử mà bắt buộc phải khai thác ngữ cảnh tìm kiếm.

Mô hình cần học được từ tương tác rất thưa, tận dụng hành vi chung của tập người dùng và thích ứng ngay với ngữ cảnh của lần tìm kiếm hiện tại.

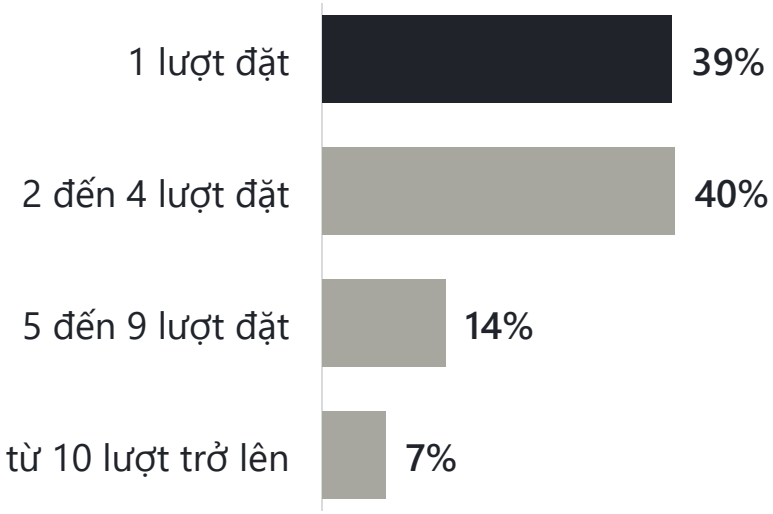
# Expedia: 2,952,675 lượt đặt phòng, 100 cluster để xếp hạng

| Đại lượng | Giá trị |
|---|---|
| Dòng thô trong file (click và đặt phòng) | 37,670,293 |
| Trong đó là click, không dùng làm nhãn | 92.0% |
| Lượt đặt phòng sau làm sạch | 2,952,675 |
| Người dùng | 813,985 |
| Đối tượng cần xếp hạng (hotel_cluster) | 100 |
| Điểm đến khác nhau | 36,933 |
| Thời gian | 2013-01-07 đến 2014-12-31 |
| Người dùng chỉ đặt một lần | 39.3% |
| Đoàn khách: solo, đôi, gia đình, nhóm | 29.0%, 44.1%, 18.7%, 8.1% |

Định nghĩa sau được tự suy ra từ số người lớn và trẻ em trong tìm kiếm: solo = 1 người lớn, đôi = 2 người lớn, nhóm = từ 3 người lớn, gia đình = có trẻ em (bất kể số người lớn)

Nguồn: results/week4_rebuild/bookings_counts.json, eda_clean.json (E2, E4); quy tắc nhóm khách: src/nbp/data/clean.py (party_type). Expedia, 2013 đến 2014, sau làm sạch.

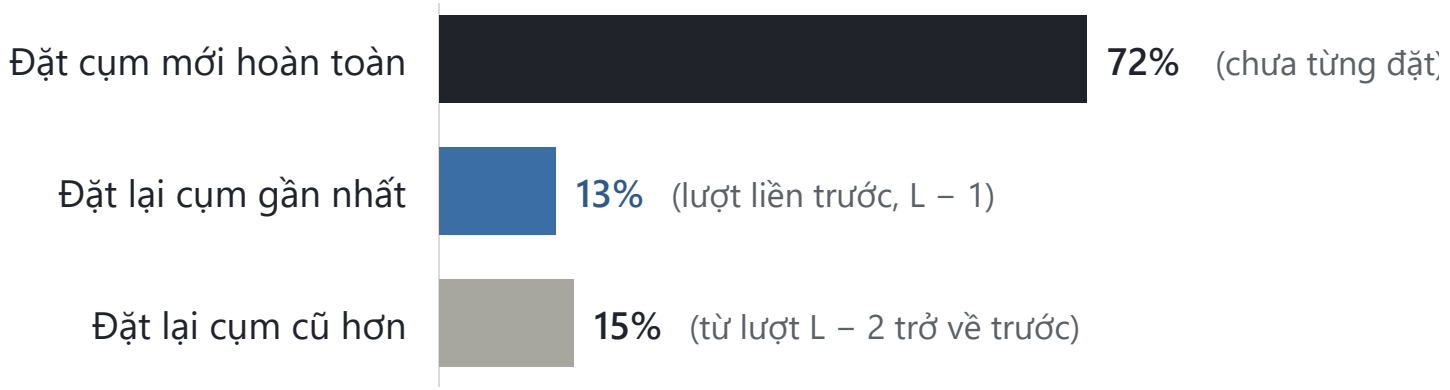
# Expedia có 2,952,675 lượt đặt phòng của 813,985 người dùng, nhưng 39% chỉ đặt một lần




Trung vị là 2 lượt đặt mỗi người dùng.

Nguồn: results/week4_rebuild/eda_clean.json (E2), bookings_counts.json. Lượt đặt Expedia, mọi người dùng.

# Khi có lịch sử, 72% lượt đặt là cụm mới; đặt lại cụm cũ chiếm 28% (13% là cụm gần nhất)




Tổng tỷ lệ đặt lại cụm cũ là 28%. Đa số khách (72%) chuyển sang cụm phòng hoặc gói mới trong chuyến đi tiếp theo.

Nguồn: data/interim/expedia_bookings.parquet. Tính trên 2,138,690 lượt đặt của khách đã có lịch sử trước đó (L ≥ 1).

# Các hướng tiếp cận phổ biến của bài toán hệ gợi ý

| Hướng tiếp cận | Ý tưởng chính |
|---|---|
| Content-based | Dựa trên thuộc tính của item |
| Collaborative filtering, matrix factorization | Dựa trên ma trận người dùng × item |
| Graph-based | Dựa trên đồ thị người dùng – item |
| Session-based | Dựa trên chuỗi hành vi trong một phiên |
| **Sequential (SMLP4Rec)** | **Dựa trên thứ tự các lượt đặt trong toàn bộ lịch sử** |
| Context-aware | Dựa trên ngữ cảnh của lần tìm kiếm |

# Mô hình hóa bài toán




Đầu ra là top k xếp hạng trong 100 hotel_cluster, đại diện (proxy) cho hạng phòng hoặc gói.

# Mọi mô hình train và chấm trên toàn bộ lượt đặt, chia theo thời gian

| train | valid | test |
| --- | --- | --- |
| 2013-01-07 – 2014-10-08 | 2014-10-08 – 2014-11-19 | 2014-11-19 – 2014-12-31 |
| 2,424,706 lượt đặt<br>Warm: 1,710,952 - 71%<br>Lần đầu: 713,754 - 29% | 264,638 lượt đặt<br>Warm: 213,869 - 81%<br>Lần đầu: 50,769 - 19% | 263,331 lượt đặt<br>Warm: 213,869 - 81%<br>Lần đầu: 49,462 - 19% |

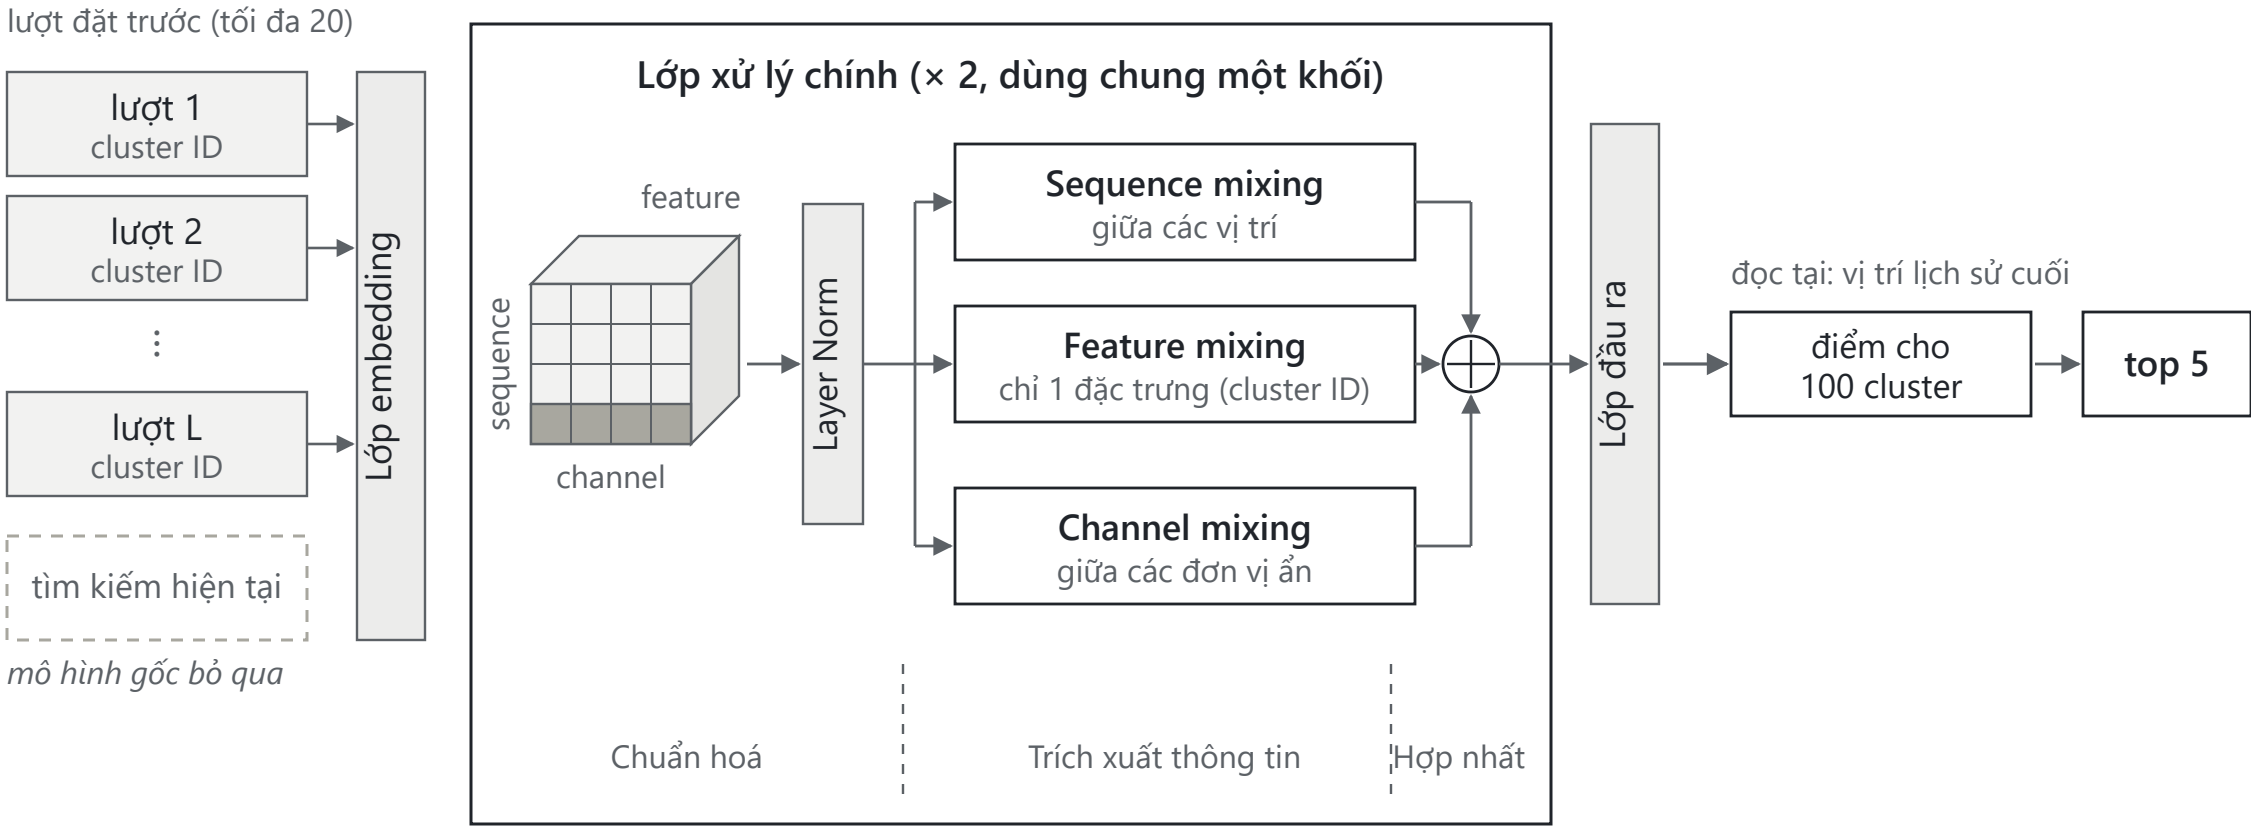
Train, valid và test đều gồm mọi lượt đặt; warm / đầu tiên chỉ là hai phần để báo cáo riêng

warm = đã có ít nhất một lượt đặt trước (L ≥ 1); đầu tiên (cold) = lịch sử rỗng (L = 0). Riêng SMLP4Rec gốc có thêm bản chỉ train trên warm

Xếp hạng đầy đủ trên cả 100 cluster. Recall và NDCG tại 5, 10 và 20. Cấu hình chọn trên valid, test chỉ đọc một lần.

Nguồn: results/week4_rebuild/eda_clean.json (splits), split_export_counts.json.

# SMLP4Rec gốc chỉ đọc các lượt đặt trước đó và bỏ qua tìm kiếm hiện tại



# Chỉ dùng lịch sử, SMLP4Rec gốc hơn ItemKNN một chút và thua xa logistic regression

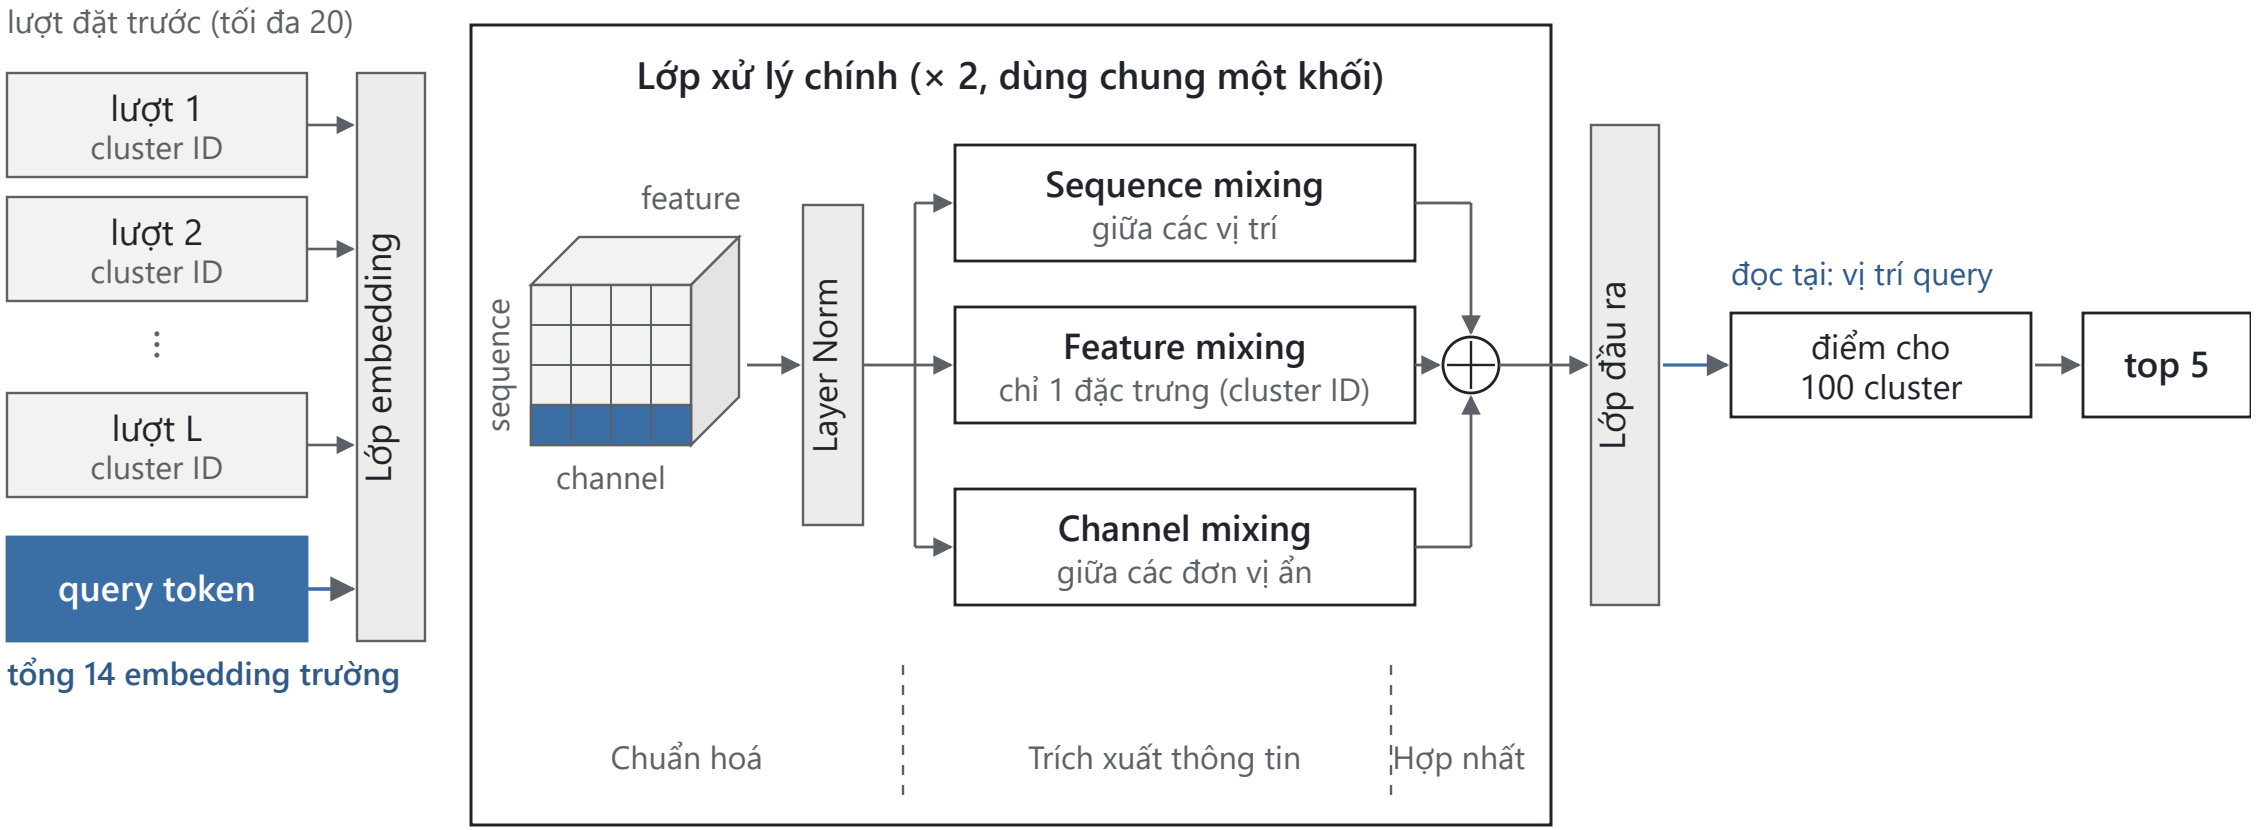
| Mô hình | Recall@5 | Recall@10 | Recall@20 | NDCG@5 | NDCG@10 | NDCG@20 |
|---|---|---|---|---|---|---|
| ItemKNN (chỉ dùng lịch sử) | 0.3036 | 0.4383 | 0.6097 | 0.2089 | 0.2522 | 0.2954 |
| **SMLP4Rec gốc (train chỉ trên dòng có lịch sử)** | **0.3212** | **0.4530** | **0.6230** | **0.2274** | **0.2698** | **0.3127** |
| Logistic regression (điểm đến + ngữ cảnh tìm kiếm) | 0.4969 | 0.6897 | 0.8578 | 0.3354 | 0.3978 | 0.4406 |

Giới hạn: SMLP4Rec gốc chỉ được train trên các lượt đặt mà khách đã có lịch sử trước đó (L ≥ 1) nên chỉ chấm được trên dòng warm; ItemKNN và logistic regression train trên mọi lượt đặt. Bảng chỉ so trên dòng warm của tập test, n = 213,869.

Cách tính Recall@K, NDCG@K

Nguồn: results/week5_final/final_benchmark.csv (plain_warm, itemknn, logreg; dòng warm). Expedia, tập test, seed 2022.

# Kết hợp hướng context-aware: query token đưa 14 trường tìm kiếm vào SMLP4Rec




[Phụ lục A1: Chi tiết về query token]

Nguồn: src/nbp/models/smlprec_query.py; results/week4_rebuild/smlprec_query_cold_train_es_run.json.

# Thêm query token, SMLP4Rec vượt cả hai baseline trên toàn bộ lượt đặt

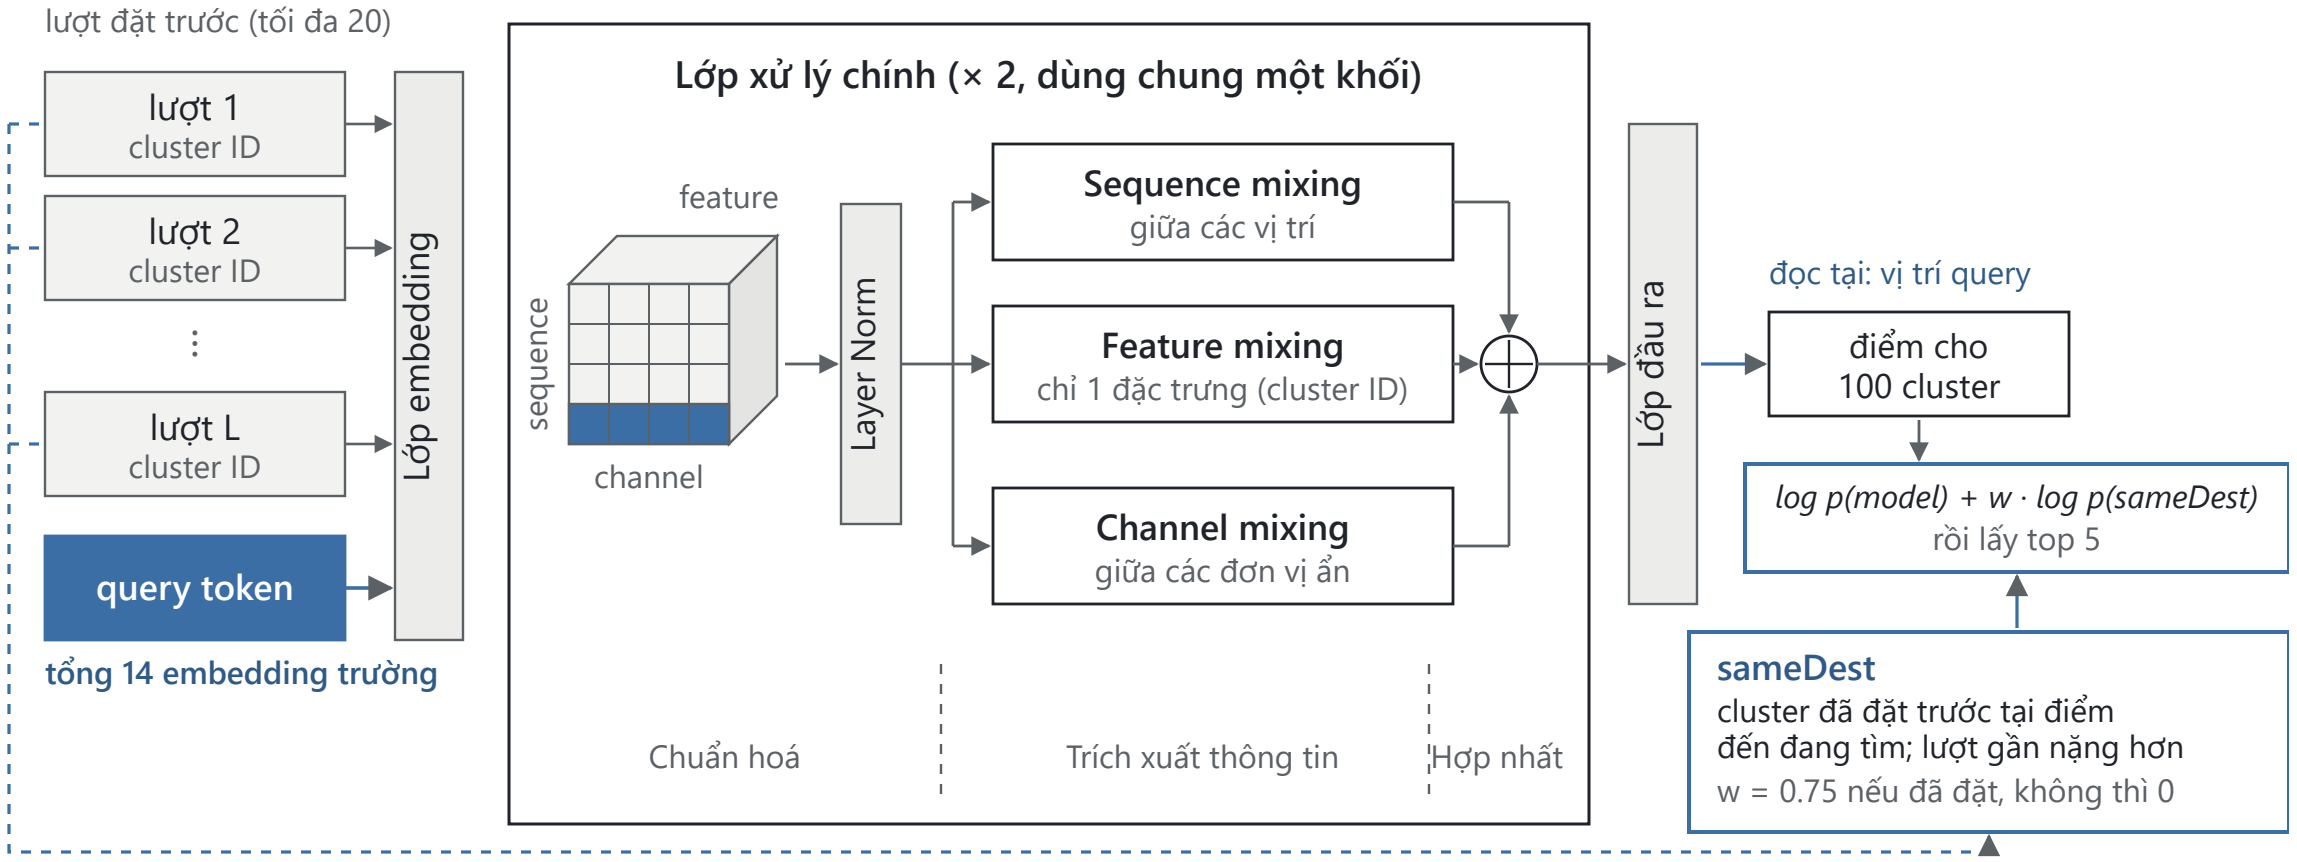
| Mô hình | Recall@5 | Recall@10 | Recall@20 | NDCG@5 | NDCG@10 | NDCG@20 |
|---|---|---|---|---|---|---|
| ItemKNN (chỉ dùng lịch sử) | 0.2713 | 0.3989 | 0.5626 | 0.1850 | 0.2260 | 0.2671 |
| SMLP4Rec gốc (train chỉ trên dòng có lịch sử) | 0.2856 | 0.4105 | 0.5734 | 0.2000 | 0.2401 | 0.2811 |
| Logistic regression (điểm đến + ngữ cảnh tìm kiếm) | 0.4948 | 0.6869 | 0.8560 | 0.3339 | 0.3961 | 0.4391 |
| **SMLP4Rec + query token (train mọi lượt đặt)** | **0.5831** | **0.7613** | **0.9050** | **0.4122** | **0.4700** | **0.5066** |

Bảng tính trên toàn bộ lượt đặt của tập test (warm và đầu tiên), n = 263,331. Với SMLP4Rec gốc, các lượt đặt đầu tiên không được mô hình chấm mà xếp theo độ phổ biến.

Cách tính Recall@K, NDCG@K

Nguồn: results/week5_final/final_benchmark.csv (plain_warm, itemknn, logreg, query_token; dòng all). Expedia, tập test, seed 2022.

# sameDest bổ sung những gì khách đã đặt trước đây tại điểm đến đang tìm




[Phụ lục A3: Chi tiết về sameDest]

Nguồn: src/nbp/hybrid/; results/week4_rebuild/smlprec_query_cold_train_es_run.json (samedest_hybrid).

# Thêm sameDest, mô hình chính dẫn đầu mọi mô hình trên toàn bộ lượt đặt

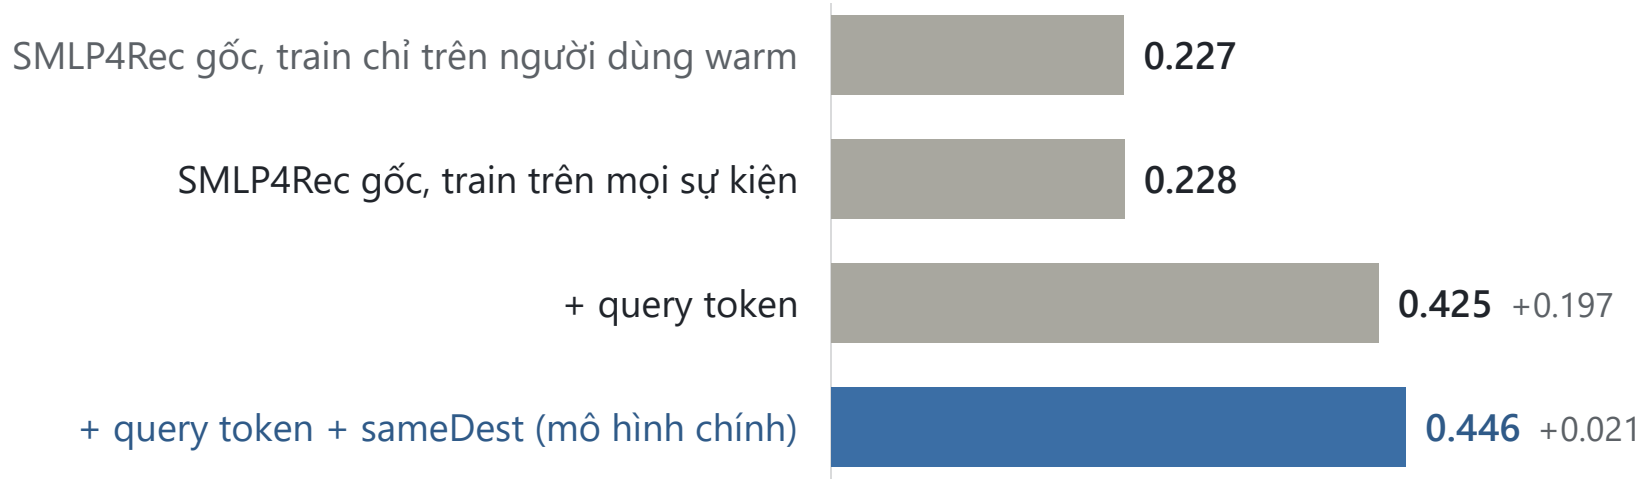
| Mô hình | Recall@5 | Recall@10 | Recall@20 | NDCG@5 | NDCG@10 | NDCG@20 |
|---|---|---|---|---|---|---|
| ItemKNN (chỉ dùng lịch sử) | 0.2713 | 0.3989 | 0.5626 | 0.1850 | 0.2260 | 0.2671 |
| SMLP4Rec gốc (train chỉ trên dòng có lịch sử) | 0.2856 | 0.4105 | 0.5734 | 0.2000 | 0.2401 | 0.2811 |
| Logistic regression (điểm đến + ngữ cảnh tìm kiếm) | 0.4948 | 0.6869 | 0.8560 | 0.3339 | 0.3961 | 0.4391 |
| SMLP4Rec + query token | 0.5831 | 0.7613 | 0.9050 | 0.4122 | 0.4700 | 0.5066 |
| **Mô hình chính (query token + sameDest)** | **0.5944** | **0.7664** | **0.9066** | **0.4295** | **0.4853** | **0.5210** |

Bảng tính trên toàn bộ lượt đặt của tập test (warm và đầu tiên), n = 263,331. Với SMLP4Rec gốc, các lượt đặt đầu tiên không được mô hình chấm mà xếp theo độ phổ biến.

Cách tính Recall@K, NDCG@K

Nguồn: results/week5_final/final_benchmark.csv (plain_warm, itemknn, logreg, query_token, main; dòng all). Expedia, tập test, seed 2022.

# query token mang phần lớn mức tăng, sameDest thêm một bước nhỏ hơn nhưng có thật




NDCG@5 trên dòng test warm. Các bước: query token +0.197 (KTC 95% +0.196 đến +0.199), sameDest +0.021 (KTC 95% +0.021 đến +0.022).

Cách tính Recall@K, NDCG@K

Nguồn: results/week5_final/final_benchmark.csv, bootstrap_ci.csv. Expedia test, dòng warm, n = 213,869, seed 2022.

# Mô hình chính dẫn trước cả hai baseline trên dòng test tất cả, cold và warm

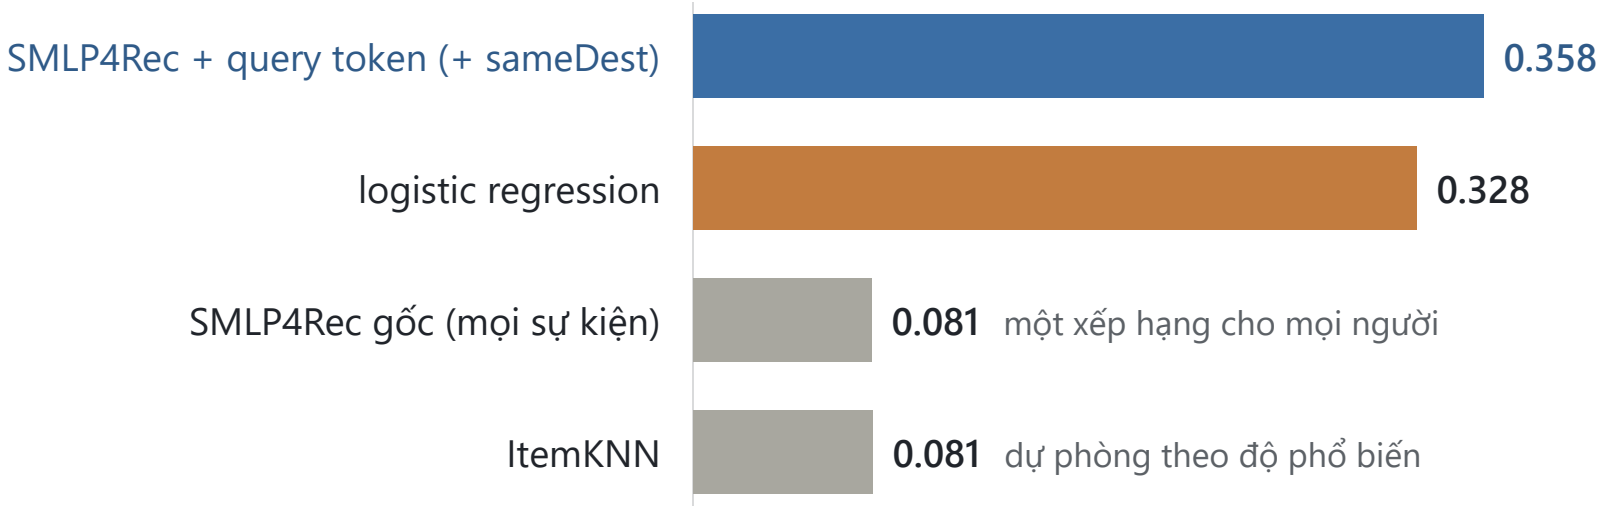
| | R@5 tất cả | R@5 cold | R@5 warm | NDCG@5 tất cả | NDCG@5 cold | NDCG@5 warm |
|---|---|---|---|---|---|---|
| ItemKNN | 0.271[a] | 0.132[a] | 0.304 | 0.185[a] | 0.081[a] | 0.209 |
| SMLP4Rec gốc, train chỉ trên người dùng warm | 0.286[a] | 0.132[a] | 0.321 | 0.200[a] | 0.081[a] | 0.227 |
| SMLP4Rec gốc, train trên mọi sự kiện | 0.286 | 0.131 | 0.321 | 0.200 | 0.081 | 0.228 |
| logistic regression | 0.495 | 0.486 | 0.497 | 0.334 | 0.328 | 0.335 |
| + query token | 0.583 | 0.525 | 0.597 | 0.412 | 0.358 | 0.425 |
| **+ query token + sameDest (chính)** | **0.594** | **0.525** | **0.610** | **0.429** | **0.358** | **0.446** |

[a] Dự phòng theo độ phổ biến trên dòng lượt đặt đầu tiên, không phải điểm của mô hình. Chính trừ logistic regression, NDCG@5: warm +0.111 (KTC 95% +0.109 đến +0.112), cold +0.030 (KTC 95% +0.028 đến +0.033).

Cách tính Recall@K, NDCG@K

Nguồn: results/week5_final/final_benchmark.csv, bootstrap_ci.csv. Expedia test: tất cả n = 263,331, cold n = 49,462, warm n = 213,869. Seed 2022.

# Trên lượt đặt đầu tiên, chỉ các mô hình có xét tìm kiếm mới xếp hạng tốt

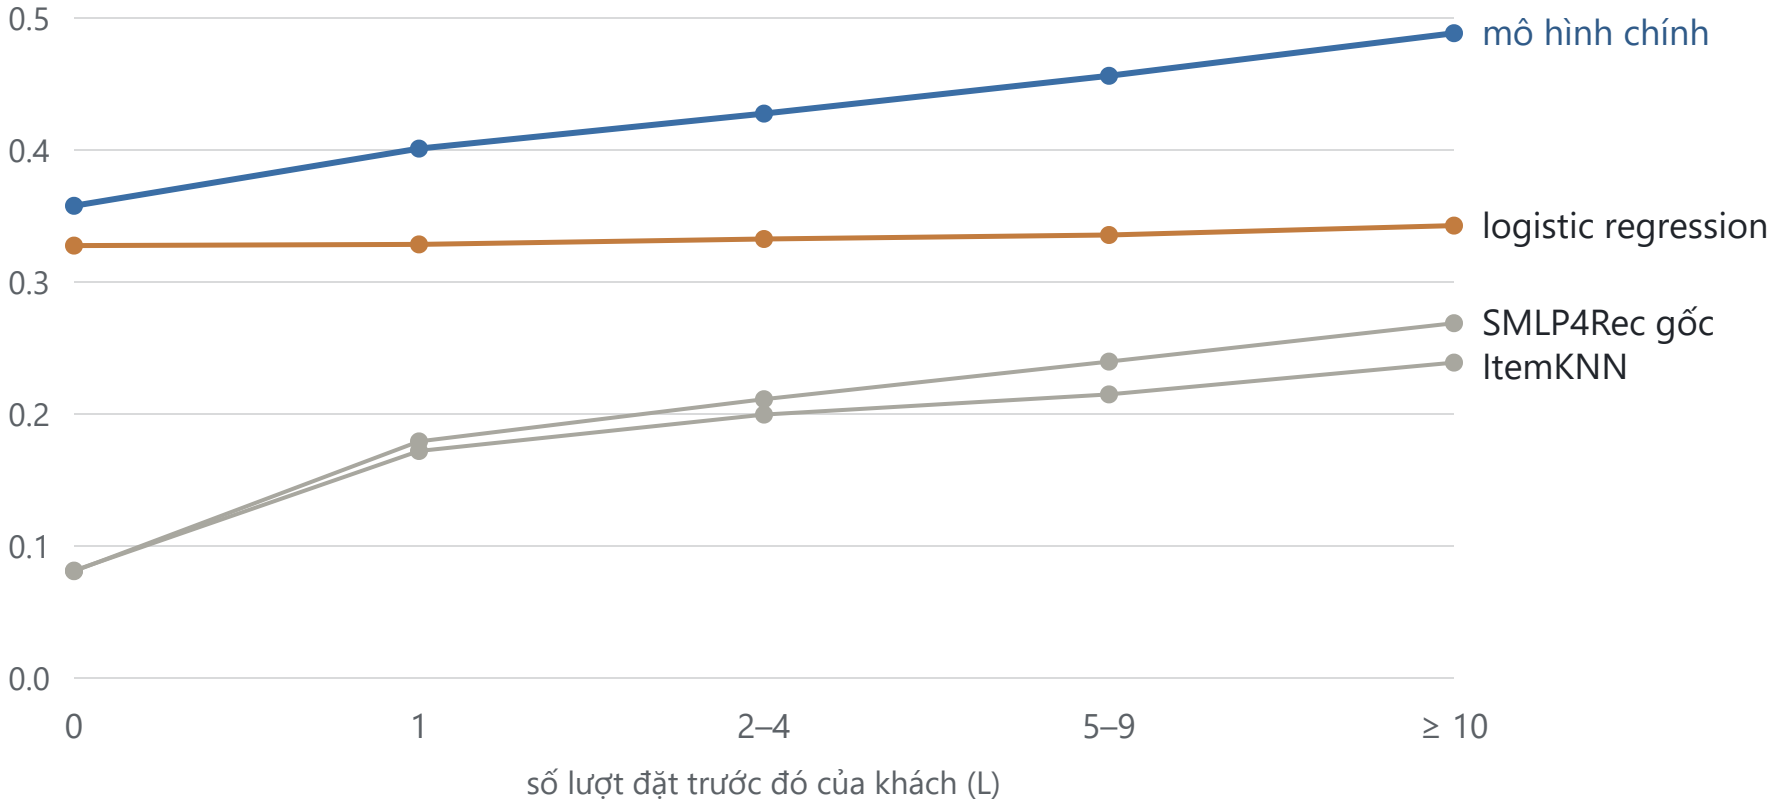



Mô hình chính dẫn trước logistic regression +0.030 (KTC 95% +0.028 đến +0.033) NDCG@5.

Cách tính Recall@K, NDCG@K

Nguồn: results/week5_final/final_benchmark.csv, bootstrap_ci.csv. Expedia test, dòng lượt đặt đầu tiên, n = 49,462.

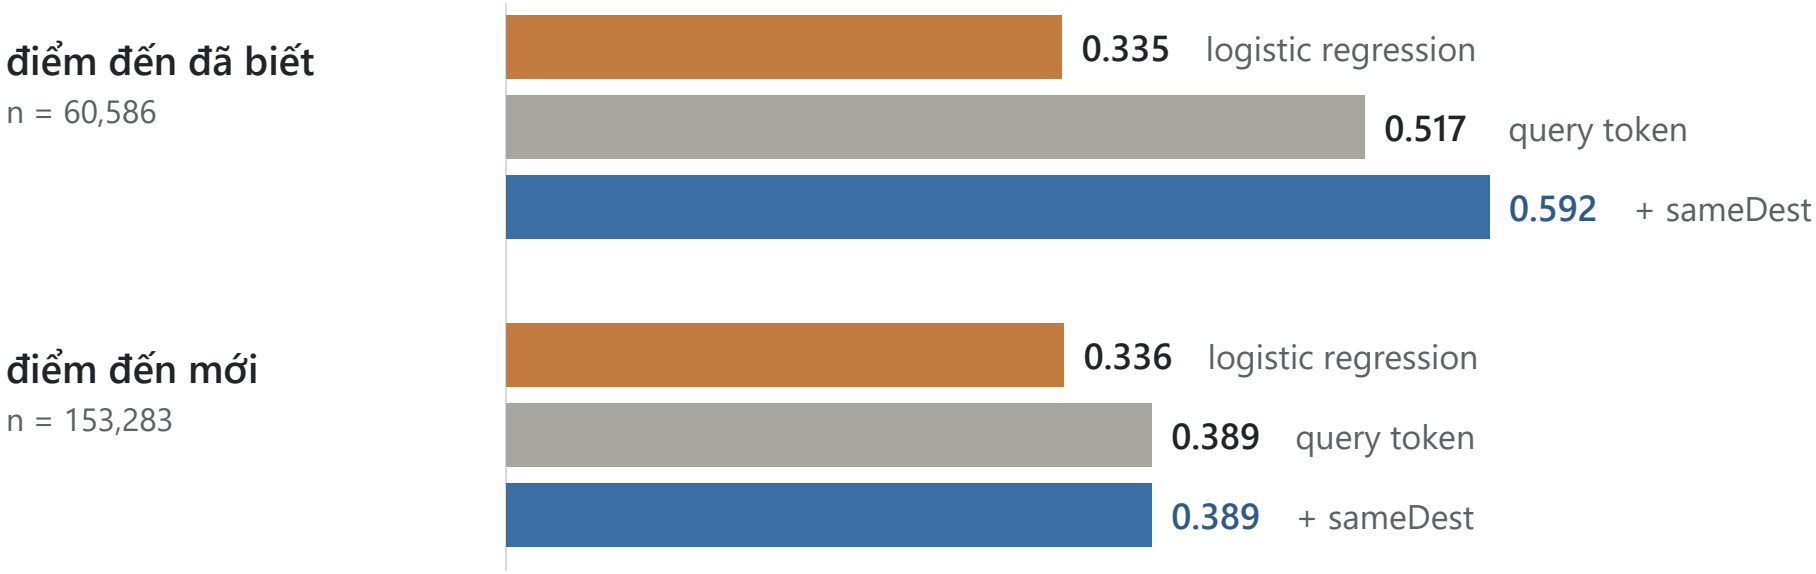
# Khoảng dẫn trước logistic regression tăng theo lịch sử, từ +0.030 đến +0.146 NDCG@5




Cách tính Recall@K, NDCG@K

Nguồn: results/week5_final/slices_history_length.csv. Expedia test, mọi dòng, n = 263,331.

# Lịch sử có giá trị ở nơi khách quay lại: sameDest nâng NDCG@5 tại điểm đến đã biết từ 0.517 lên 0.592




Loại các lượt đặt lại trong vòng một ngày, mức tăng của sameDest trên dòng warm vẫn là +0.012 NDCG@5.

Cách tính Recall@K, NDCG@K

Nguồn: results/week5_final/slices_destination_known.csv, bootstrap_ci.csv. Expedia test, dòng warm chia theo điểm đến.

# Tìm kiếm hiện tại là tín hiệu chính, lịch sử là phần bổ sung nhỏ hơn nhưng có thật

- SMLP4Rec có xét tìm kiếm dẫn trước logistic regression +0.111 và ItemKNN +0.237 NDCG@5 trên dòng warm.
- Lượt đặt đầu tiên được chấm tốt, không cần lịch sử.
- sameDest giúp khách quay lại tại điểm đến đã biết.

Nguồn: results/week5_final/final_benchmark.csv, bootstrap_ci.csv. Expedia test, dòng warm.

# Phụ lục A4. Cấu hình chi tiết của các mô hình

| | |
|---|---|
| **Dữ liệu và đánh giá** | chia theo thời gian 80/10/10 trên mục tiêu next-booking; lịch sử tối đa 20 lượt; xếp hạng đầy đủ 100 cluster; Recall và NDCG tại 5, 10, 20; chọn mô hình theo NDCG@10 trên valid; seed 2022 |
| **SMLP4Rec** | 2 lớp dùng chung một khối, hidden 64, expansion 3, dropout 0, GELU, loss cross-entropy; 33,702 tham số (bản gốc), 1,050,204 (có query token) |
| **Query token** | 14 trường tìm kiếm; điểm đến và quốc gia người dùng cần ít nhất 5 lượt đặt ở train mới có embedding riêng, các trường khác ít nhất 1; 1,016,256 tham số của các embedding trường |
| **Huấn luyện** | Adam, learning rate 0.001, weight decay 0 (mặc định RecBole), batch 1024, tối đa 10 epoch trên CPU; early stopping theo NDCG@10 trên valid, patience 2, min_delta 0.0007; lần chạy chính chọn epoch 8, mất 3.1 giờ; bản SMLP4Rec gốc train chỉ trên dòng có lịch sử chạy cố định 3 epoch |
| **sameDest** | cơ số 0.7, $\alpha = 0.2$, $w = 0.75$ nếu điểm đến đã có trong lịch sử, 0 nếu không; lưới $\alpha \in \{0.05, 0.1, 0.2, 0.3, 0.5\}$, $w \in \{0, 0.25, 0.5, 0.75, 1, 1.25, 1.5, 2, 2.5, 3\}$, chọn trên valid theo một sai số chuẩn |
| **ItemKNN** | cosine (thư viện implicit), $K = 50$ chọn từ {5, 10, 20, 50, 100} trên valid; đầu vào là 20 lượt đặt gần nhất; lượt đặt đầu tiên xếp theo độ phổ biến của các lượt đặt đầu tiên |
| **Logistic regression** | sklearn, saga, multinomial, $C = 1$ chọn từ {0.1, 1, 10}, dừng ở lượt lặp 8 theo valid; 14 trường tìm kiếm, không dùng lịch sử |

Nguồn: configs/smlprec_expedia.yaml; results/week4_rebuild/ (smlprec_query_cold_train_es_run.json, smlprec_plain_cold_train_es_run.json, baselines_es_run.json).

# Phụ lục A1. 14 trường của query token, đều thuộc lần tìm kiếm

| Trường | Ý nghĩa | Cách mã hóa | Số giá trị |
|---|---|---|---|
| `dest` | Điểm đến đang tìm (srch_destination_id) | id gốc; điểm đến có dưới 5 lượt đặt ở train thành "ngoài từ vựng" | 15,509 |
| `dest_type` | Loại điểm đến | id gốc | 9 |
| `ci_month` | Tháng check-in | 1 đến 12; 0 = không rõ | 12 |
| `lead` | Số ngày từ lúc tìm đến check-in | 10 khoảng, từ 0 ngày đến từ 365 ngày; 0 = không rõ | 11 |
| `stay` | Số đêm lưu trú | 0 đến 14 đêm, dài hơn gộp chung; 0 = không rõ | 14 |
| `adults` | Số người lớn | cắt ở 9; 0 = không rõ | 10 |
| `children` | Số trẻ em | cắt ở 9 | 10 |
| `rooms` | Số phòng | cắt ở 8; 0 = không rõ | 9 |
| `package` | Đặt kèm gói (is_package) | 0 hoặc 1 | 2 |
| `mobile` | Tìm trên thiết bị di động | 0 hoặc 1 | 2 |
| `channel` | Kênh tiếp thị | id gốc | 11 |
| `site` | Website Expedia (site_name) | id gốc | 41 |
| `posa` | Châu lục điểm bán | id gốc | 5 |
| `country` | Quốc gia của người dùng | id gốc; dưới 5 lượt đặt ở train thành "ngoài từ vựng" | 219 |

← Quay lại slide 11

Nguồn: src/nbp/data/query_features.py; smlprec_query_cold_train_es_run.json (query_coverage). Số giá trị = kích thước từ vựng, tính trên train.

# Phụ lục A2. Recall@K và NDCG@K tính từ thứ hạng của cluster đúng

Mỗi lượt đặt có đúng một cluster đúng. Mô hình chấm điểm cả 100 cluster, không lấy mẫu negative, rồi xếp hạng; gọi `r` là thứ hạng của cluster đúng (1 là tốt nhất). Đồng điểm thì cluster có chỉ số cột nhỏ hơn xếp trước.

`Recall@K = 1[r ≤ K]`

`NDCG@K = 1[r ≤ K] / log2(r + 1)` (DCG lý tưởng bằng 1 vì chỉ có một cluster đúng)

Kết quả là trung bình trên các dòng đang xét, với K = 5, 10, 20. Ví dụ bốn lượt đặt có `r` = 1, 3, 6, 11 và K = 5:

| r | Recall@5 | NDCG@5 |
|---:|---:|---:|
| 1 | 1 | 1.000 |
| 3 | 1 | 0.500 |
| 6 | 0 | 0.000 |
| 11 | 0 | 0.000 |
| **trung bình** | **0.500** | **0.375** |

← Quay lại

Nguồn: src/nbp/eval/metrics.py (target_rank, recall_at_k, ndcg_at_k, summarize); ví dụ khớp tests/test_metrics.py.

# Phụ lục A3. Công thức sameDest và điểm cuối cùng

Động lực: trên dòng warm của test, 29.0% tìm kiếm diễn ra tại điểm đến khách từng đặt; trong số đó 51.6% lại đặt đúng một cluster đã đặt tại điểm đó (14.96% toàn bộ dòng warm).

`sameDest(k) = Σ 0.7^tuổi` trên các lượt đặt trước tại điểm đến đang tìm có cluster k, rồi chuẩn hóa: `q_sameDest(k) = sameDest(k) / Σj sameDest(j)`

`điểm(k) = log q_mô hình(k) + w · log q_sameDest(k)`, với `log q = log((1 − α)·p + α/100)`, α = 0.2; w = 0.75 nếu điểm đến đã có trong lịch sử, w = 0 nếu không.

Ví dụ: lịch sử bốn lượt đặt, tìm kiếm tại điểm đến A.

| Điểm đến | Cluster | Tuổi | Tính vào sameDest? | 0.7^tuổi |
|---|---|---|---|---|
| A | 7 | 3 | có | 0.343 |
| B | 9 | 2 | không (khác điểm đến) | 0 |
| A | 12 | 1 | có | 0.700 |
| A | 7 | 0 | có | 1.000 |

Tìm kiếm tại điểm đến A: cluster 7 có 0.343 + 1.000 = 1.343, cluster 12 có 0.700; sau chuẩn hóa `q_sameDest`(7) = 0.657, `q_sameDest`(12) = 0.343.

Cơ số 0.7 là giá trị đặt cố định, không tune: $0.7^2 \approx 0.5$ nên cứ hai lượt đặt cũ hơn thì trọng số còn khoảng một nửa. Tuổi 0 là lượt gần nhất.

← Quay lại

Nguồn: src/nbp/hybrid/same_dest.py, fusion.py; eda_clean.json (E5); smlprec_query_cold_train_es_run.json (samedest_hybrid). Ví dụ tính bằng same_dest_scores.