Phân tích và Khám phá tập dữ liệu Expedia

Vũ Quốc Anh · Mentor: **Trần Quốc Thái**
Phạm Anh Minh · Mentor: **Lê Huỳnh Đức**

01 Dữ liệu
02 Phương pháp
03 Thực nghiệm và cải tiến
04 Kết luận

Dữ liệu Expedia và bài toán dự đoán

37.670.293 dòng

07/01/2013 → 31/12/2014

Click · 34.669.600 · 92,0%

Booking · 3.000.693 · 8,0%

Chỉ dùng booking làm tương tác

- **Lựa chọn thật:** user đã đặt phòng
- **Click quá nhiều:** 92% dòng, ~12 click mỗi booking

USER
1.198.786
813.985 có đặt phòng

CẦN XẾP HẠNG
100 cluster
hotel_cluster, id ẩn danh

7 nhóm cột

lần tìm kiếm · chứa nhãn

- **Tương tác, thời gian**
  cnt · date_time · is_booking
- **User**
  user_id
- **Ngữ cảnh chuyến đi**
  is_package · srch_adults_cnt · srch_children_cnt · srch_ci · srch_co · srch_rm_cnt
- **Tìm kiếm, điểm đến**
  srch_destination_id · srch_destination_type_id
- **Khách sạn, mục tiêu**
  hotel_cluster · hotel_continent · hotel_country · hotel_market
- **Vị trí user**
  orig_destination_distance · user_location_city · user_location_country · user_location_region
- **Kênh, nền tảng**
  channel · is_mobile · posa_continent · site_name

Làm sạch tập booking

48.018 booking · 1,6%

đặt lặp y hệt booking trước

≈ 6.100 lỗi · 0,2%

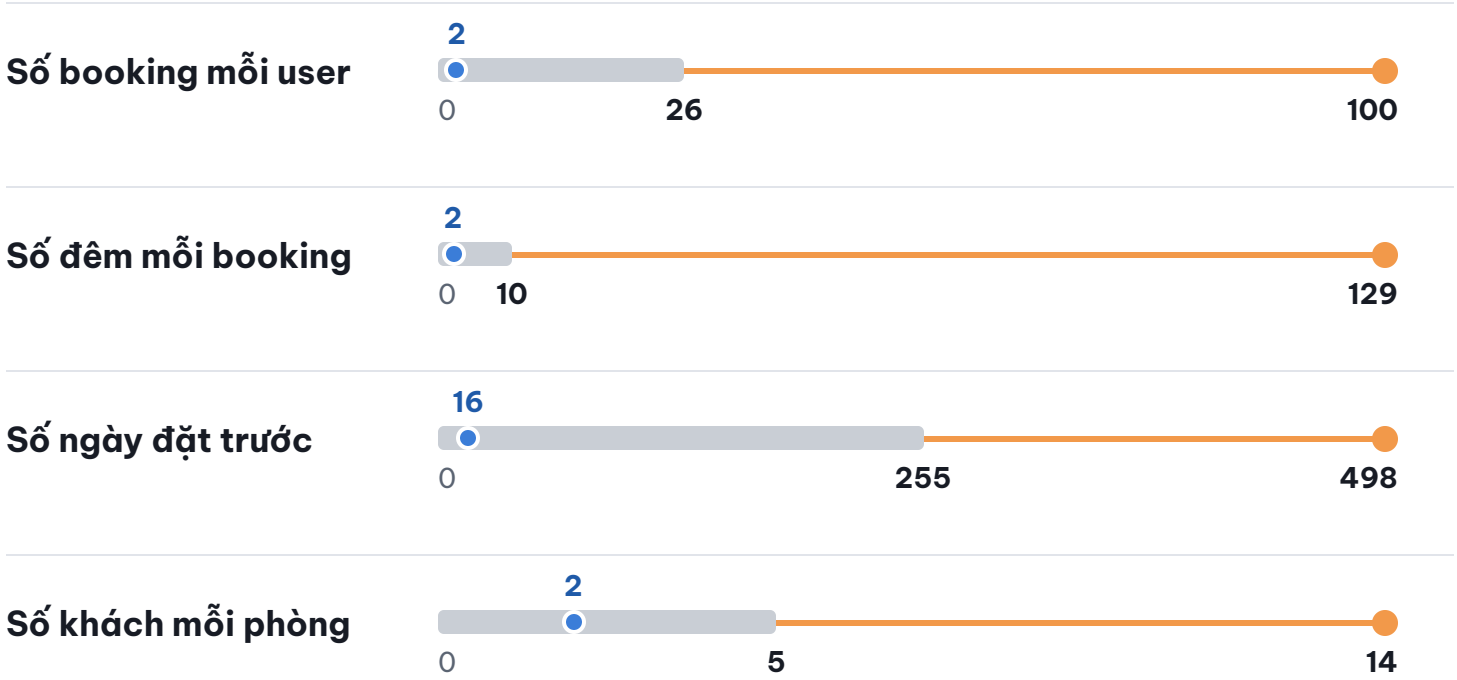
ngày, số người, số phòng vô lý: giữ dòng, để trống ô sai

khoảng cách

thiếu 33,8% booking

Outlier: giữ lại, đánh dấu hoặc gom nhóm

99% thấp nhất · 1% cao nhất · trung vị



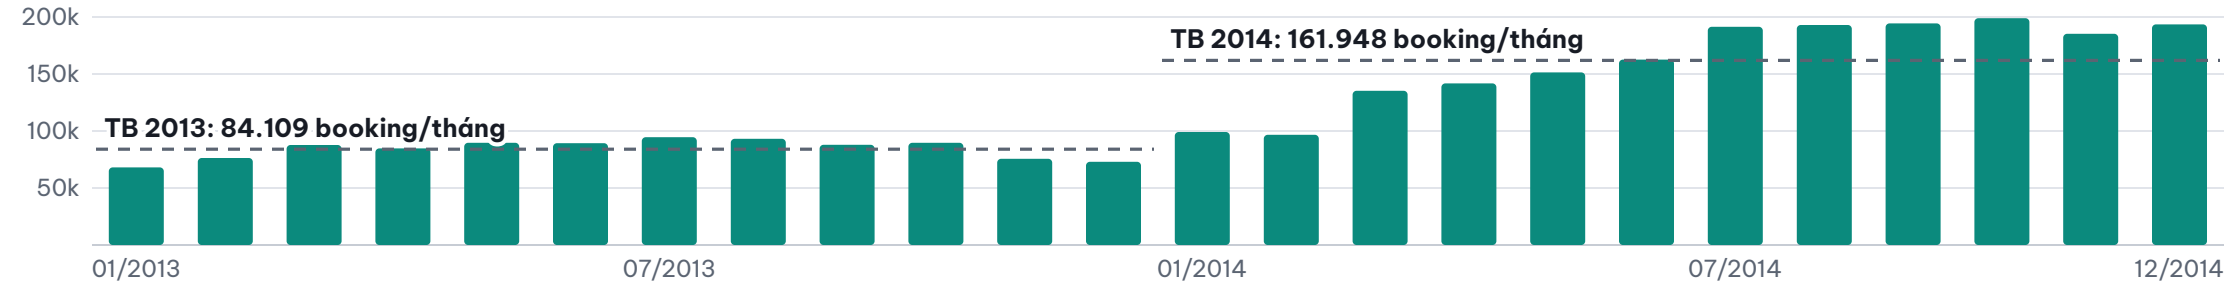
1,7% user đặt hơn 20 lần, chiếm 15,8% booking

Outlier **không phải là lỗi dữ liệu** mà là hành vi của user.

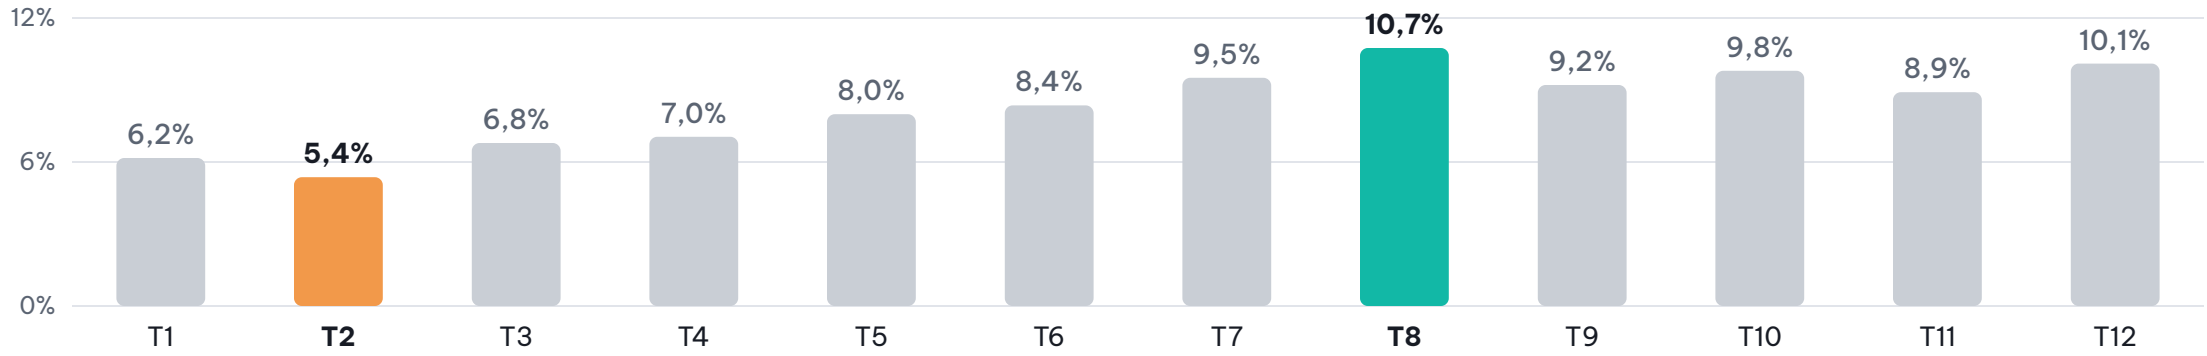
Sau khi làm sạch, dữ liệu **đủ tin cậy** để trả lời: user là ai, họ đặt gì.

Booking theo thời gian và mùa vụ

Số booking mỗi tháng train.csv



Tỷ lệ booking theo tháng check-in

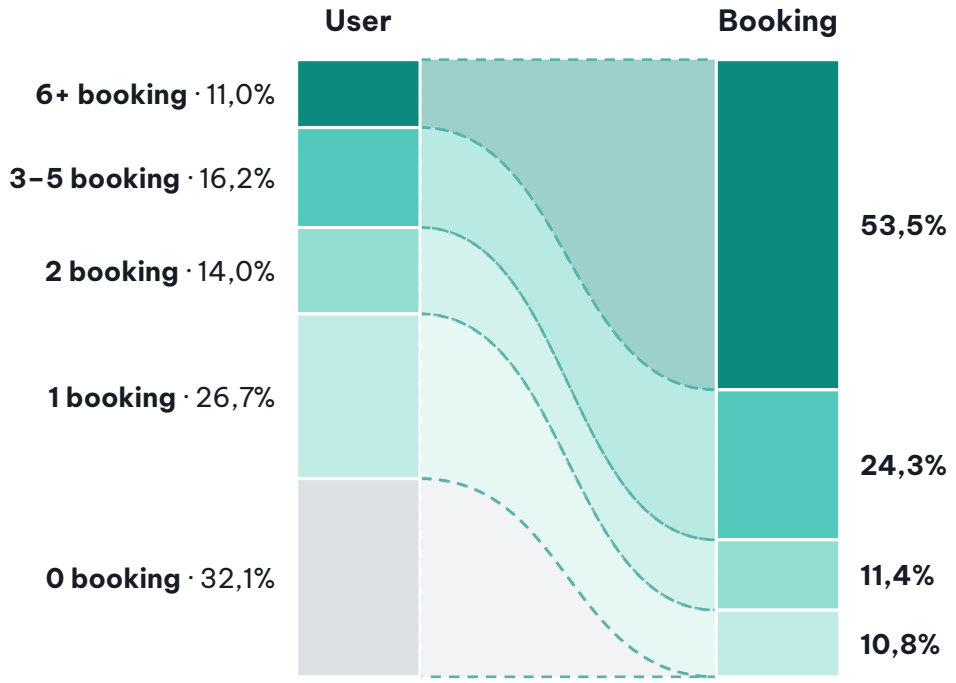


Dữ liệu gần đây **dày hơn hẳn**, cho thấy **hành vi gần đây chiếm ưu thế**, nên **chia tập theo thời gian**.

Check-in dồn vào mùa hè (T8 gấp đôi T2), nhưng dữ liệu mới phủ hai năm: **tính mùa vụ chưa rõ rệt**.

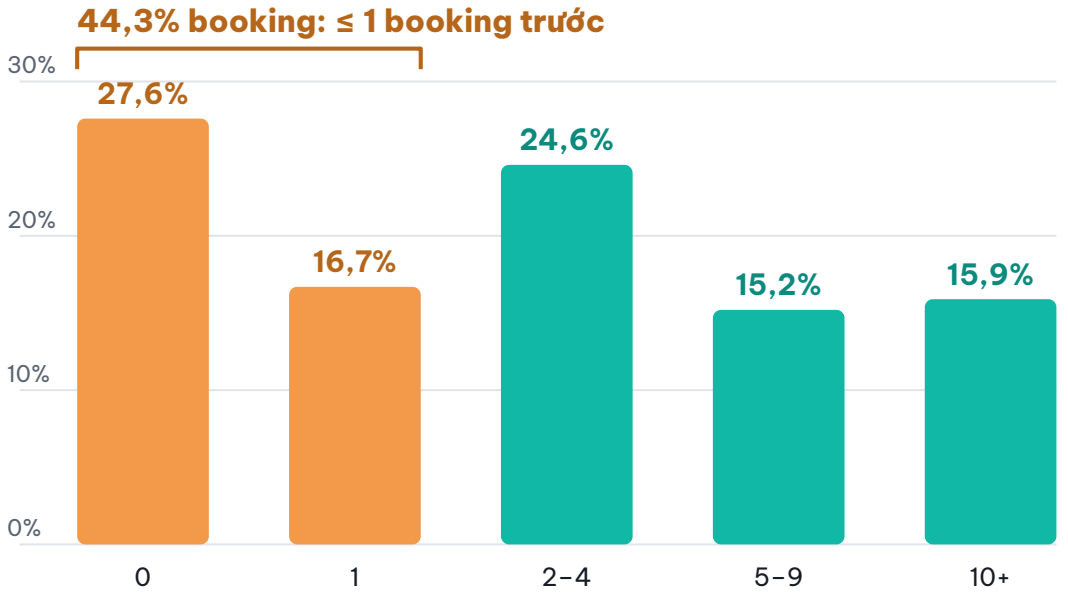
Số booking của mỗi user

User và booking theo số booking của mỗi user



0–1 booking: 58,8% user

Lịch sử tại mỗi booking cần dự đoán tỷ lệ booking



số booking trước đó của user · trung vị 2 · 2.952.675 booking

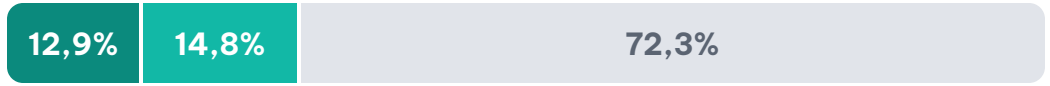
Booking tập trung ở nhóm nhỏ: **11,0% user** (từ 6 booking) tạo **53,5% booking**, **58,8% user** chỉ có 0–1 booking.

44,3% booking cần dự đoán **chưa có lịch sử hoặc lịch sử ngắn**, vì vậy **không thể chỉ dựa vào lịch sử**, cần bổ sung thông tin khác.

Đặt lại và khám phá của user

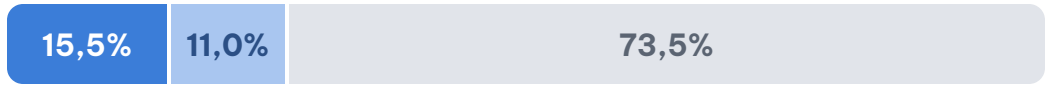
Booking mới: đặt lại hay khám phá? user đã có lịch sử

27,7% đặt lại **hotel_cluster** đã từng đặt



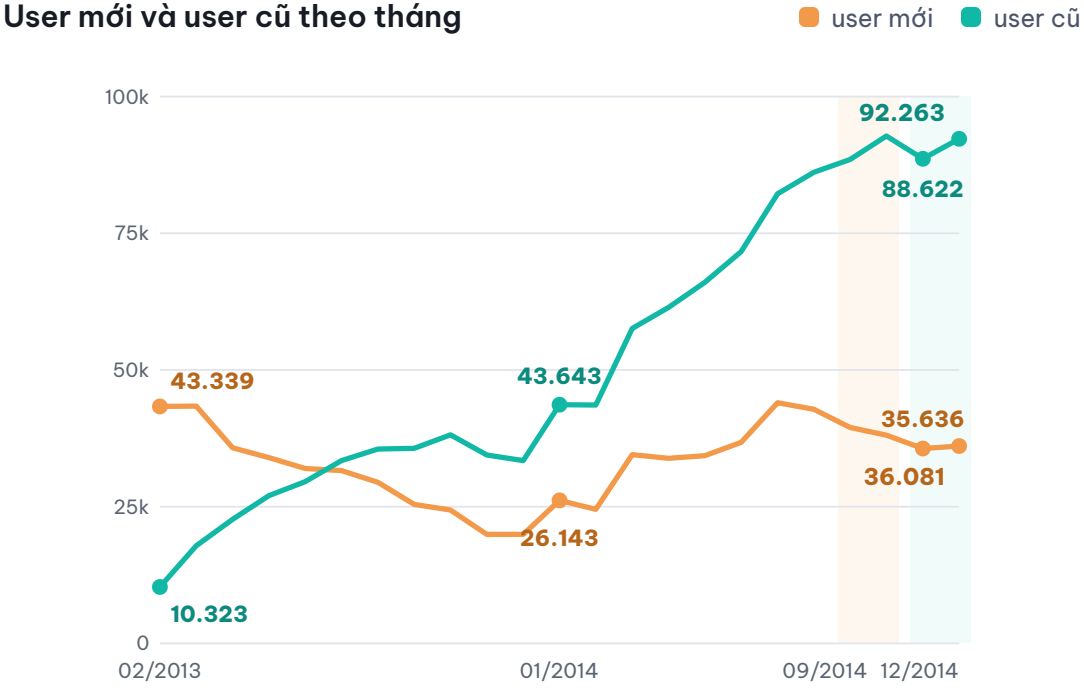
đúng cluster liền trước · cluster cũ hơn · cluster chưa từng

26,5% quay lại **srch_destination_id** đã từng đặt



đúng điểm đến liền trước · điểm đến cũ hơn · điểm đến chưa từng

User mới và user cũ theo tháng



User mới: tháng có booking đầu tiên của user
User cũ: user đã có booking ở các tháng trước

Đa số booking là cluster mới, nhưng vẫn có phần đáng kể quay lại cluster và điểm đến cũ: **không thể loại cluster cũ** khỏi tập cluster dự đoán.

Cold start diễn ra liên tục: mỗi tháng có hàng chục nghìn user đặt phòng lần đầu, chưa có lịch sử, nên cần gợi ý được **ngay từ lần tìm kiếm đầu**.

Cluster và địa lý khách sạn

Cluster có mặt ở bao nhiêu nơi

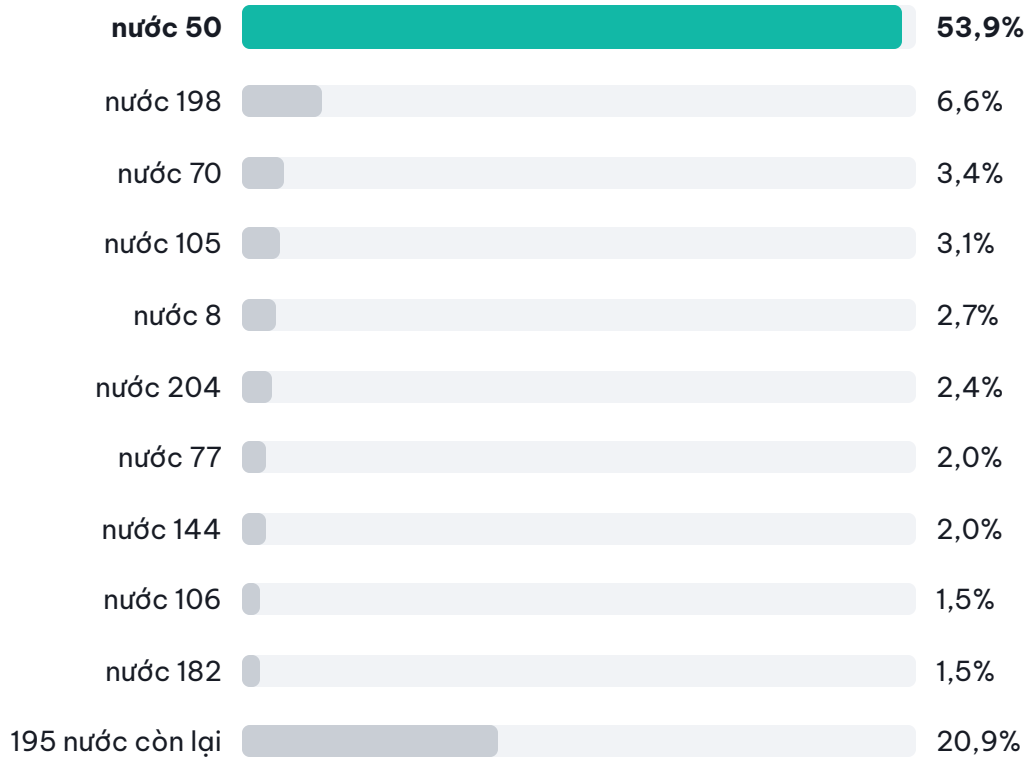
trung vị tổng

Châu lục 6 / 7

Nước 49 / 205

Market 388 / 2.103

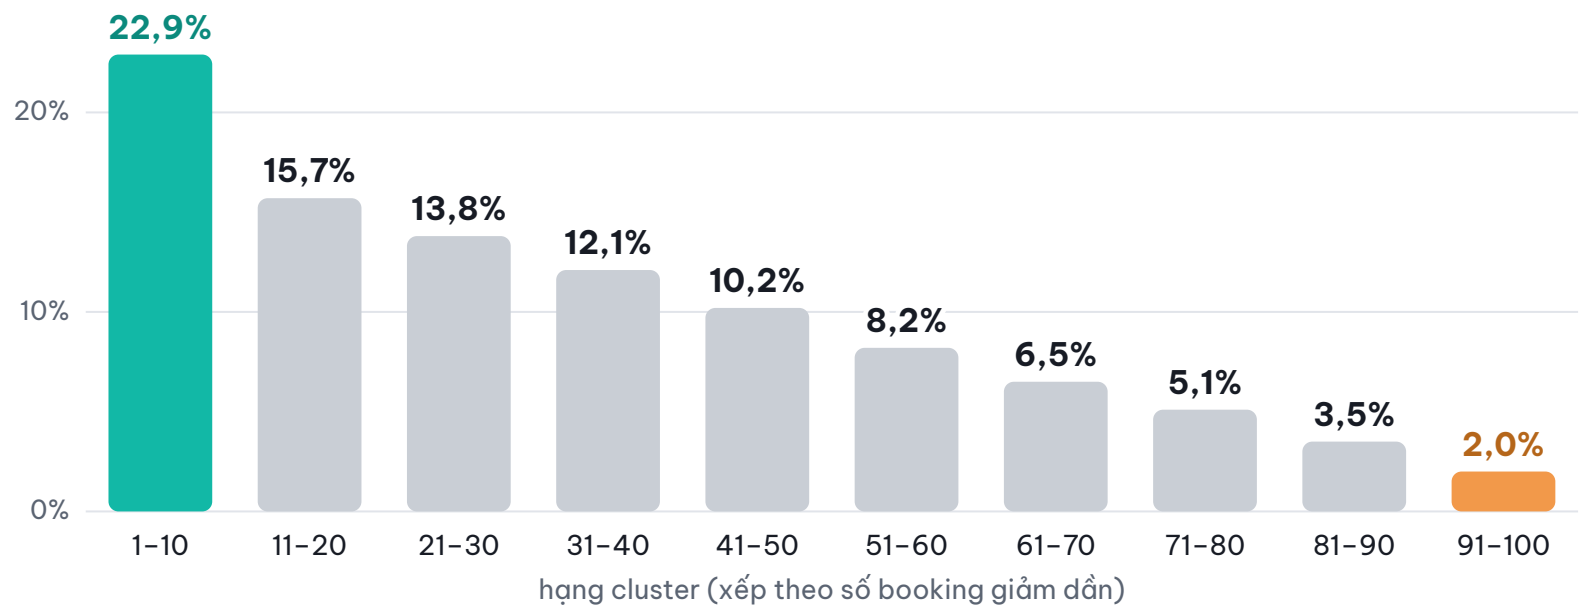
Tỷ trọng booking theo hotel country 10 nước đầu



Booking dồn vào **một nước** (53,9%), nhưng mỗi cluster trải ở trung vị **49 nước và 388 market**: biết **địa điểm** chưa đủ để biết **user chọn cluster nào**.

Phân bố booking theo nhóm cluster

Tỷ trọng booking của từng nhóm 10 cluster 100 cluster, xếp theo số booking giảm dần, mỗi cột là 10 cluster



Cộng dồn từ cluster nhiều booking nhất

38,6%
booking thuộc 20 cluster đầu

74,7%
booking thuộc 50 cluster đầu

50 lần
cluster nhiều nhất so với ít nhất (91 và 74)

Phân bố **chênh lệch**: 50 cluster đầu chiếm 3/4 booking, 10 cluster cuối chỉ **2,0%**.

Khi đánh giá, cần xem cả **cluster ít booking** có được gợi ý không, không chỉ độ chính xác.

Tổng kết EDA và hướng tiếp cận

EDA cho thấy

- **Lịch sử thưa, cold start liên tục:** 44,3% booking có tối đa 1 booking trước đó
  → **cần gợi ý được từ lần tìm kiếm đầu**
- **Lịch sử vẫn có giá trị:** 28% quay lại cluster cũ, 26,5% quay lại điểm đến cũ
  → **không loại cluster cũ khỏi tập dự đoán**

Sequential: đọc thứ tự lịch sử booking

ĐIỂM MẠNH

- Hướng chuẩn cho bài toán dự đoán lựa chọn kế tiếp
- Khai thác thứ tự và việc quay lại cluster cũ

ĐIỂM YẾU

- Cần lịch sử đủ dài, trong khi dữ liệu thưa
- User chưa có lịch sử: không có gì để đọc (cold start)
- Không dùng thông tin của lần tìm kiếm hiện tại

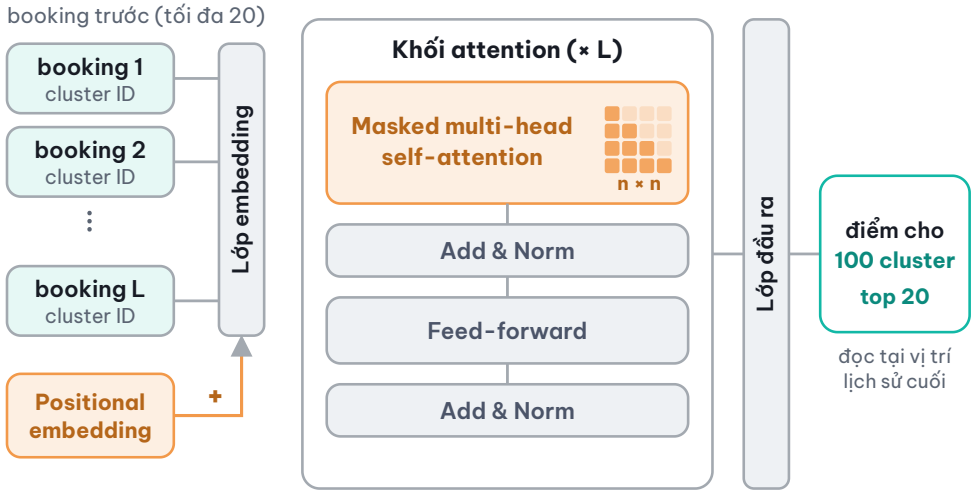
Sequential thuần **chưa đủ** cho dữ liệu thưa: **giữ làm nền**, rồi **bù bằng ngữ cảnh lần tìm kiếm và thông tin điểm đến**.

SMLP4Rec gợi ý khách sạn trên Expedia

Sequential-based kết hợp Context-aware

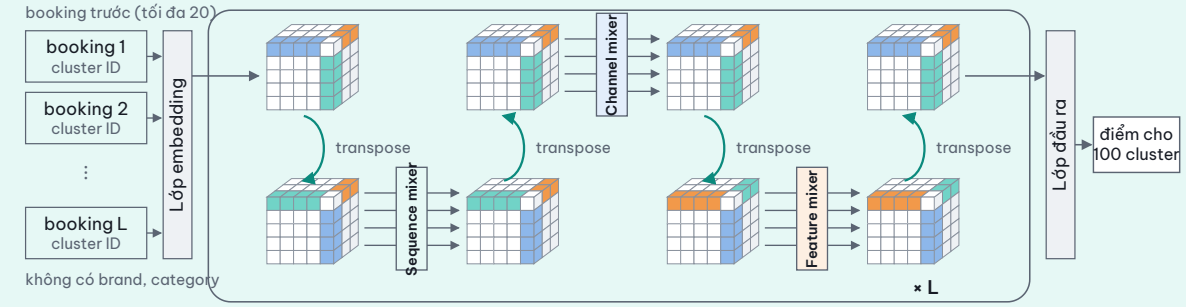
Từ attention đến MLP4Rec

Self-attention dạng SASRec



- Cần positional embedding: dễ làm nhiễu item embedding
- Chi phí bậc hai theo độ dài chuỗi
- Nhiều tham số, dễ overfit

MLP4Rec thay attention bằng MLP

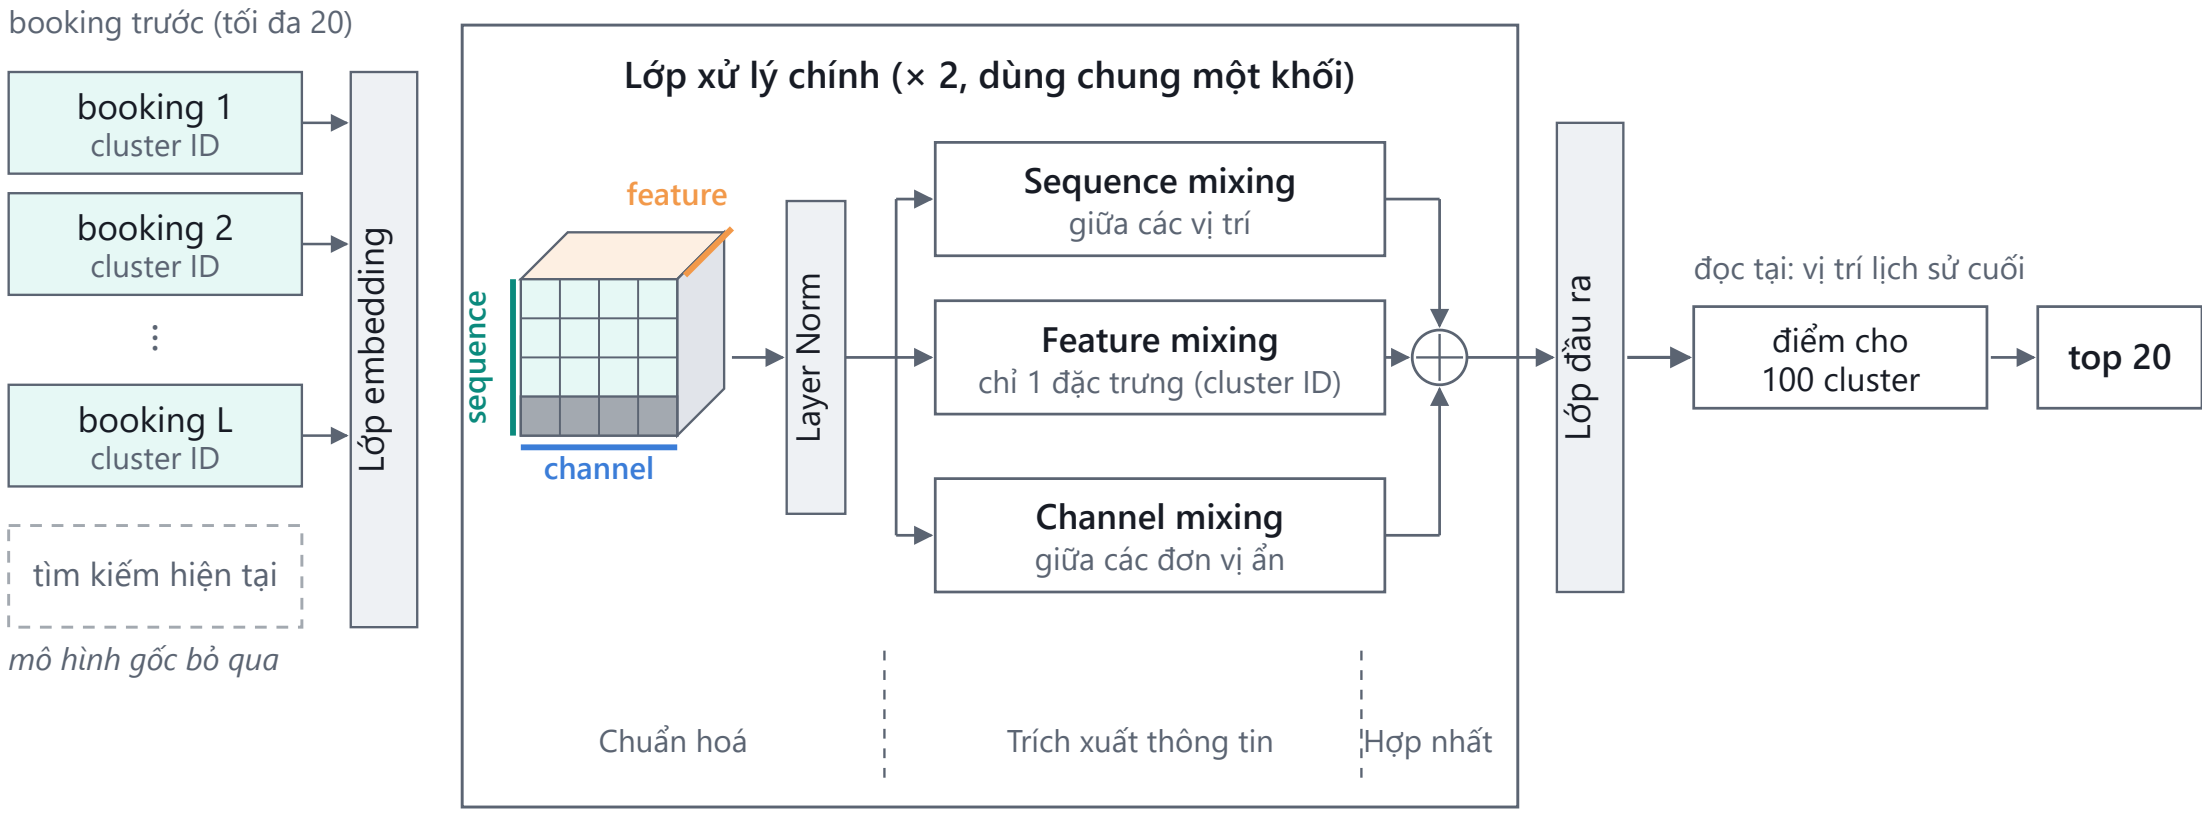


- Nhạy thứ tự sẵn, không cần positional embedding
- Chi phí tuyến tính, ít tham số
- Hạn chế: mixer nối tiếp, nhiều lớp chuẩn hoá

MLP4Rec **hợp dữ liệu thưa hơn attention**: ít tham số, chi phí tuyến tính, không cần positional embedding.

Hạn chế còn lại là **mixer nối tiếp, nhiều lớp chuẩn hoá**: SMLP4Rec khắc phục ở slide sau.

SMLP4Rec: mô hình nền của đề tài

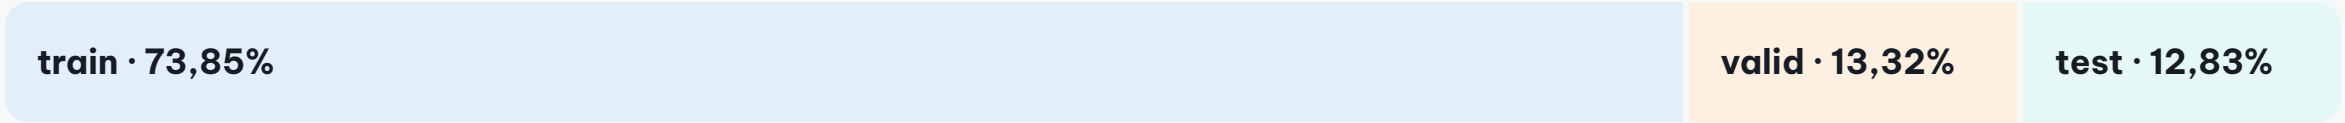


Khắc phục: song song, một Layer Norm

Còn thiếu: tìm kiếm hiện tại

Chia tập theo thời gian

CHIA THEO NGÀY ĐẶT PHÒNG (BOOKING DATE, KHÔNG PHẢI NGÀY CHECK-IN)



train
07/01/2013 – 31/08/2014

Booking	2.180.488
User	664.727

valid
01/09 – 31/10/2014

Booking	393.399
User	226.064
Trong đó chưa có ở train	77.541 34,3%

test
01/11 – 31/12/2014

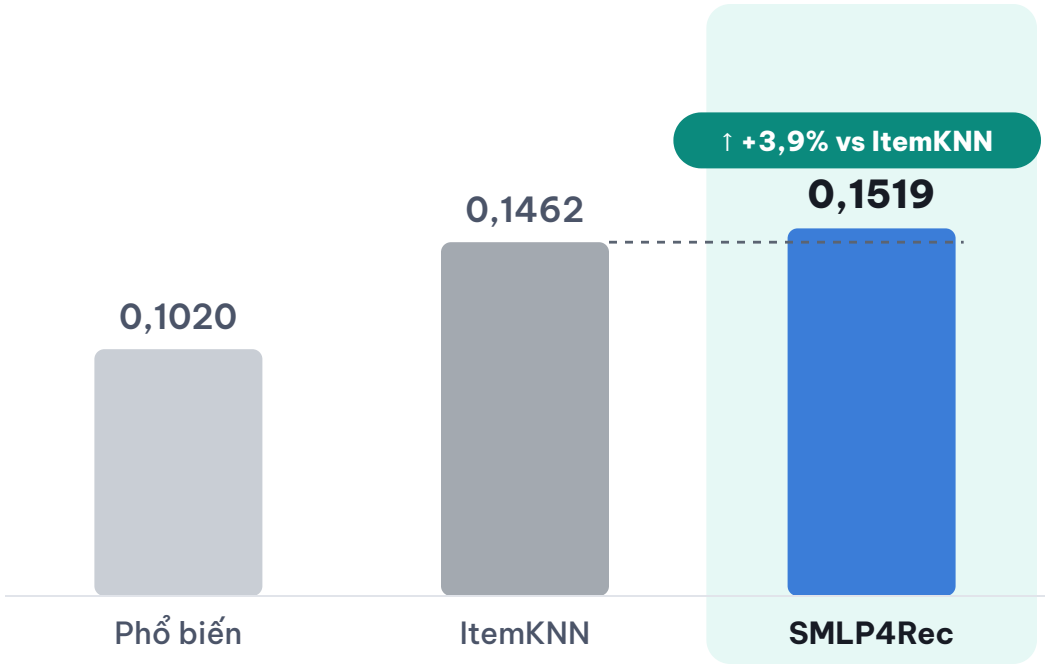
Booking	378.788
User	222.428
Trong đó chưa có ở train	87.008 39,1%

Một user có thể thuộc nhiều tập

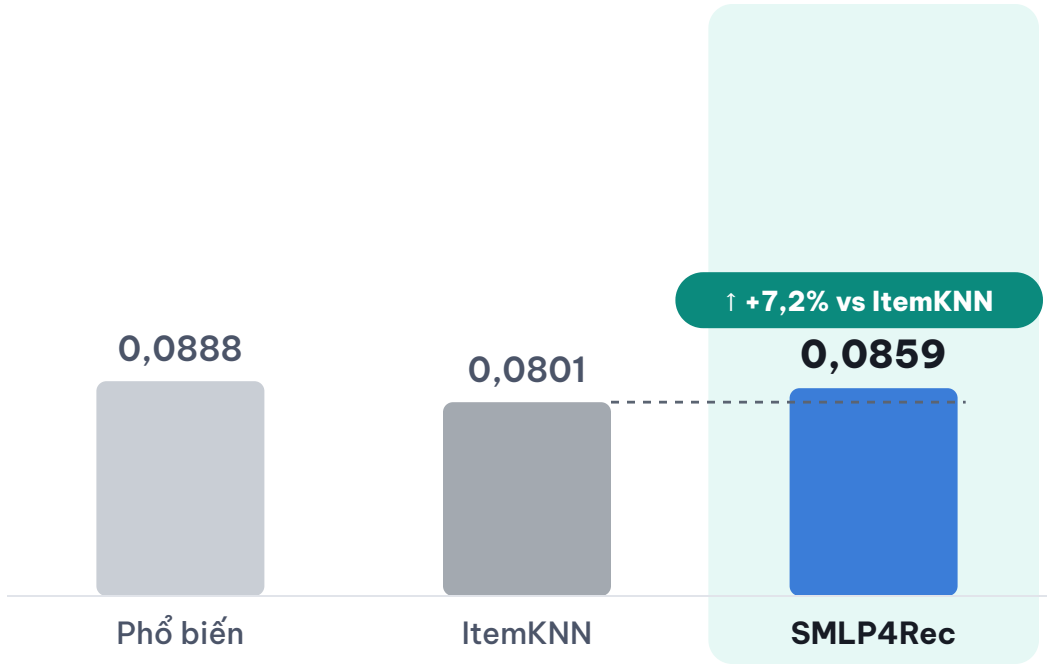
User tính trên 813.985 user của cả dataset

SMLP4Rec gốc: kết quả khi chỉ dùng lịch sử

NDCG@5 tất cả user test



NDCG@5 user cold: chưa có lịch sử



Chỉ huấn luyện với các booking đã có lịch sử, nên **chạy không hiệu quả với booking của user mới**.

Chỉ thấy thông tin trong lịch sử, **chưa thấy ngữ cảnh của chuyến đi hiện tại**.

Cách test và đánh giá →

Bổ sung ngữ cảnh lần tìm kiếm: query embedding

Vì sao chọn query embedding?

Giải pháp trực tiếp cho phần thiếu sót: Chưa thấy ngữ cảnh chuyến đi

→ **14 trường tìm kiếm** (điểm đến, ngày, số người, gói...) gộp thành **một vị trí query** sau lịch sử

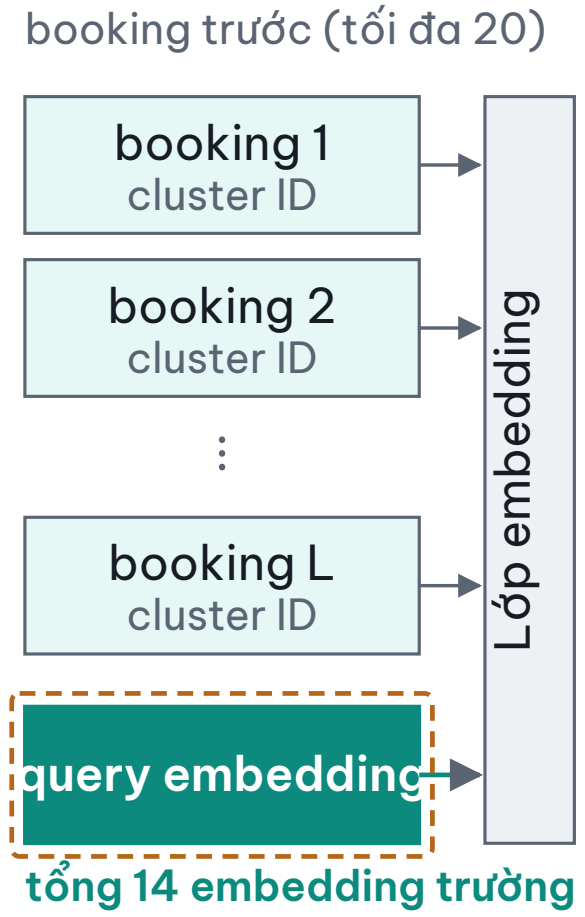
Hoạt động tốt với cả user mới

→ Query embedding có ở **mọi booking**, kể cả khi lịch sử rỗng: **chạy được với user mới**

Cách làm gọn

→ Chỉ **thêm một vị trí** vào chuỗi, giữ nguyên mô hình nền

Query embedding nối vào lịch sử



Phụ lục A1: 14 trường →

Query embedding: kết quả

SMLP4Rec + query embedding

NDCG@10

0,4426

↑ +0,2506 (+130,5%)

so với SMLP4Rec gốc · khoảng tin cậy 95%: +0,2491 đến +0,2521

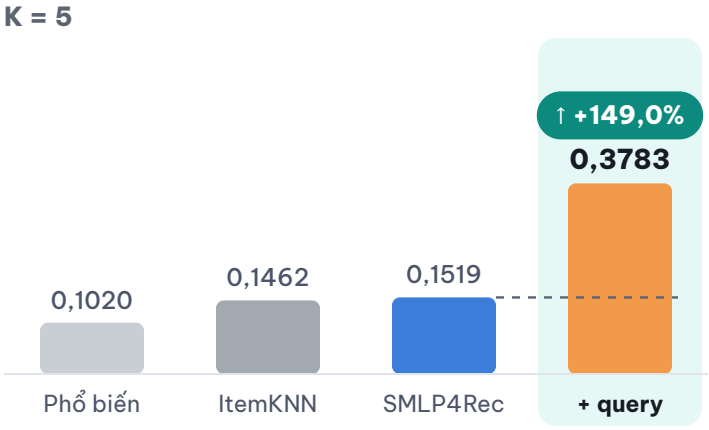
RECALL@10

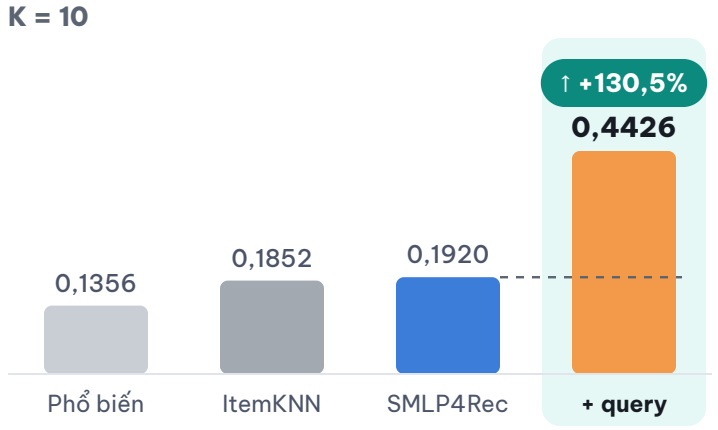
69,5%

↑ +115,6%

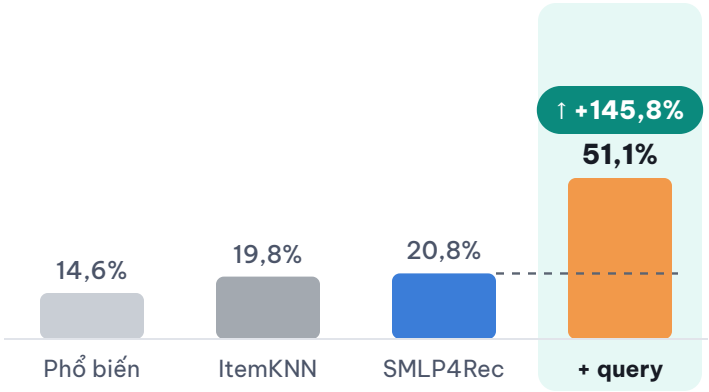
K = 5: NDCG **0,3783** · Recall **51,1%**. Lần tìm kiếm hiện tại là **tín hiệu chính**.

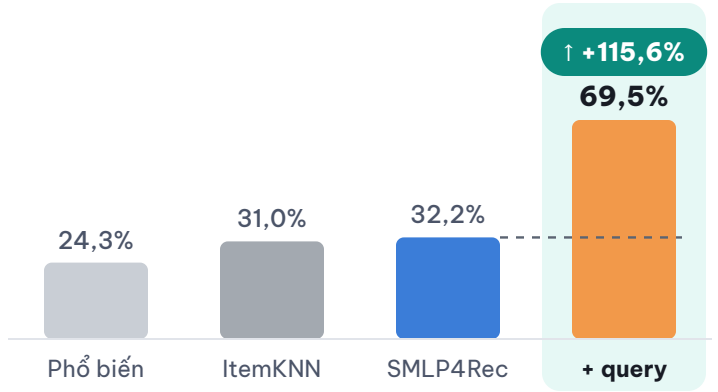
NDCG@K chất lượng xếp hạng





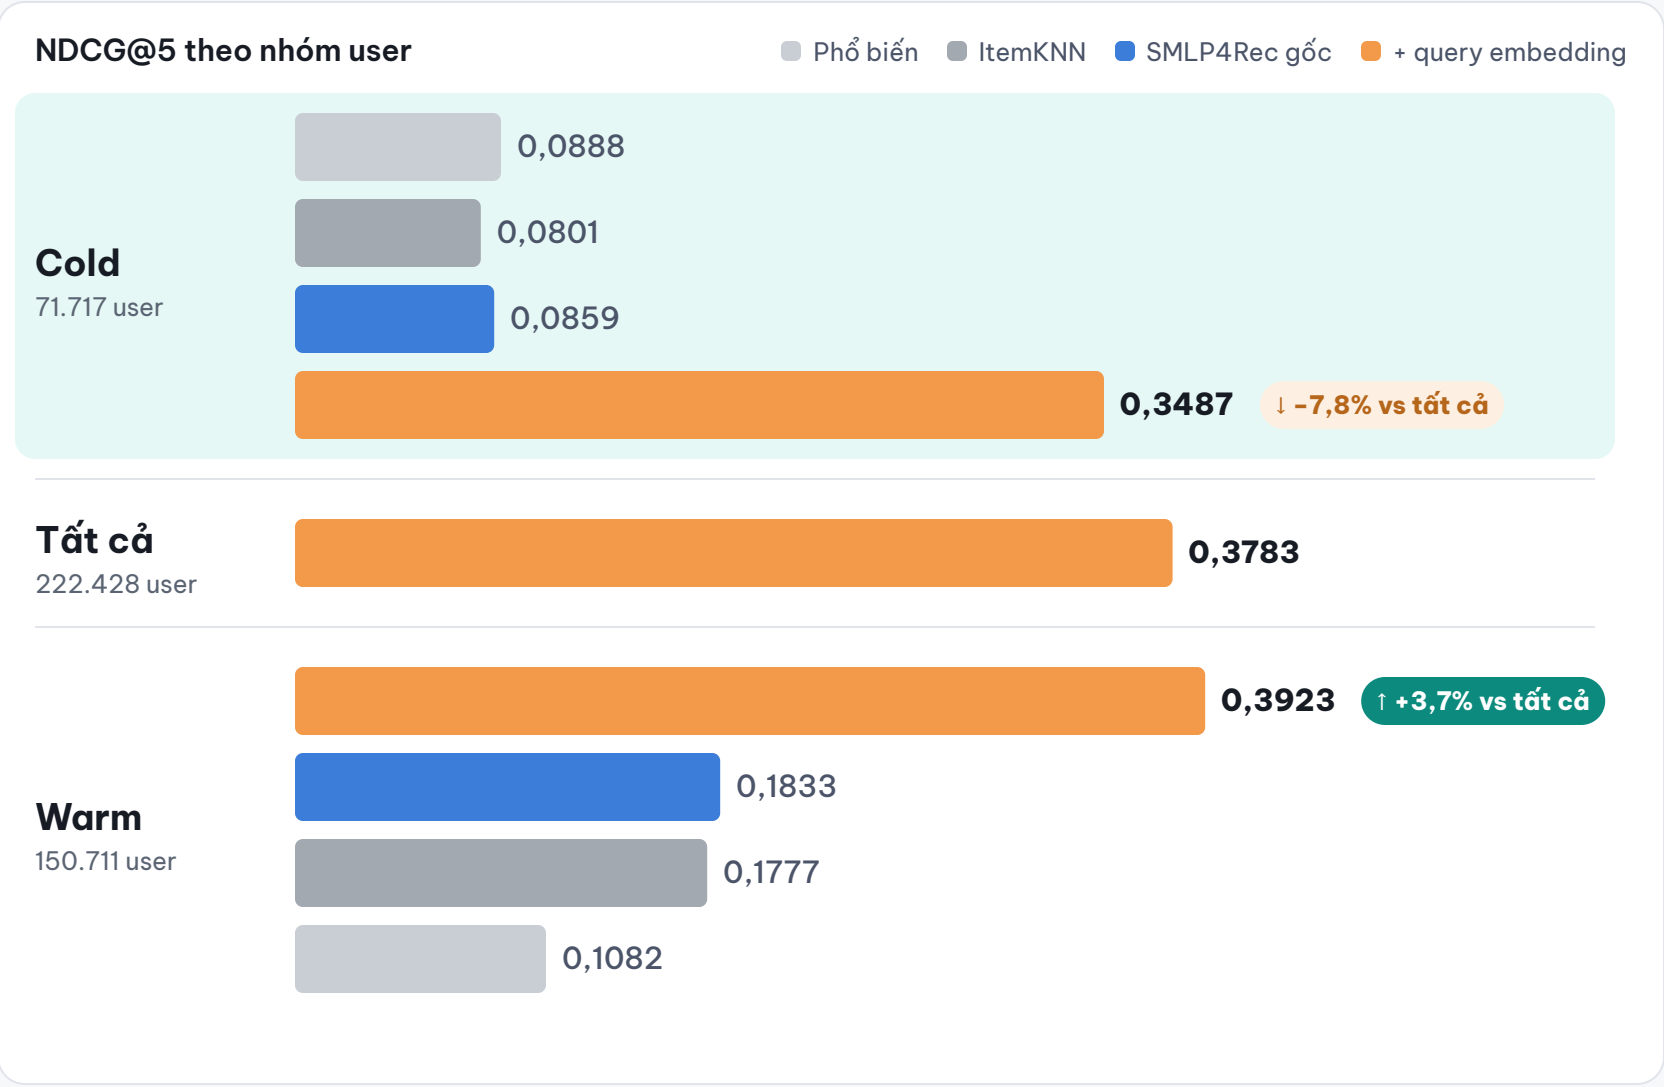
Recall@K tỷ lệ booking thật nằm trong top K





Cách test và đánh giá →

Query embedding: kết quả với user cold



USER COLD · NDCG@5

0,3487

↑ 4,4× ItemKNN (0,0801)

↑ 3,9× độ phổ biến (0,0888)

Cold: chưa có booking nào trước 01/11/2014. Mô hình chỉ đọc lịch sử không có gì để xếp hạng; query embedding **đọc lần tìm kiếm hiện tại**.

Bổ sung thông tin điểm đến: sameDest

1 **Cluster đã đặt càng gần càng có giá trị** Khám phá

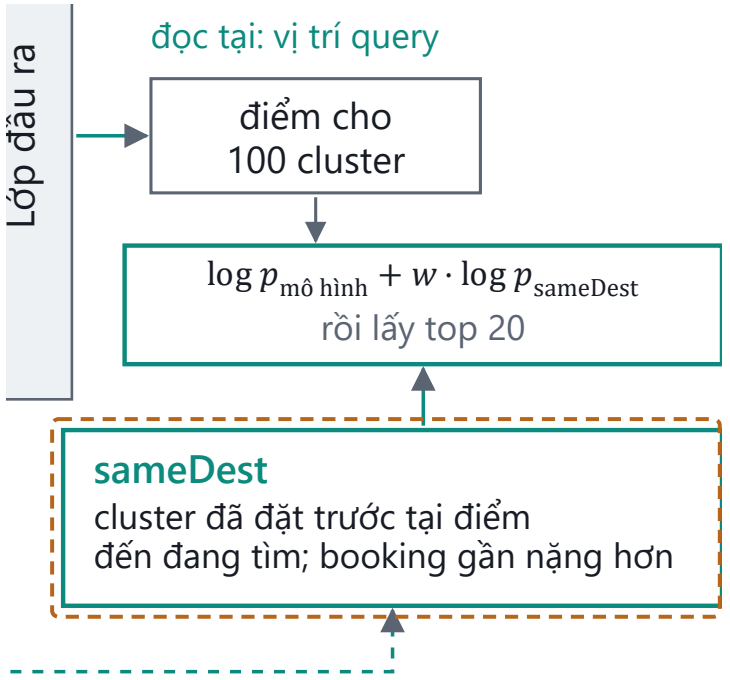
Trong các booking đã có lịch sử, khoảng 28% đặt lại cluster cũ, và khoảng một nửa trong số đó là cluster liền trước.

2 **Lịch sử dài: mô hình gốc có thể chưa học được pattern** Giả thuyết

Chuỗi lịch sử tối đa 20 là dài, nên với nhóm user có lịch sử dài, pattern đặt lại gần có thể chưa được học.

3 **Cluster cũ nói chung là nhiễu** Giả thuyết

Cluster đã đặt gắn với ngữ cảnh, cụ thể là điểm đến đang tìm, mới có giá trị.



26,5% booking có lịch sử quay lại điểm đến đã từng đặt

Late-fusion · booking gần nặng hơn

Phụ lục A3: công thức →

sameDest: kết quả

Mô hình chính (+ sameDest)

NDCG@10

0,4474

↑ +0,0048 (+1,1%) vs + query embedding

khoảng tin cậy 95%: +0,0045 đến +0,0052

↑ 3,3× độ phổ biến · 2,4× ItemKNN

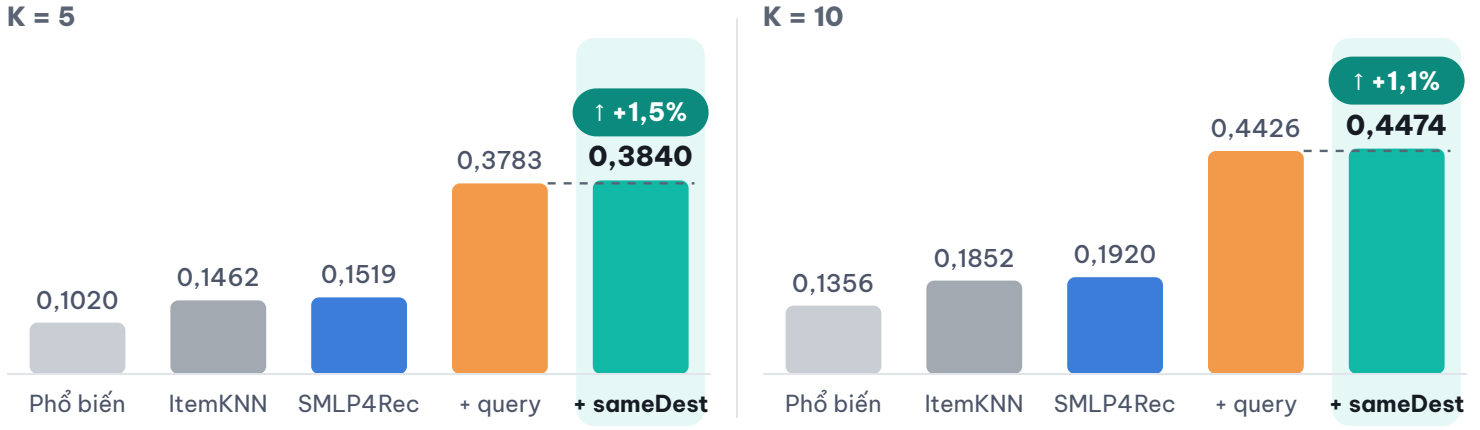
RECALL@10

69,7%

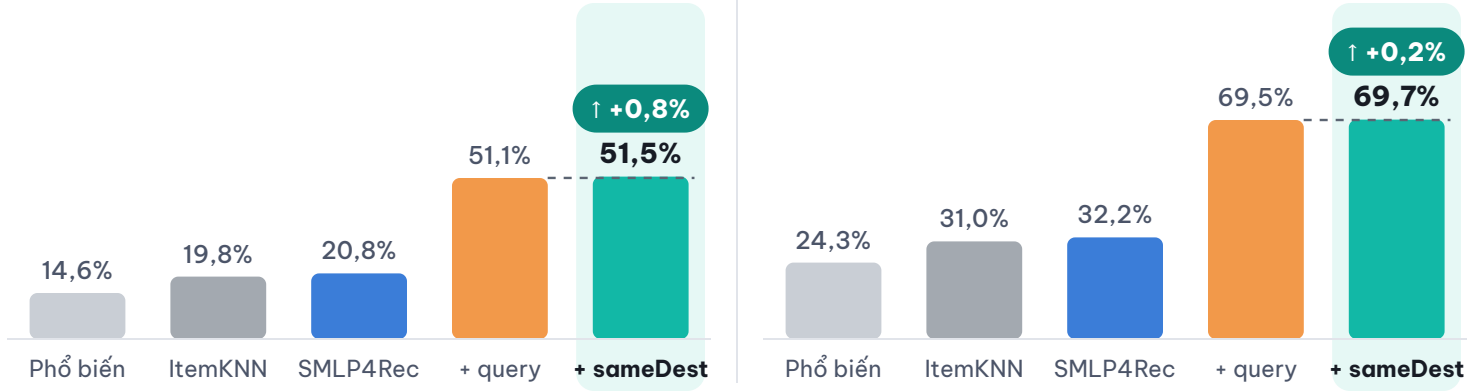
↑ +0,2%

K = 5: NDCG **0,3840** · Recall **51,5%**. Recall gần như không đổi: mức tăng nằm ở **thứ hạng**.

NDCG@K chất lượng xếp hạng



Recall@K tỷ lệ booking thật nằm trong top K

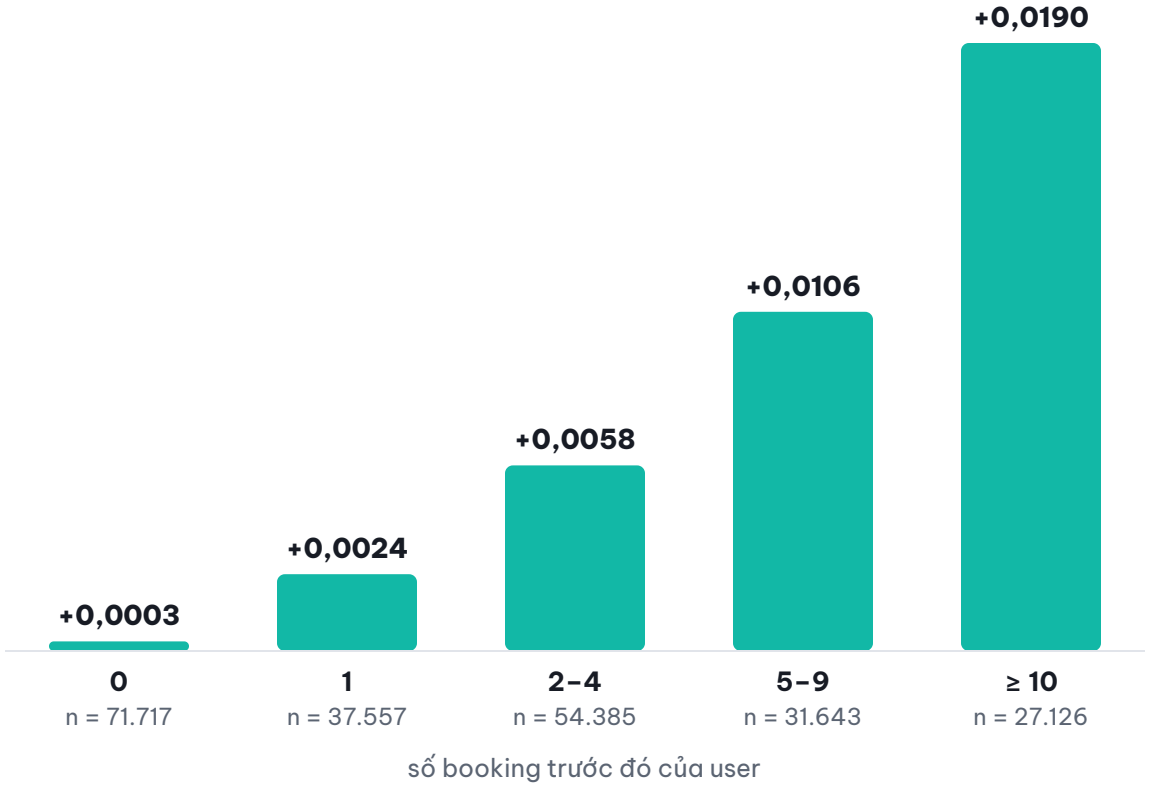


Theo mùa, nhóm khách, gói đặt (A4) → Cách test và đánh giá →

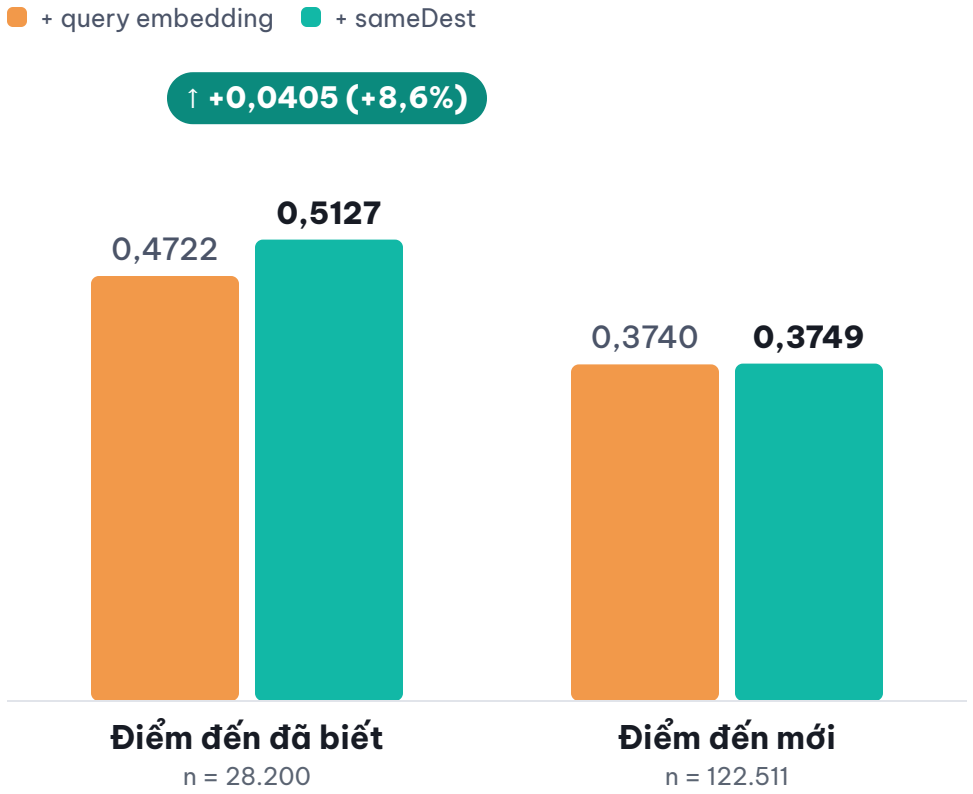
sameDest: lợi ích theo nhóm user

Mức tăng NDCG@5 theo số booking trước đó

sameDest − query embedding



NDCG@5 user warm theo điểm đến



sameDest chỉ giúp khi user **quay lại điểm đến cũ**, và lịch sử càng dài càng có ích.

Với điểm đến mới, mô hình dựa vào ngữ cảnh tìm kiếm; sameDest **không làm hại**.

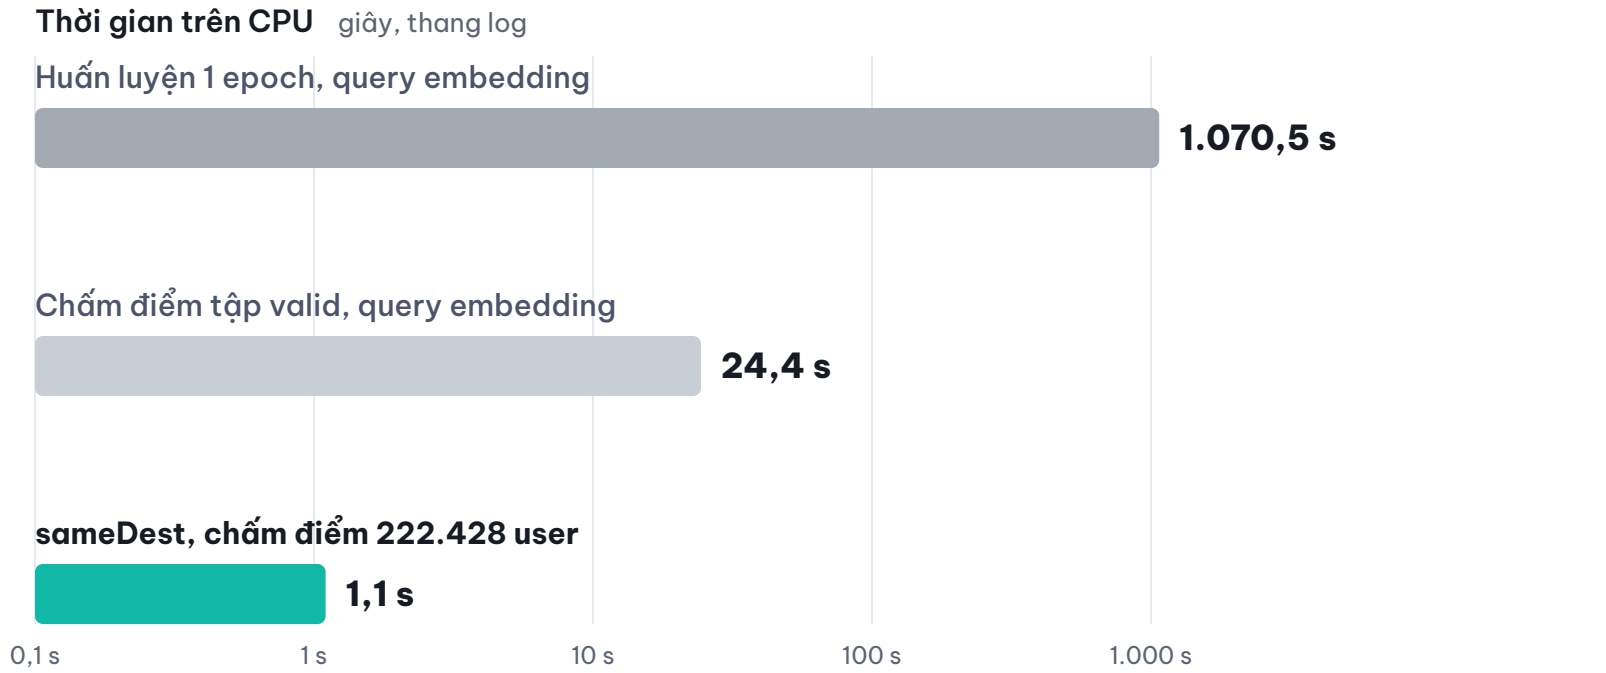
sameDest: chi phí

SAMEDEST · 222.428 USER

1,1 s

~4,8 µs mỗi user

Không huấn luyện lại



sameDest đo trên đầu vào mô phỏng cùng kích thước, không huấn luyện lại.

Chấm điểm 222.428 user mất **1,1 s**, bằng khoảng **1/1000** một epoch huấn luyện.

Chạy ngay trên mô hình có sẵn, **không huấn luyện lại**: dễ thêm vào hệ thống thật.

Kết luận

1. **SMLP4Rec gốc vẫn dùng được nhưng chưa phù hợp với bài toán du lịch:** mô hình chỉ đọc lịch sử booking, không biết lần tìm kiếm hiện tại, nên cần các cải tiến bổ sung ngữ cảnh.

2. **Lần tìm kiếm hiện tại là tín hiệu chính:** query embedding nâng NDCG@5 từ 0,1519 lên 0,3783 (+149%).

3. **Lịch sử booking là phần bổ sung nhỏ nhưng có thật:** sameDest tăng 8,6% NDCG@5 ở user quay lại điểm đến đã biết (+1,5% toàn tập), chi phí khoảng 1 giây.

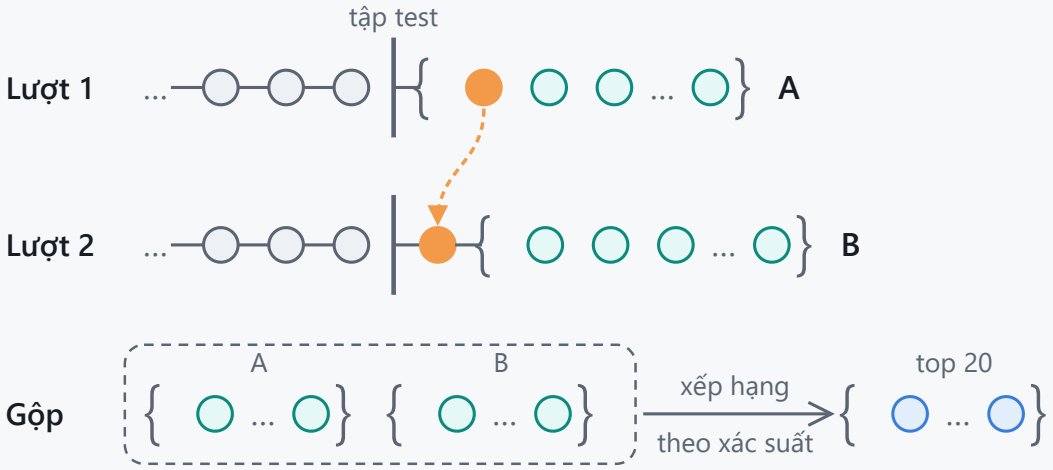
4. **User cold vẫn được xếp hạng tốt:** NDCG@5 đạt 0,3487, trong khi ItemKNN chỉ 0,0801.

Phụ lục A1. 14 trường query embedding

Trường	Ý nghĩa	Cách mã hóa	Số giá trị
`dest`	Điểm đến đang tìm (srch_destination_id)	id gốc; điểm đến có dưới 5 booking ở train thành "ngoài từ vựng"	14.711
`dest_type`	Loại điểm đến	id gốc	9
`ci_month`	Tháng check-in	1 đến 12; 0 = không rõ	12
`lead`	Số ngày từ lúc tìm đến check-in	10 khoảng, từ 0 ngày đến từ 365 ngày; 0 = không rõ	11
`stay`	Số đêm lưu trú	0 đến 14 đêm, dài hơn gộp chung; 0 = không rõ	14
`adults`	Số người lớn	cắt ở 9; 0 = không rõ	10
`children`	Số trẻ em	cắt ở 9	10
`rooms`	Số phòng	cắt ở 8; 0 = không rõ	9
`package`	Đặt kèm gói (is_package)	0 hoặc 1	2
`mobile`	Tìm trên thiết bị di động	0 hoặc 1	2
`channel`	Kênh tiếp thị	id gốc	11
`site`	Website Expedia (site_name)	id gốc	39
`posa`	Châu lục điểm bán	id gốc	5
`country`	Quốc gia của user	id gốc; dưới 5 booking ở train thành "ngoài từ vựng"	216

Phụ lục A2. Cách test và đánh giá

Mỗi user một danh sách top 20 cố định



Chấm điểm, K = 5, 10, 20

$$\text{Recall@K} = \frac{\left|\text{Top}_K \cap \text{Actual}\right|}{|\text{Actual}|}$$

$$\text{NDCG@K} = \frac{\text{DCG@K}}{\text{IDCG@K}}$$

$$\text{DCG@K} = \sum_{r=1}^{K} \frac{\text{rel}_r}{\log_2(r+1)}$$

$$\text{IDCG@K} = \sum_{r=1}^{\min(K, |\text{Actual}|)} \frac{1}{\log_2(r+1)}$$

Top$_5$ = { 7 **3** 12 40 **9** }

Actual = { **3** **9** 55 }

Đại lượng	Cách tính	Giá trị
Recall@5	$\frac{\lvert\{3,9\}\rvert}{\lvert\{3,9,55\}\rvert} = \frac{2}{3}$	0.667
DCG@5	$\frac{1}{\log_2(2+1)} + \frac{1}{\log_2(5+1)}$	1.018
IDCG@5	$\frac{1}{\log_2(1+1)} + \frac{1}{\log_2(2+1)} + \frac{1}{\log_2(3+1)}$	2.131
NDCG@5	$\frac{1.018}{2.131}$	**0.478**

Phụ lục A2.1. Hai cách gộp còn lại

Cách 1

chỉ lấy lượt 1



Cách 3

biến đổi lượt 2



α: xác suất của cluster đầu A

Phụ lục A3. Công thức sameDest

B(*k*): các booking trước, tại điểm đến đang tìm, có cluster *k*. *lag*: 0 là booking gần nhất.

$$\text{sameDest}(k) = \sum_{i \in B(k)} 0.7^{\text{lag}_i}$$

Ý nghĩa: với các cluster trong lịch sử có cùng điểm đến với lần tìm kiếm, cluster được đặt càng gần đây thì được cộng trọng số điểm càng cao.

Phụ lục A4. Mô hình chính theo mùa, nhóm khách, gói đặt

NDCG@5 của mô hình chính tập test, theo thuộc tính của booking đầu tiên của user



Phụ lục A5. Ý nghĩa các trường dữ liệu

Cột	Ý nghĩa
`date_time`	thời điểm của lượt tìm kiếm hoặc đặt
`user_id`	mã user
`is_package`	đặt kèm gói (1) hoặc không (0)
`srch_adults_cnt`	số người lớn
`srch_children_cnt`	số trẻ em
`srch_ci`	ngày check-in
`srch_co`	ngày check-out
`srch_rm_cnt`	số phòng
`srch_destination_id`	mã điểm đến tìm kiếm
`srch_destination_type_id`	loại điểm đến
`hotel_cluster`	cụm khách sạn đã đặt, mã ẩn danh: nhãn cần dự đoán

Cột	Ý nghĩa
`hotel_continent`	châu lục của khách sạn đã đặt
`hotel_country`	quốc gia của khách sạn đã đặt
`hotel_market`	thị trường của khách sạn đã đặt
`orig_destination_distance`	khoảng cách từ user đến khách sạn, có thể thiếu
`user_location_country`	quốc gia của user
`user_location_region`	vùng của user
`user_location_city`	thành phố của user
`channel`	kênh tiếp thị dẫn tới lượt tìm kiếm
`is_mobile`	dùng thiết bị di động (1) hoặc không (0)
`posa_continent`	châu lục của điểm bán
`site_name`	website Expedia dùng để tìm kiếm