Next-best-product recommendation

Gợi ý sản phẩm tiếp theo trong lĩnh vực du lịch nghỉ dưỡng

Đặc điểm của bài toán gợi ý trong du lịch – khách sạn

Khách đang tìm khách sạn: đề xuất cụm khách sạn nào?

Đặc điểm	Biểu hiện
Tần suất mua thấp	một đến hai chuyến mỗi năm, dữ liệu theo từng người dùng rất ít
Chi phí chọn sai cao	đặt nhầm: tốn tiền, tốn thời gian, ảnh hưởng cả chuyến đi
Ngữ cảnh chuyến đi quyết định	một mình, cặp đôi, nhóm; điểm đến, ngày đi

Bộ dữ liệu Expedia Hotel Recommendations

Đại lượng	Giá trị
Dòng thô trong file (click và đặt phòng)	37,670,293
Trong đó là click, không dùng làm nhãn	34,669,600 (92.0%)
Lượt đặt phòng	3,000,693 (8.0%)
Người dùng (cả người chỉ click)	1,198,786
Người dùng có đặt phòng	813,985
Đối tượng cần xếp hạng (hotel_cluster)	100
Thời gian	2013-01-07 đến 2014-12-31

Các nhóm cột của bộ dữ liệu

Nhóm cột	Các cột
Tương tác, thời gian	cnt, date_time, is_booking
Người dùng	user_id
Ngữ cảnh chuyến đi	is_package, srch_adults_cnt, srch_children_cnt, srch_ci, srch_co, srch_rm_cnt
Tìm kiếm, điểm đến	srch_destination_id, srch_destination_type_id
Khách sạn, mục tiêu	hotel_cluster, hotel_continent, hotel_country, hotel_market
Vị trí người dùng	orig_destination_distance, user_location_city, user_location_country, user_location_region
Kênh, nền tảng	channel, is_mobile, posa_continent, site_name

Chia tập theo ngày booking



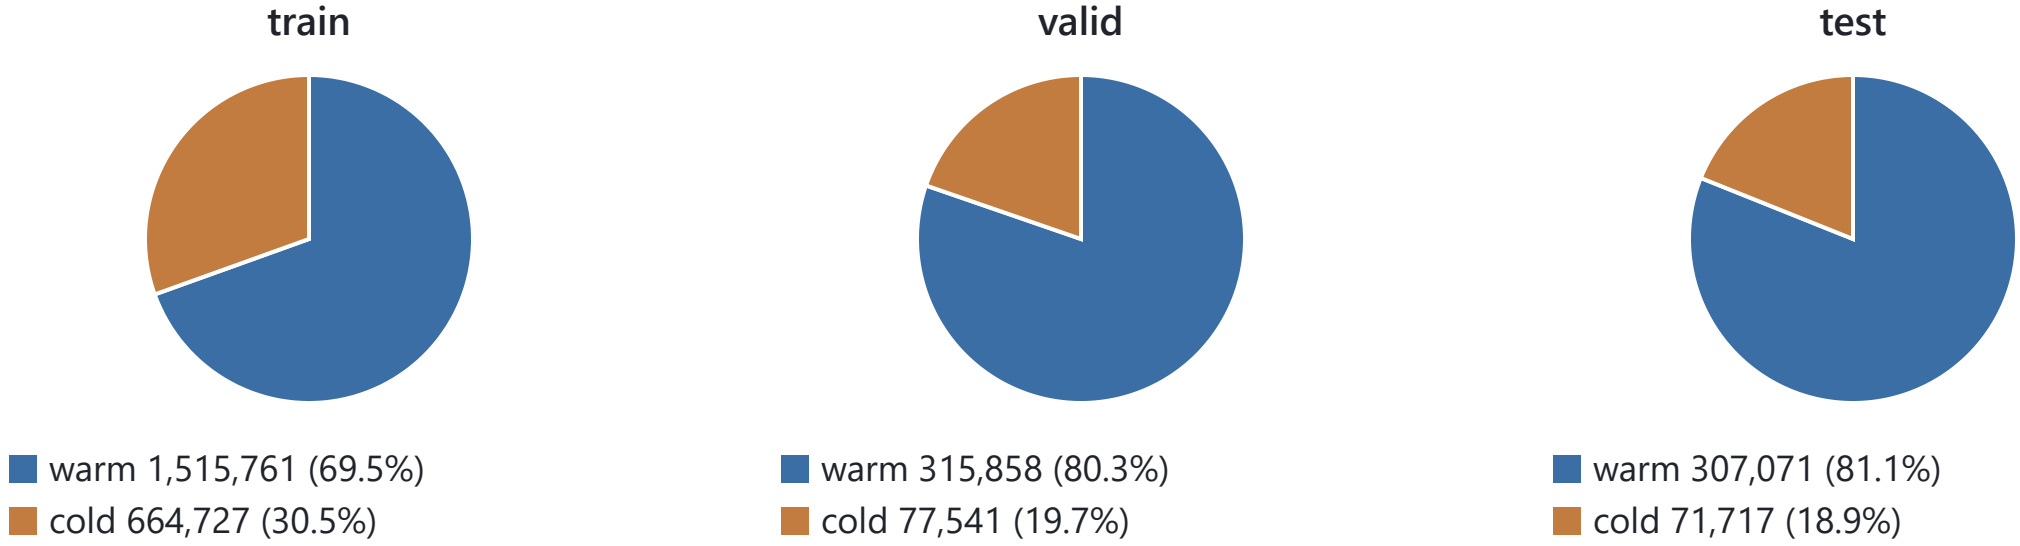
độ rộng theo số booking

Tập	Khoảng ngày booking	Booking	User trong tập	Tỷ trọng booking	Tỷ trọng user
train	2013-01-07 đến 2014-08-31	2,180,488	664,727	73.85%	81.66%
valid	2014-09-01 đến 2014-10-31	393,399	226,064	13.32%	27.77%
test	2014-11-01 đến 2014-12-31	378,788	222,428	12.83%	27.33%
Tổng	**2013-01-07 đến 2014-12-31**	**2,952,675**	**813,985**	**100.00%**	**100.00%**

Tỷ trọng user tính trên 813,985 user của cả dataset. Một user có thể xuất hiện ở nhiều tập nên ba tỷ trọng user không cộng thành 100%.

Tỷ lệ warm, cold theo tập

Tỷ lệ booking warm và cold của từng tập



Warm: booking đã có booking trước đó. Cold: booking đầu tiên.

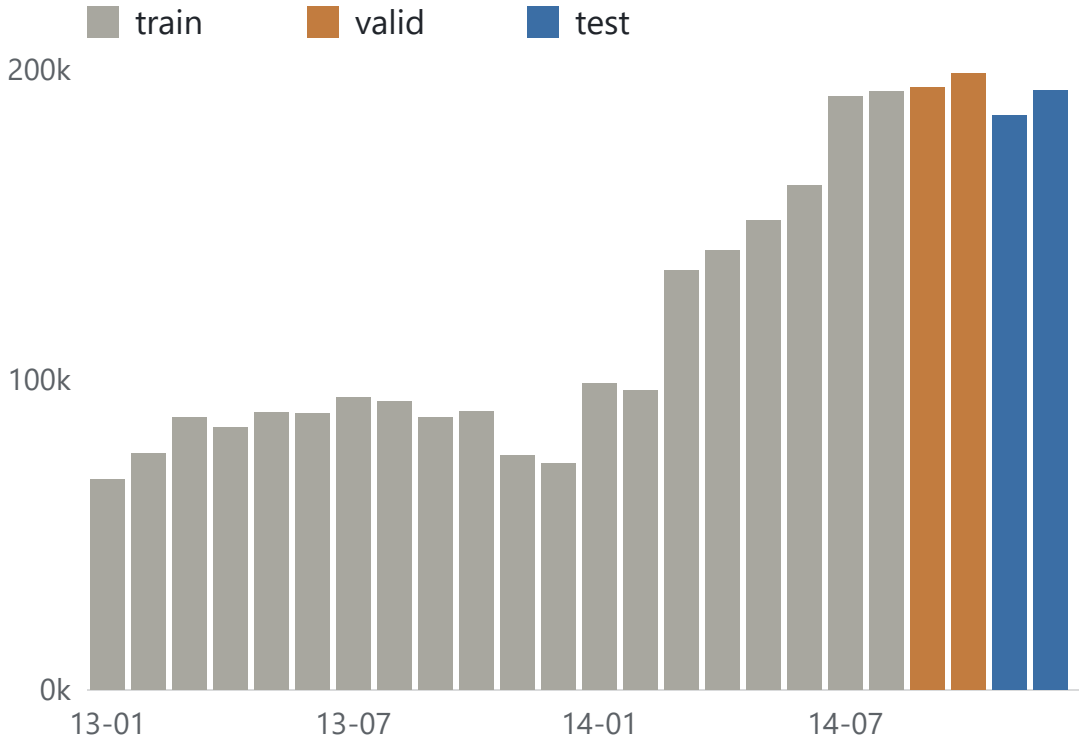
Tỷ lệ user của từng tập có và không có booking ở train



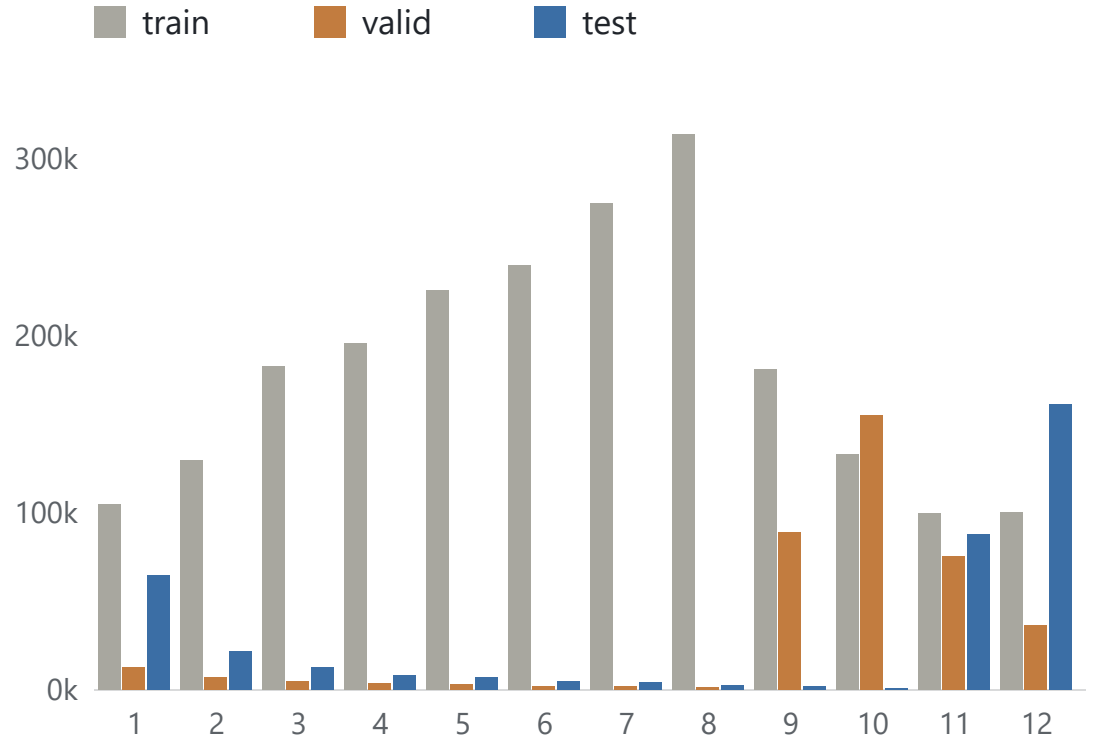
Test vắng ở train gồm 71,717 user mới hoàn toàn (cold) và 15,291 user xuất hiện lần đầu ở valid.

Lượng booking theo tháng đặt và tháng check-in

Số booking theo thời gian đặt (tháng booking)

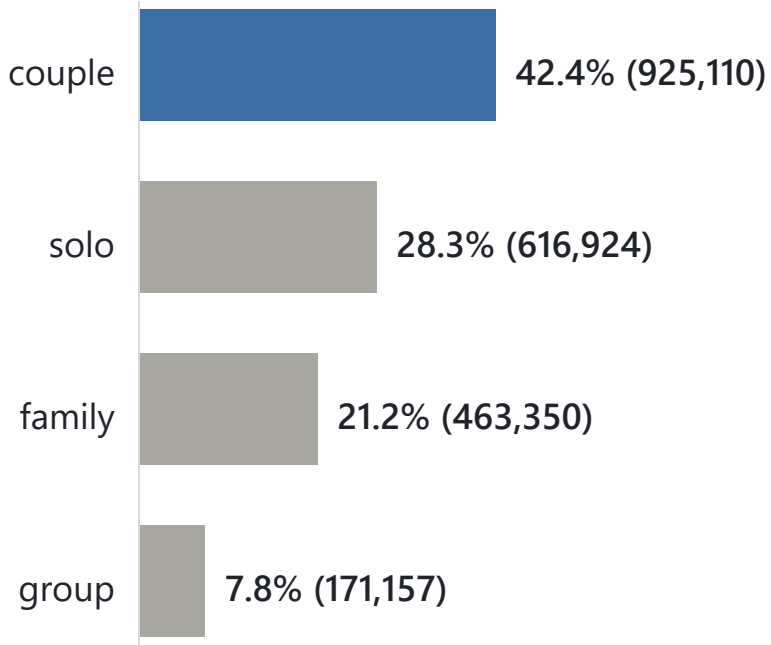


Số booking theo tháng check-in, trong từng tập

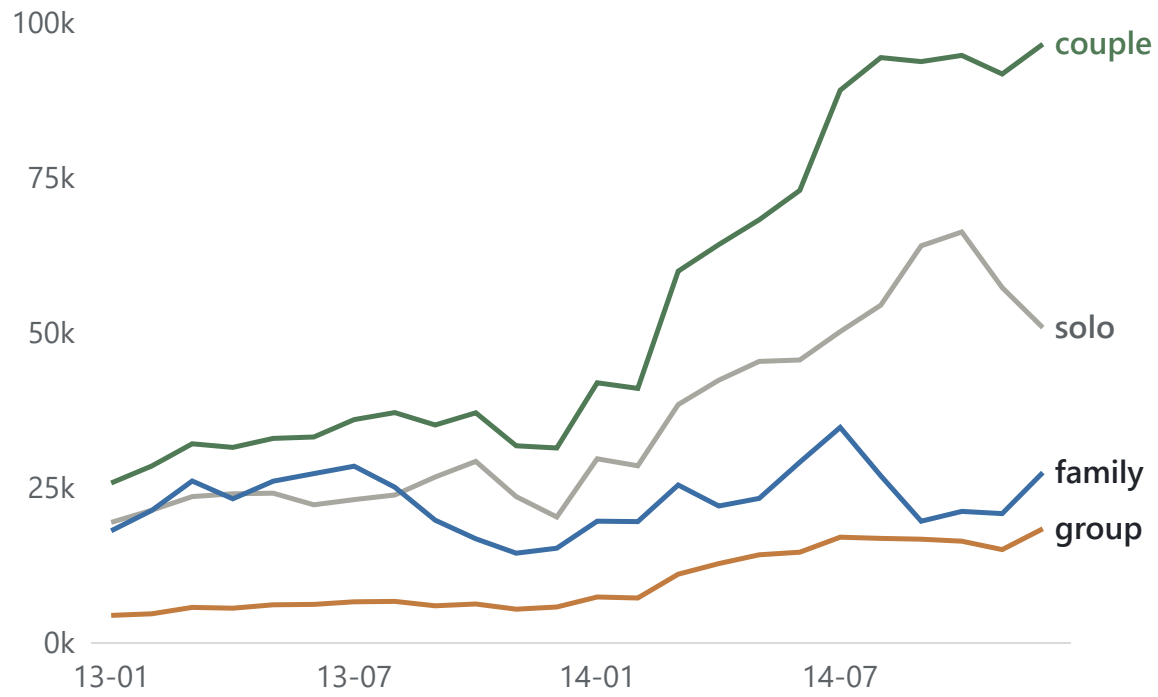


Loại đoàn khách: tỷ trọng và diễn biến theo tháng

Tỷ lệ booking theo loại đoàn khách, tập train

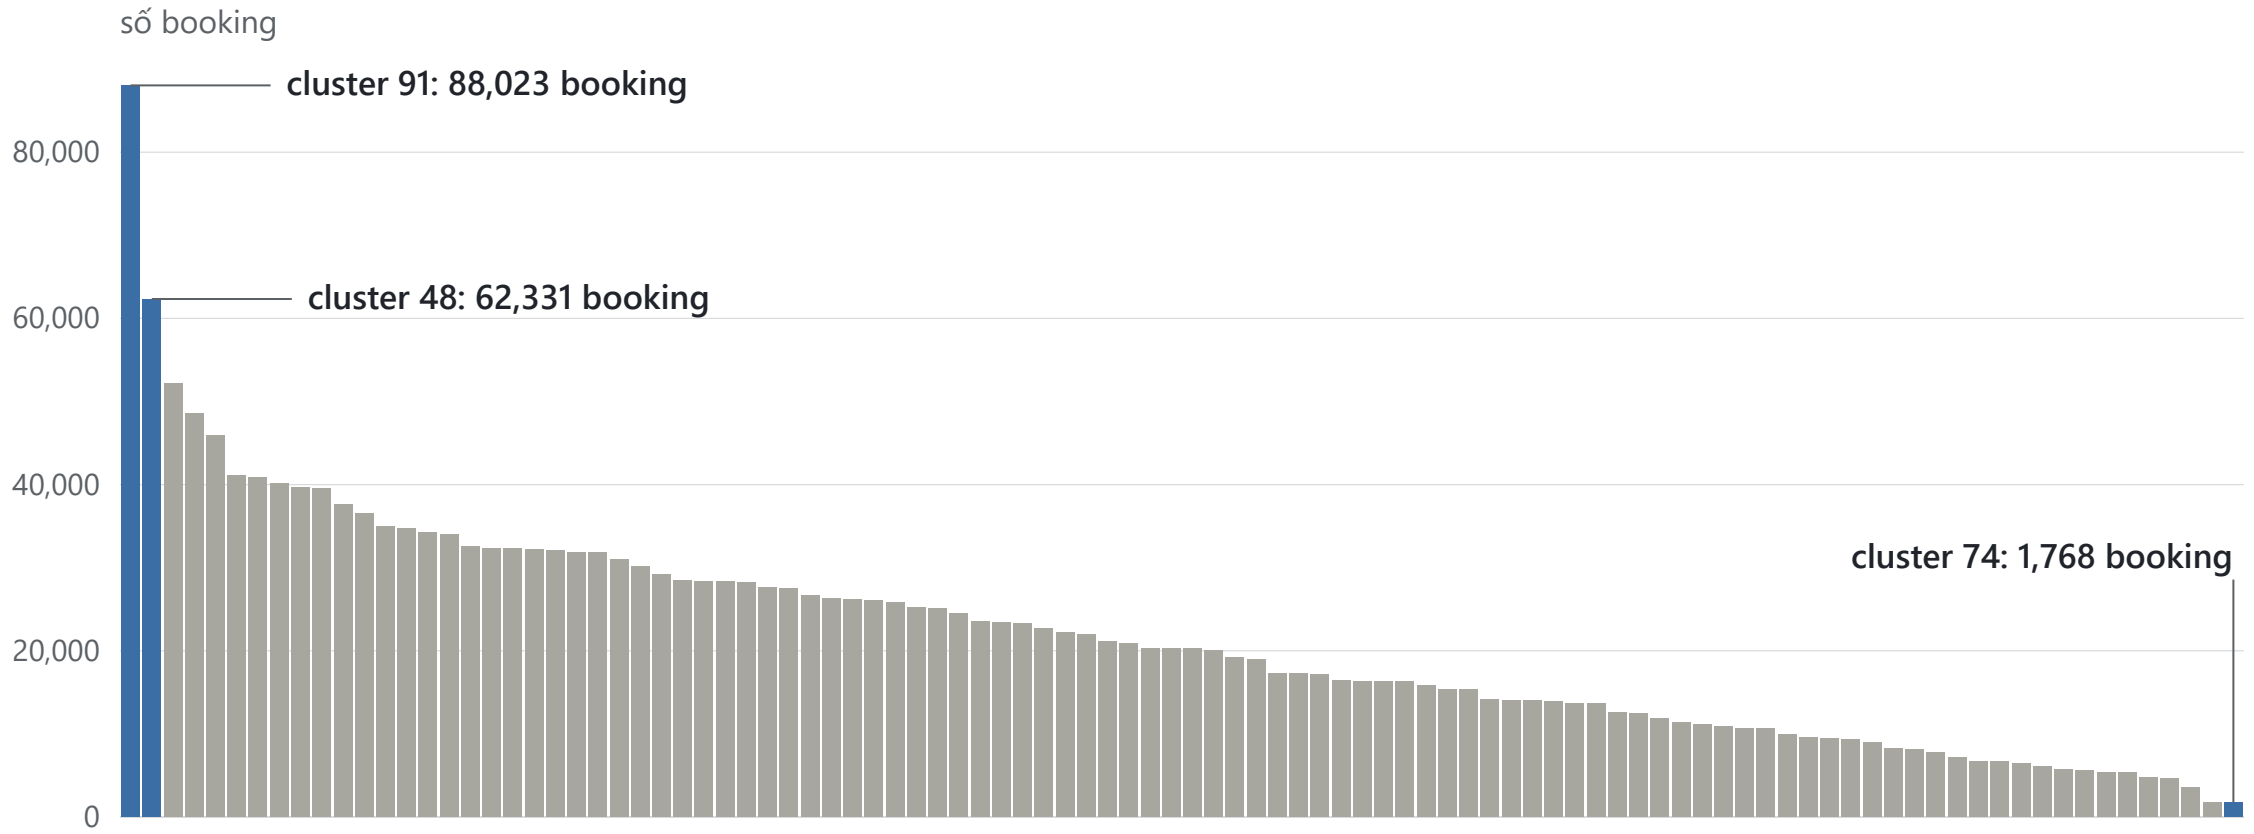


Số booking mỗi tháng theo loại đoàn khách



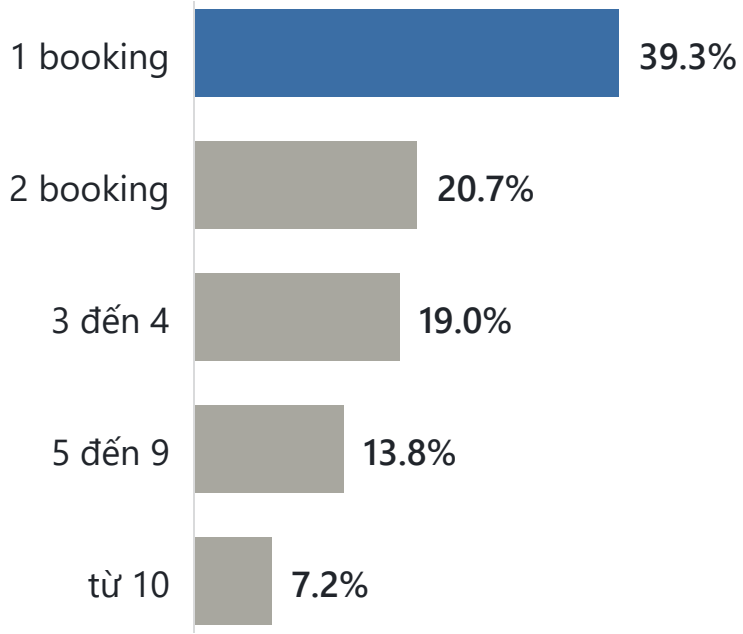
family: có trẻ em. solo: 1 người lớn. couple: 2 người lớn. group: từ 3 người lớn. unknown (0.18%): không vẽ.

Số booking của mỗi cluster trong tập train



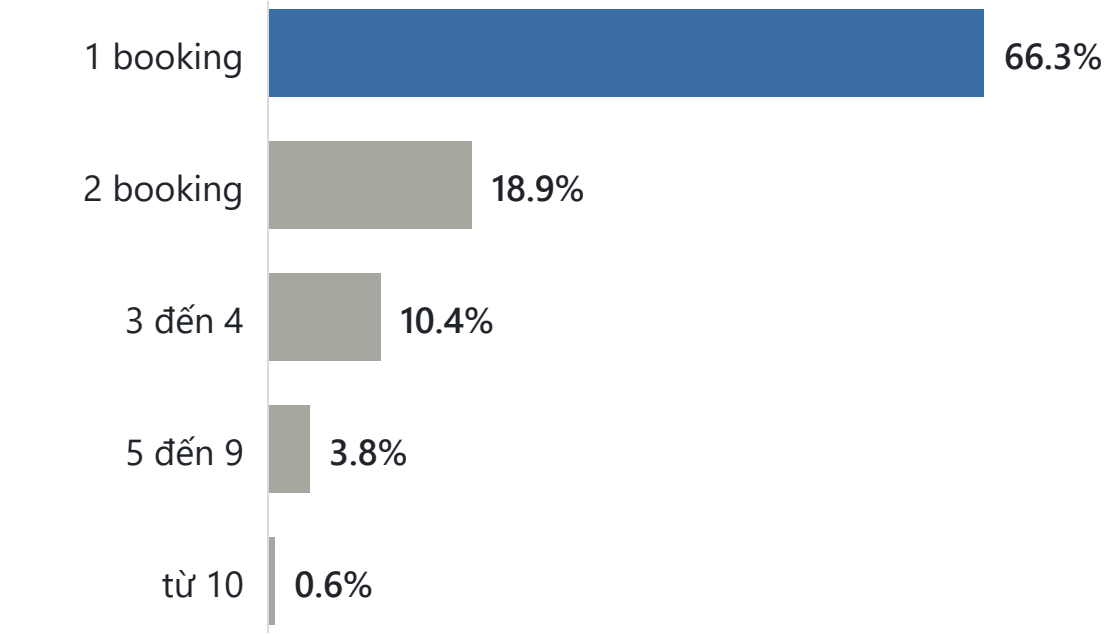
Tần suất đặt của user

Toàn dataset



Trung vị: 2 booking mỗi user.

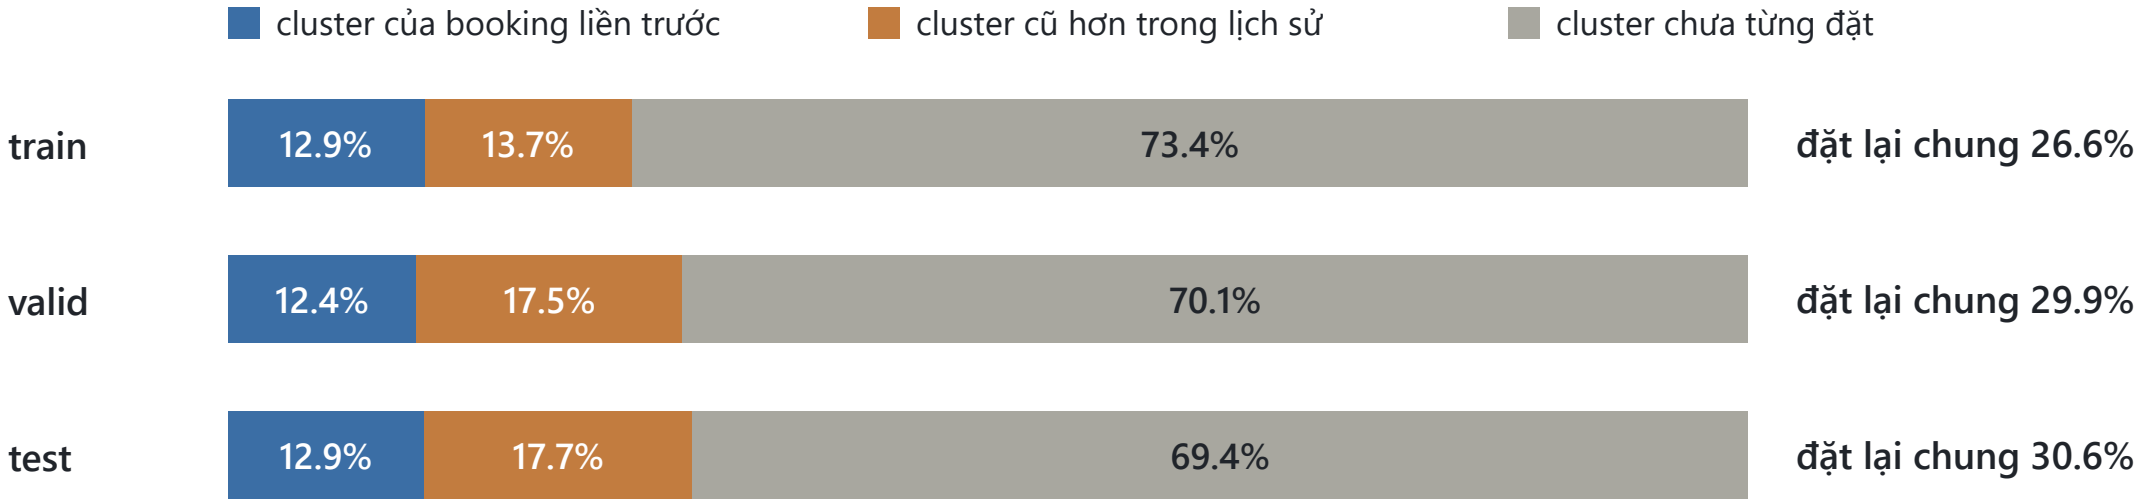
Tập test



Trung vị: 1 booking mỗi user.

Tỷ lệ đặt lại cluster

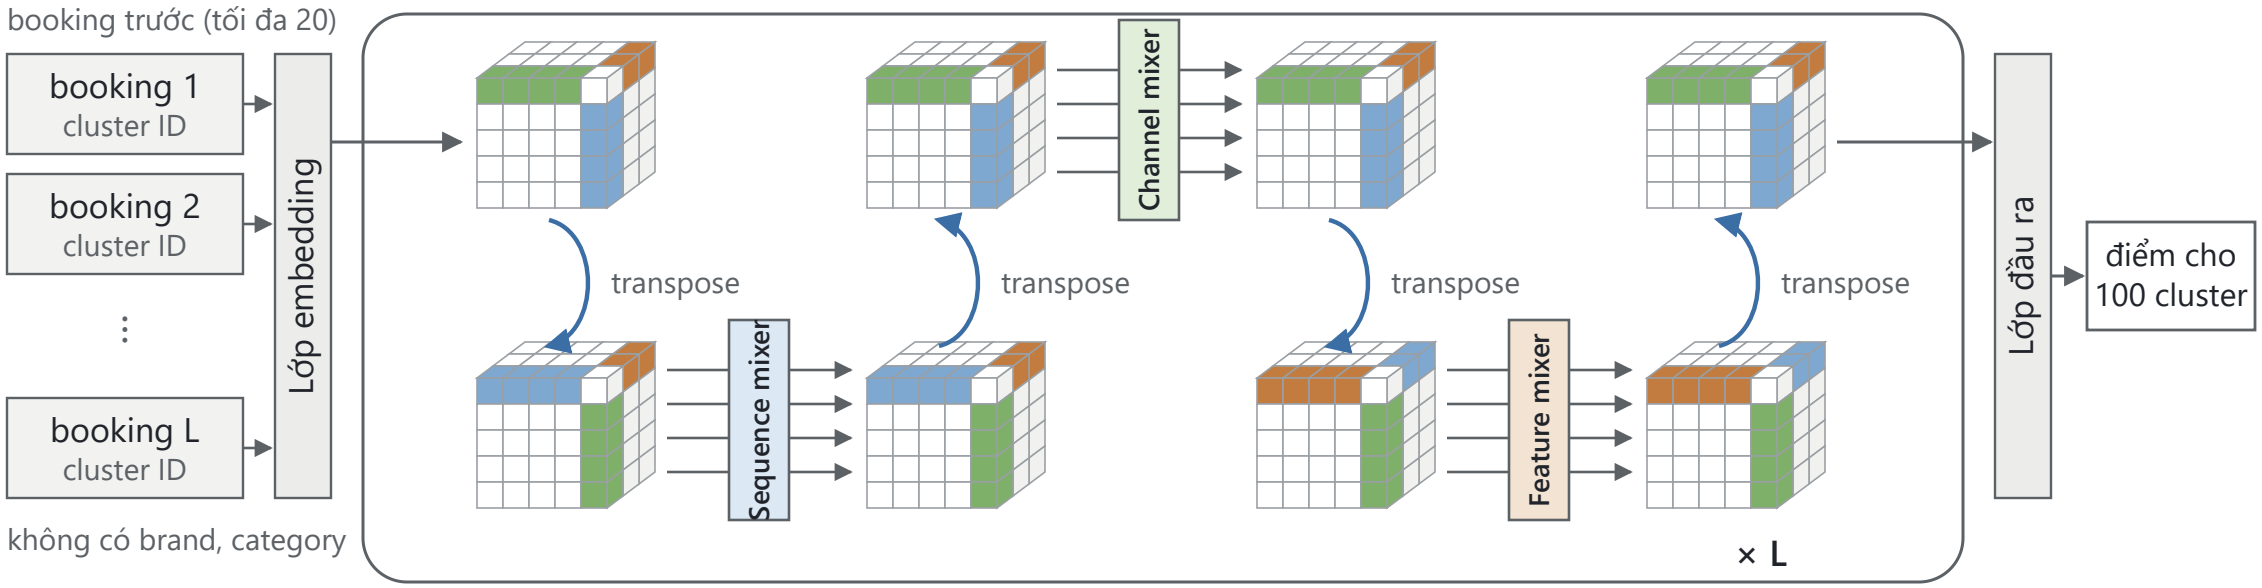
Booking của user đã có lịch sử (warm), theo cluster so với lịch sử của user



Các hướng tiếp cận của bài toán gợi ý

Hướng tiếp cận	Ý tưởng chính	Điểm mạnh	Điểm yếu
Content-based	Thuộc tính của item	Không cần dữ liệu user khác	Cần thuộc tính item; cluster chỉ là id ẩn danh
Collaborative filtering, matrix factorization	Ma trận user × item	Học sở thích chung của nhiều user	Cần nhiều booking mỗi user; bỏ qua ngữ cảnh
Graph-based	Đồ thị user – item	Khai thác quan hệ gián tiếp	Nặng tính toán; vẫn cần nhiều tương tác
Session-based	Chuỗi hành vi trong một phiên	Không cần lịch sử dài	Ít booking cùng phiên, ít tín hiệu
Sequential (SMLP4Rec)	**Thứ tự các booking trong toàn bộ lịch sử**	**Nắm bắt xu hướng đổi theo thời gian**	**Cần lịch sử đủ dài; bỏ qua tìm kiếm hiện tại**
Context-aware	Ngữ cảnh của lần tìm kiếm	Dùng được khi chưa có lịch sử	Phụ thuộc chất lượng các trường ngữ cảnh

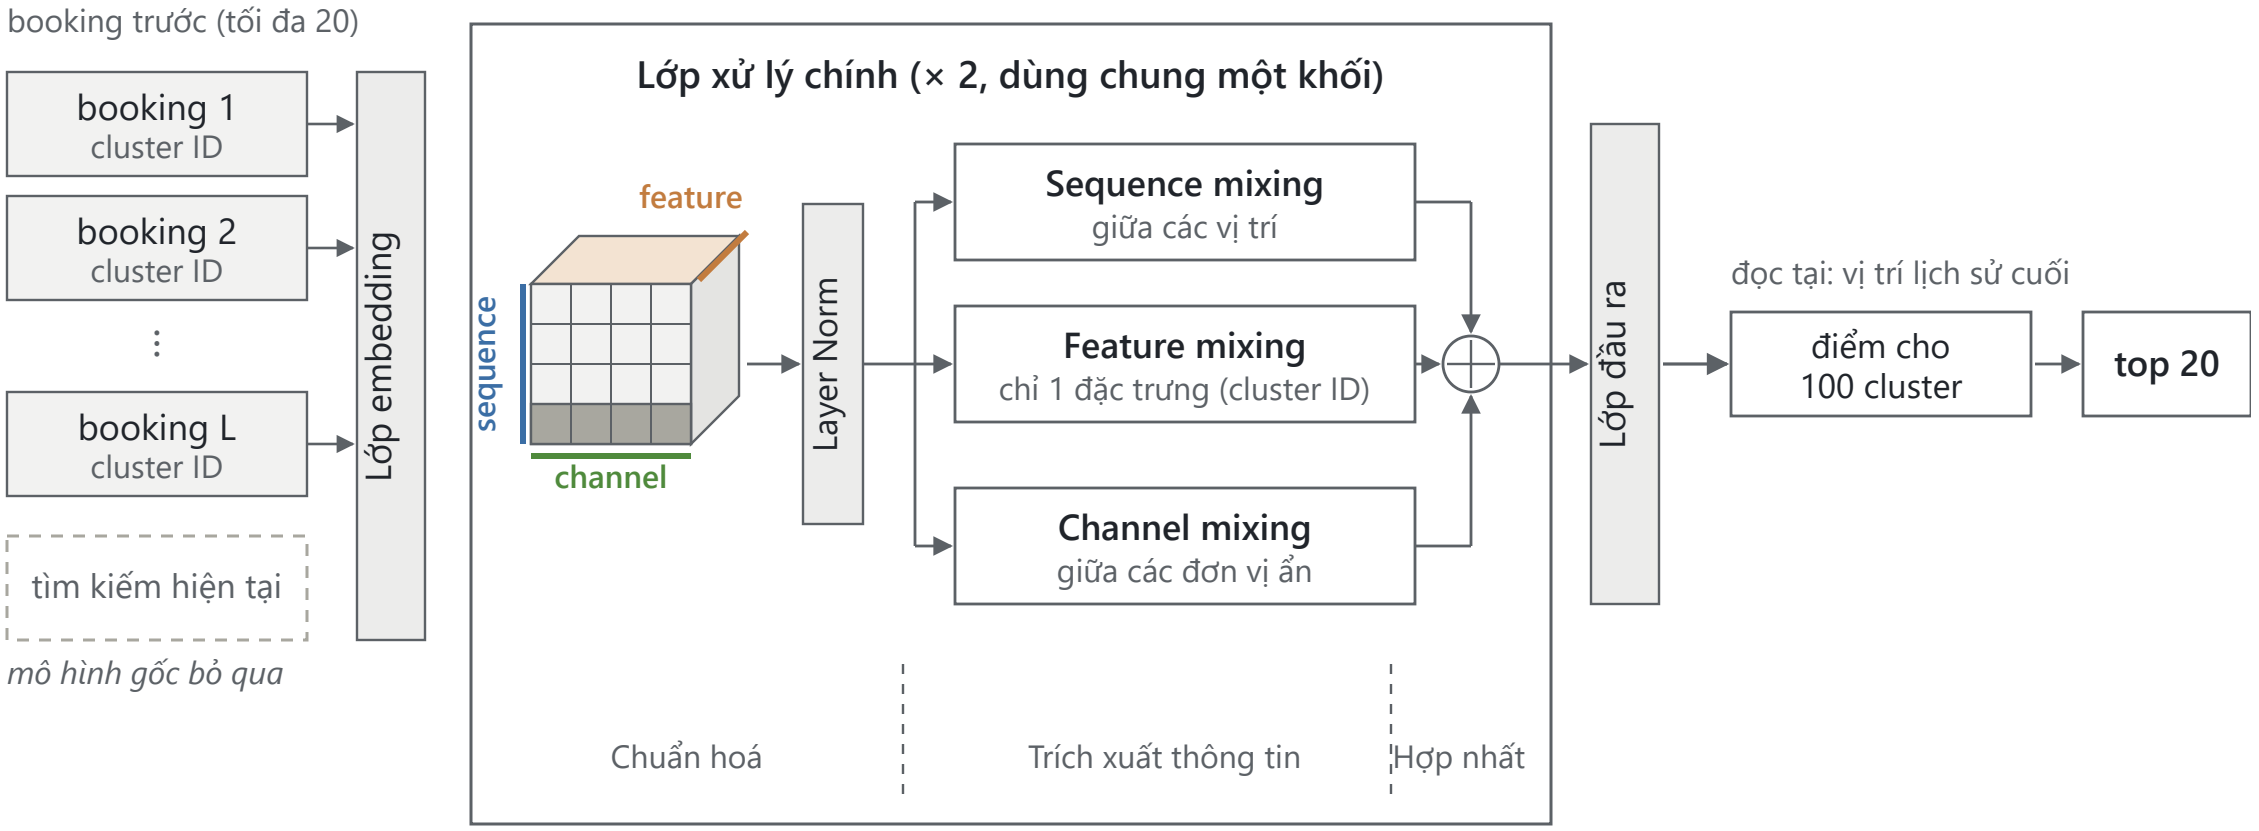
MLP4Rec và SMLP4Rec: phần kế thừa và phần cải tiến



Kế thừa từ MLP4Rec: chỉ dùng MLP, trộn thông tin theo ba hướng. Ba màu của khối là ba chiều: xanh dương sequence, xanh lá channel, cam feature; mỗi lần transpose, khối xoay để mixer nằm trên chiều cần trộn.

	MLP4Rec	SMLP4Rec	Mô hình chính của đề tài
Ba mixer (sequence, channel, feature)	nối tiếp	song song	song song (giữ của SMLP4Rec)
Lớp chuẩn hoá	nhiều lớp giữa các mixer	gộp, ít lớp hơn	giữ của SMLP4Rec
Đầu vào	ID và thuộc tính của item	ID và thuộc tính của item	chỉ cluster ID
Lần tìm kiếm hiện tại	không đọc	không đọc	query embedding, sameDest

SMLP4Rec gốc: chỉ đọc các booking trước, bỏ qua tìm kiếm hiện tại



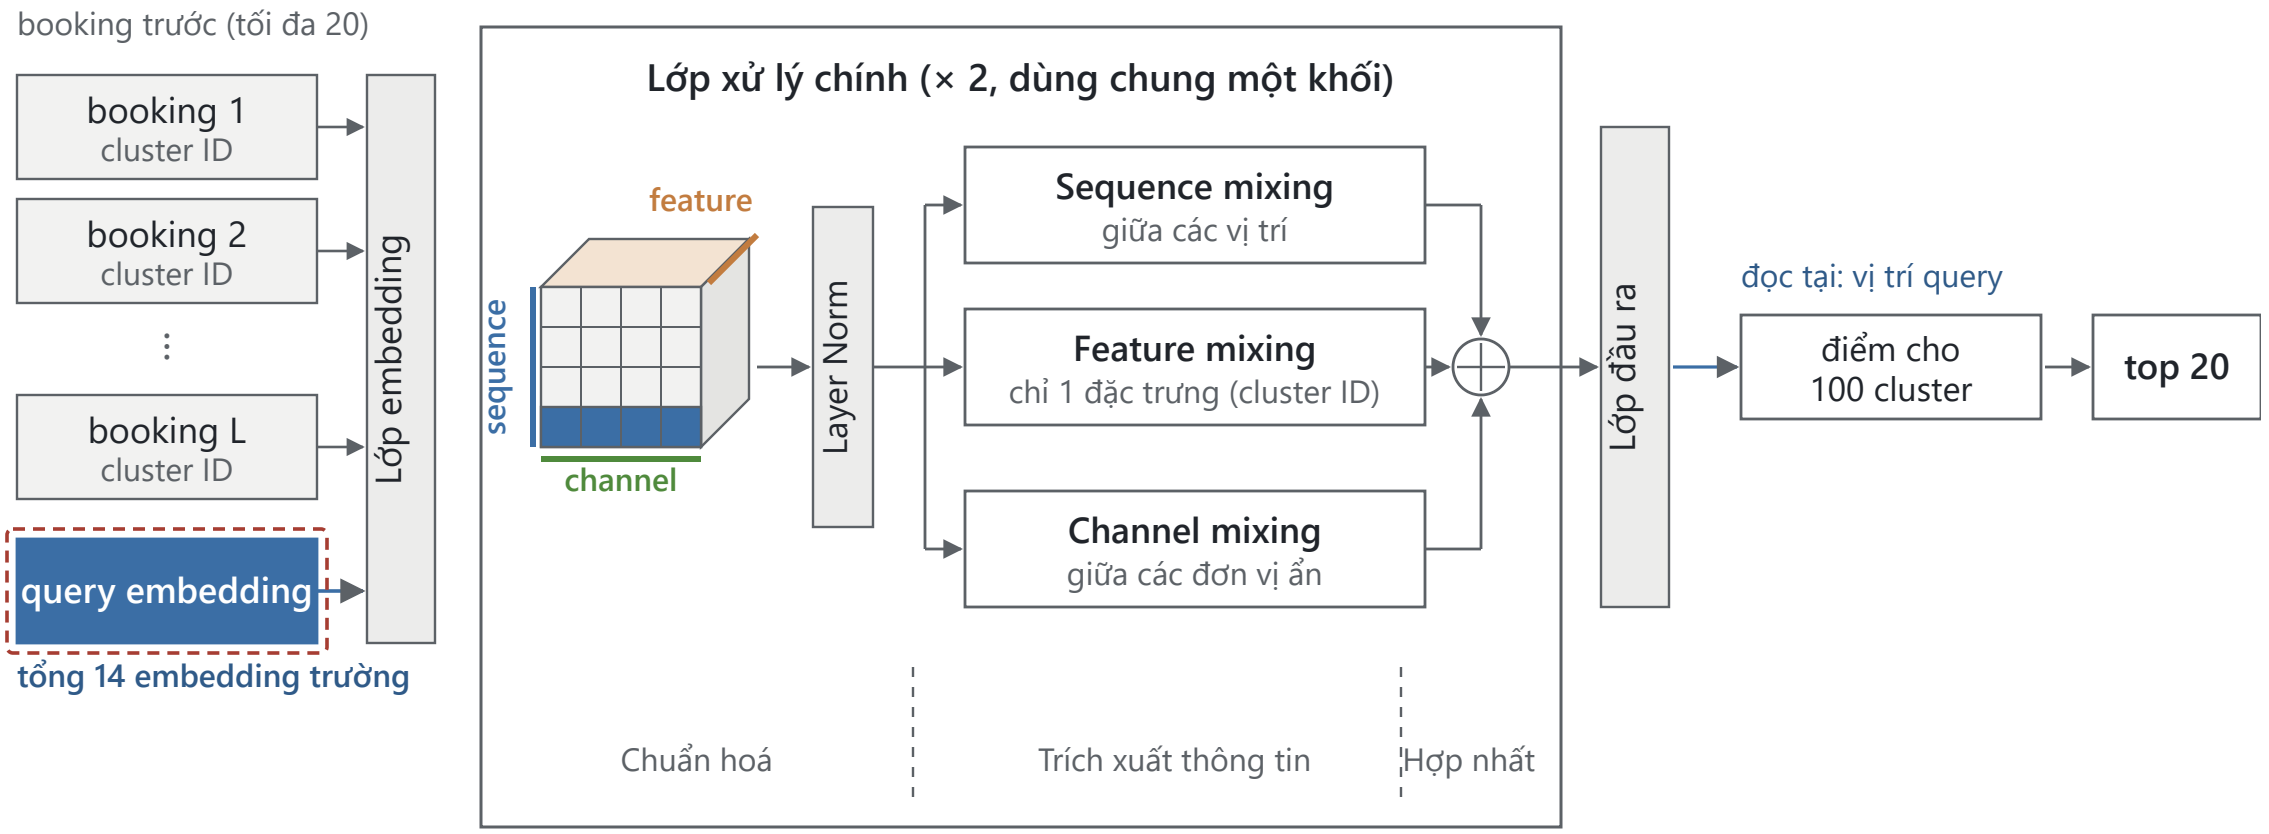
SMLP4Rec gốc nhỉnh hơn ItemKNN, hơn xa độ phổ biến toàn cục

Mô hình	NDCG@5	NDCG@10	NDCG@20	Recall@5	Recall@10	Recall@20
ItemKNN (chỉ lịch sử)	0.1462	0.1852	0.2330	0.1984	0.3096	0.4815
Độ phổ biến toàn cục	0.1020	0.1356	0.1774	0.1459	0.2425	0.3939
SMLP4Rec gốc (chỉ lịch sử)	**0.1519**	**0.1920**	**0.2385**	**0.2080**	**0.3224**	**0.4900**

Tập test: 222,428 user, mỗi user một danh sách top 20 cố định; số liệu là trung bình theo user, seed 2024.

Cách test và eval

Query embedding: đưa 14 trường tìm kiếm vào SMLP4Rec



[Phụ lục A1: Chi tiết về query embedding]

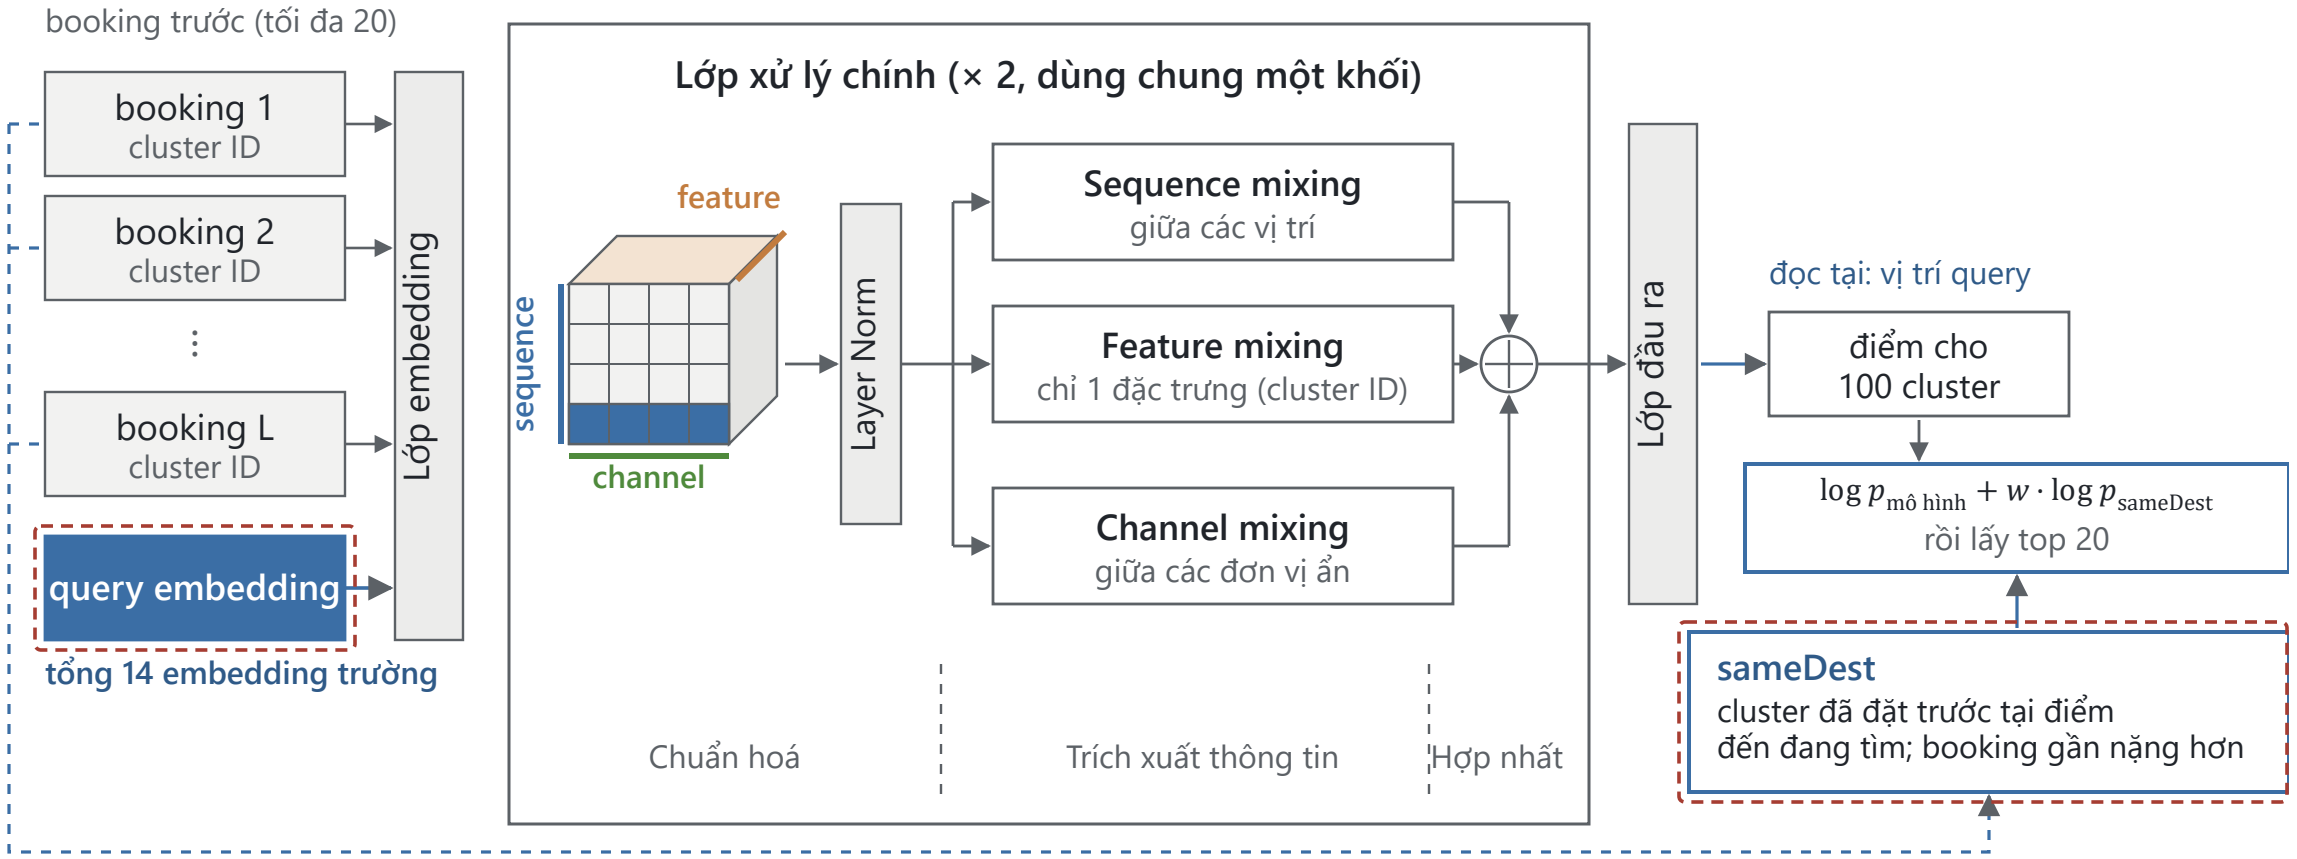
Thêm query embedding: SMLP4Rec vượt mọi mô hình trước đó

Mô hình	NDCG@5	NDCG@10	NDCG@20	Recall@5	Recall@10	Recall@20
ItemKNN (chỉ lịch sử)	0.1462	0.1852	0.2330	0.1984	0.3096	0.4815
Độ phổ biến toàn cục	0.1020	0.1356	0.1774	0.1459	0.2425	0.3939
SMLP4Rec gốc (chỉ lịch sử)	0.1519	0.1920	0.2385	0.2080	0.3224	0.4900
SMLP4Rec + query embedding	**0.3783**	**0.4426**	**0.4893**	**0.5113**	**0.6952**	**0.8590**

Tập test: 222,428 user, mỗi user một danh sách top 20 cố định; số liệu là trung bình theo user, seed 2024.

Cách test và eval

sameDest: bổ sung các booking cũ tại điểm đến đang tìm



Phụ lục A3: Chi tiết về sameDest

Thêm sameDest: mô hình chính dẫn đầu ở hầu hết các chỉ số

Mô hình	NDCG@5	NDCG@10	NDCG@20	Recall@5	Recall@10	Recall@20
ItemKNN (chỉ lịch sử)	0.1462	0.1852	0.2330	0.1984	0.3096	0.4815
Độ phổ biến toàn cục	0.1020	0.1356	0.1774	0.1459	0.2425	0.3939
SMLP4Rec gốc (chỉ lịch sử)	0.1519	0.1920	0.2385	0.2080	0.3224	0.4900
SMLP4Rec + query embedding	0.3783	0.4426	0.4893	0.5113	0.6952	0.8590
Mô hình chính (+ sameDest)	**0.3840**	**0.4474**	**0.4936**	**0.5154**	**0.6968**	**0.8588**

Tập test: 222,428 user, mỗi user một danh sách top 20 cố định; số liệu là trung bình theo user, seed 2024.

Cách test và eval

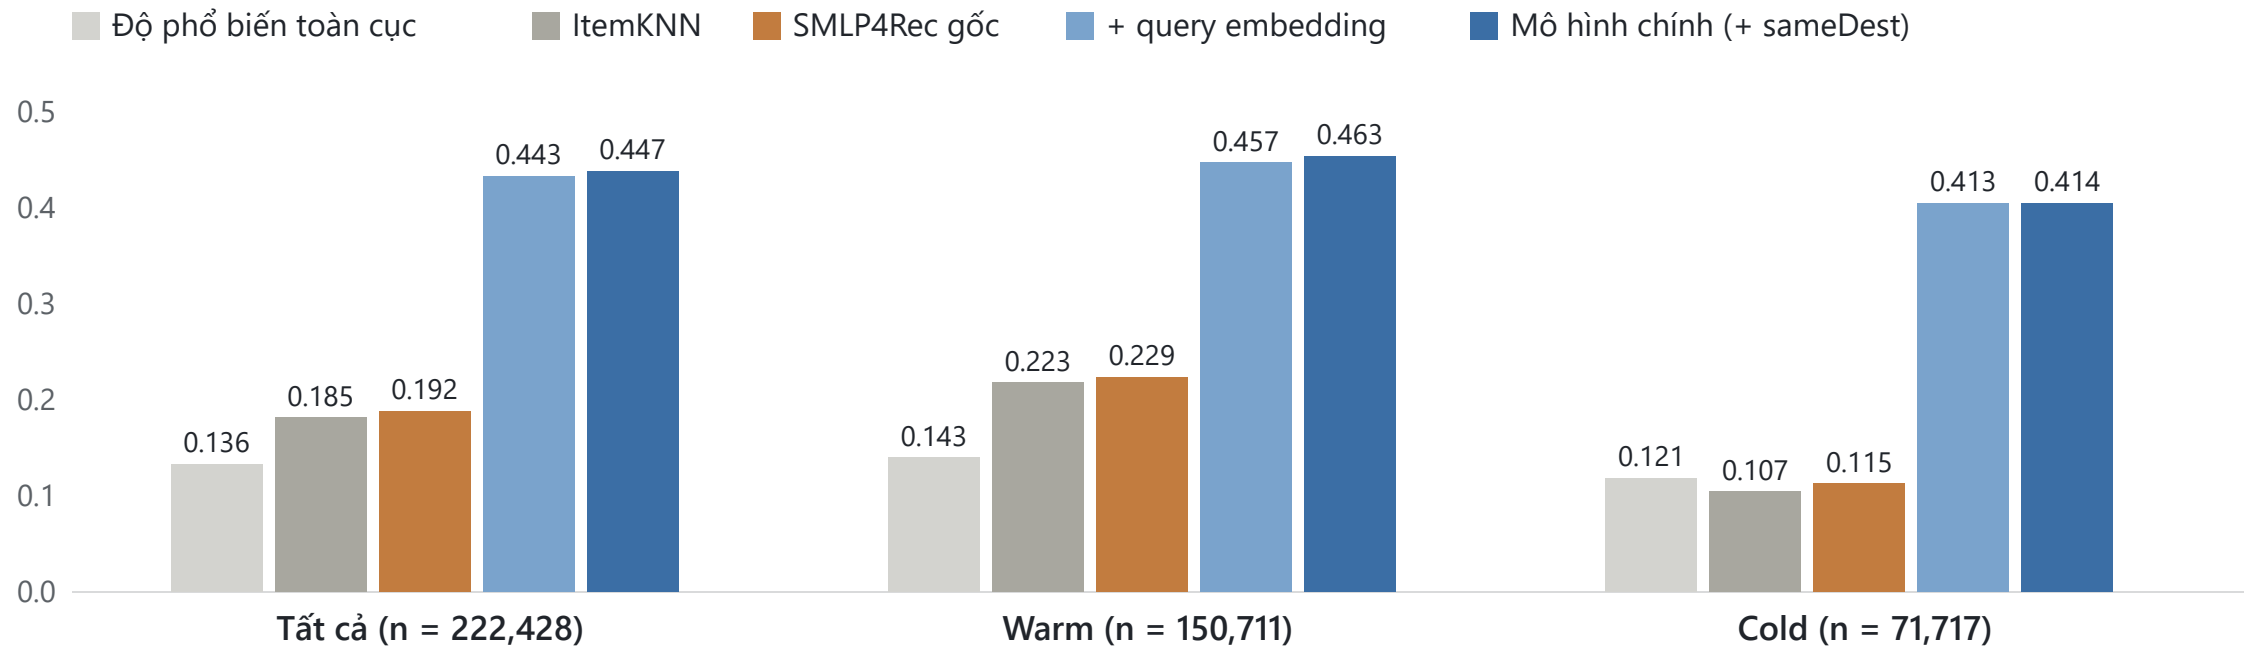
Mô hình chính theo tập user

Tập	n	NDCG@5	NDCG@10	NDCG@20	Recall@5	Recall@10	Recall@20
Tất cả user	**222,428**	**0.3840**	**0.4474**	**0.4936**	**0.5154**	**0.6968**	**0.8588**
User warm (đã có lịch sử)	150,711	0.4007	0.4635	0.5089	0.5288	0.7067	0.8637
User cold (chưa có lịch sử)	71,717	0.3490	0.4137	0.4614	0.4873	0.6758	0.8485

Cách test và eval

Các mô hình theo tập user

NDCG@10, tập test, trung bình theo user

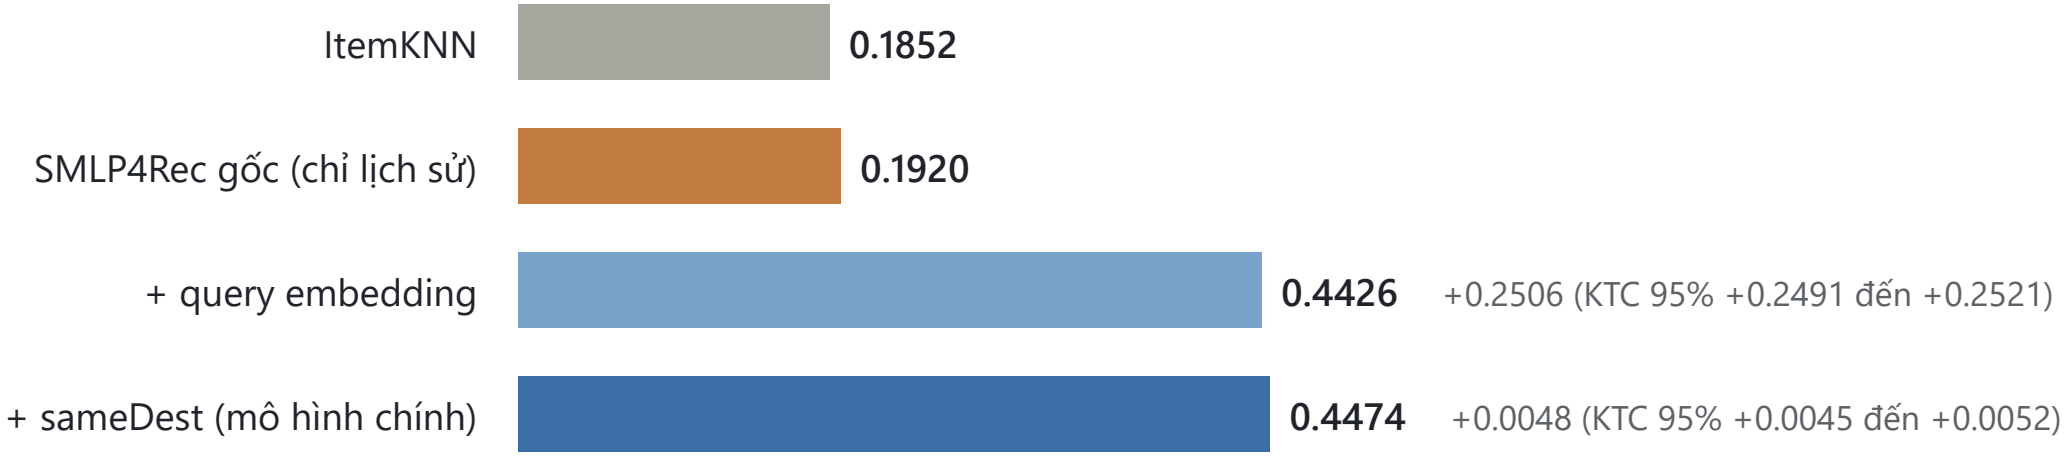


User cold: mô hình chính đạt 0.4137, ItemKNN 0.1066, độ phổ biến toàn cục 0.1208. Mô hình không dùng lịch sử vẫn xếp hạng tốt nhờ đọc lần tìm kiếm hiện tại.

[Cách test và eval]

Đóng góp của từng thành phần

NDCG@10, tập test, mọi user, trung bình theo user

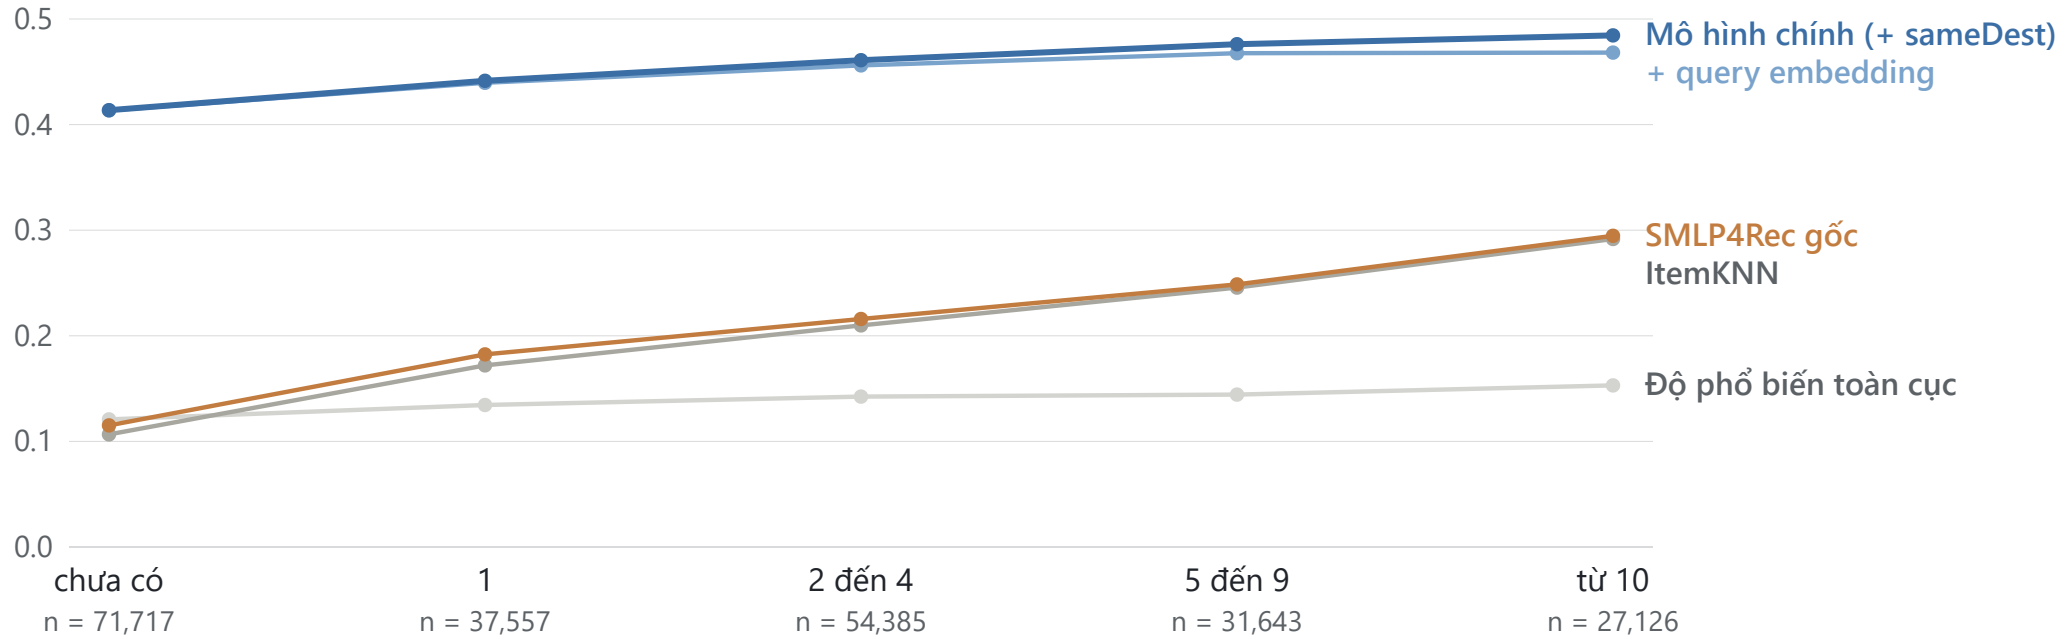


Query embedding đóng góp phần lớn mức tăng; sameDest thêm một bước nhỏ hơn nhưng có ý nghĩa. Mô hình chính hơn độ phổ biến toàn cục +0.3118 (KTC 95% +0.3102 đến +0.3133) và hơn ItemKNN +0.2622 (KTC 95% +0.2606 đến +0.2637).

Cách test và eval

Xu hướng theo số booking trước đó

NDCG@10 theo số booking trước đó của user (L), tập test, trung bình theo user



Mô hình chính tăng đều theo lịch sử, từ 0.4137 (chưa có) lên 0.4844 (từ 10 booking). Phần tăng của sameDest tập trung ở lịch sử dài: +0.0162 ở nhóm từ 10 booking, +0.0004 khi chưa có lịch sử.

Cách test và eval

Xu hướng theo mùa, loại đoàn khách, gói đặt

NDCG@10, tập test, trung bình theo user

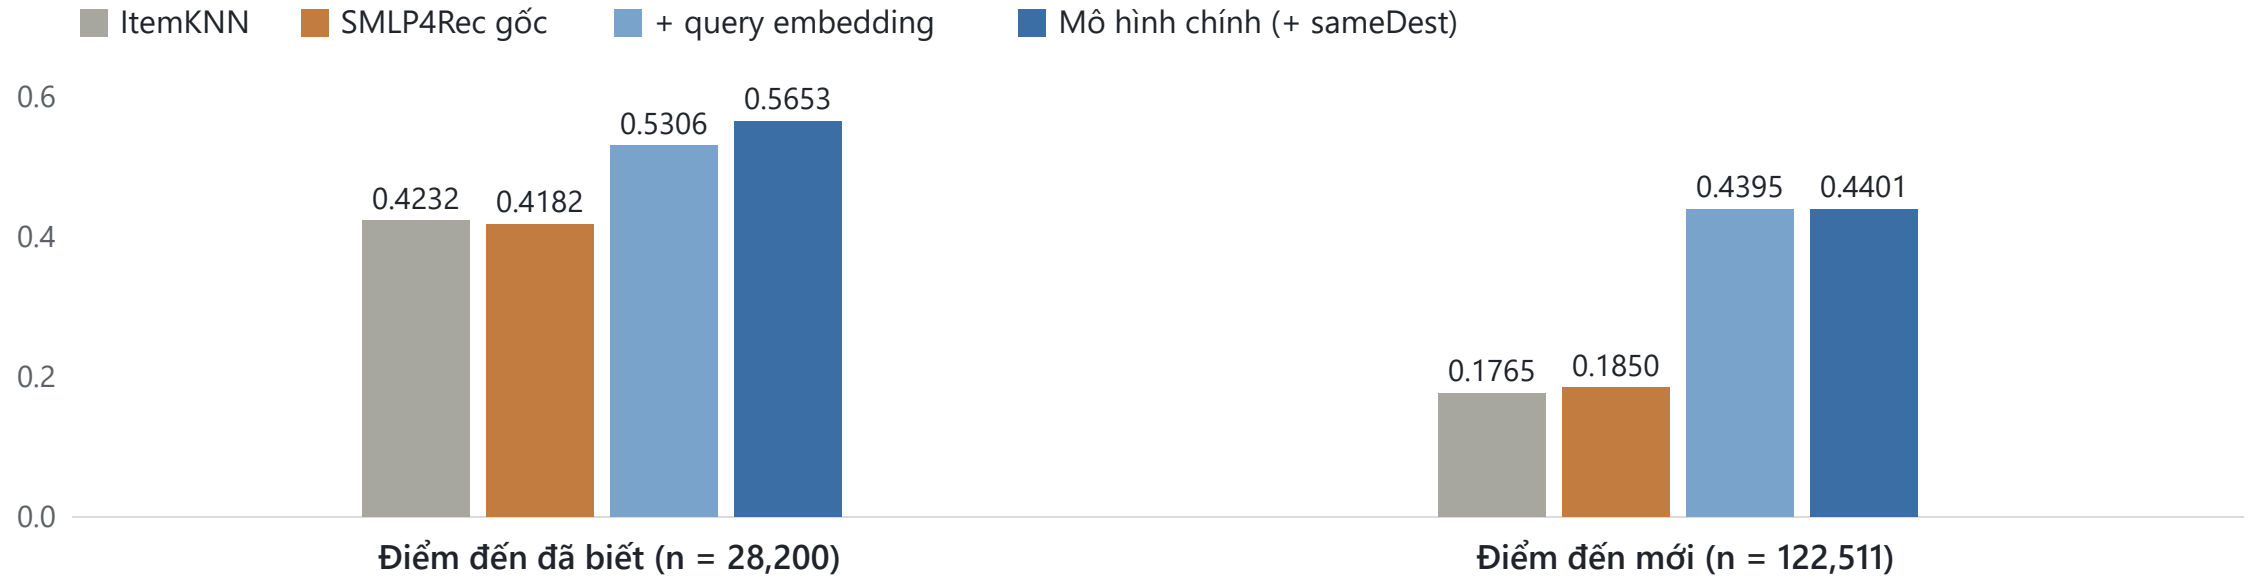
Nhóm	n	Độ phổ biến	ItemKNN	SMLP4Rec gốc	+ query embedding	Mô hình chính
Check-in tháng 11 đến 12	150,740	0.1520	0.2039	0.2114	0.4469	**0.4523**
Check-in tháng 1 đến 3	55,535	0.1027	0.1487	0.1544	0.4372	**0.4408**
Check-in tháng 4 đến 10	16,153	0.0962	0.1363	0.1406	0.4216	**0.4251**
solo	58,127	0.1399	0.2217	0.2277	0.4411	**0.4491**
couple	115,301	0.1270	0.1720	0.1788	0.4435	**0.4477**
family	29,705	0.1626	0.1744	0.1823	0.4462	**0.4482**
group	18,983	0.1340	0.1711	0.1790	0.4366	**0.4402**
Đặt kèm gói	32,013	0.0735	0.1326	0.1373	0.4564	**0.4602**
Không đặt kèm gói	190,415	0.1461	0.1941	0.2012	0.4403	**0.4453**

Mô hình chính dẫn đầu ở mọi nhóm: 0.4251 đến 0.4523 theo mùa, 0.4402 đến 0.4491 theo loại đoàn khách. Độ phổ biến toàn cục thấp nhất ở user đặt kèm gói (0.0735), mô hình chính cao nhất ở nhóm đó (0.4602).

Cách test và eval

Điểm đến đã biết và điểm đến mới

NDCG@10 trên user warm, tập test, trung bình theo user



Điểm đến đã biết (18.7% user warm): sameDest nâng NDCG@10 từ 0.5306 lên 0.5653 (+0.0347, KTC 95% +0.0323 đến +0.0371). Điểm đến mới: gần như không đổi (0.4395 và 0.4401).

Cách test và eval

Những điều rút ra từ kết quả

- Lần tìm kiếm hiện tại là tín hiệu chính: thêm query embedding nâng NDCG@10 từ 0.1920 lên 0.4426 (+0.2506). Lịch sử là phần bổ sung nhỏ hơn nhưng có thật: sameDest thêm +0.0048 (KTC 95% +0.0045 đến +0.0052).
- User chưa có lịch sử vẫn được xếp hạng tốt: NDCG@10 0.4137, so với 0.1066 của ItemKNN và 0.1208 của độ phổ biến toàn cục.
- Lịch sử càng dài mô hình chính càng tốt: 0.4137 khi chưa có lịch sử, 0.4844 từ 10 booking. Phần của sameDest tập trung ở user quay lại điểm đến cũ (+0.0347 ở điểm đến đã biết, gần như không đổi ở điểm đến mới).
- Mô hình chính dẫn đầu ở mọi mùa, loại đoàn khách và nhóm gói đặt đã xét; mức thấp nhất (0.4251) vẫn gấp hơn ba lần độ phổ biến toàn cục (0.1356 trên toàn tập test).

Phụ lục A1. 14 trường của query embedding, đều thuộc lần tìm kiếm

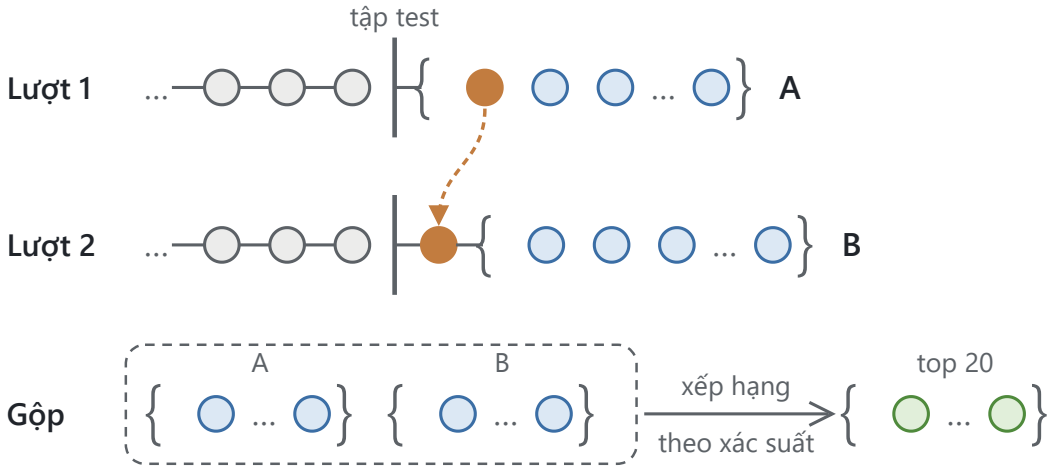
Trường	Ý nghĩa	Cách mã hóa	Số giá trị
`dest`	Điểm đến đang tìm (srch_destination_id)	id gốc; điểm đến có dưới 5 booking ở train thành "ngoài từ vựng"	14,711
`dest_type`	Loại điểm đến	id gốc	9
`ci_month`	Tháng check-in	1 đến 12; 0 = không rõ	12
`lead`	Số ngày từ lúc tìm đến check-in	10 khoảng, từ 0 ngày đến từ 365 ngày; 0 = không rõ	11
`stay`	Số đêm lưu trú	0 đến 14 đêm, dài hơn gộp chung; 0 = không rõ	14
`adults`	Số người lớn	cắt ở 9; 0 = không rõ	10
`children`	Số trẻ em	cắt ở 9	10
`rooms`	Số phòng	cắt ở 8; 0 = không rõ	9
`package`	Đặt kèm gói (is_package)	0 hoặc 1	2
`mobile`	Tìm trên thiết bị di động	0 hoặc 1	2
`channel`	Kênh tiếp thị	id gốc	11
`site`	Website Expedia (site_name)	id gốc	39
`posa`	Châu lục điểm bán	id gốc	5
`country`	Quốc gia của người dùng	id gốc; dưới 5 booking ở train thành "ngoài từ vựng"	216

← Quay lại slide 16

Phụ lục

Phụ lục A2. Cách test và eval

Mỗi user một danh sách top 20 cố định



Chấm điểm, K = 5, 10, 20

$$\text{Recall@K} = \frac{\left|\text{Top}_K \cap \text{Actual}\right|}{|\text{Actual}|}$$

$$\text{NDCG@K} = \frac{\text{DCG@K}}{\text{IDCG@K}}$$

$$\text{DCG@K} = \sum_{r=1}^{K} \frac{\text{rel}_r}{\log_2\left(r+1\right)}$$

$$\text{IDCG@K} = \sum_{r=1}^{\min\left(K, |\text{Actual}|\right)} \frac{1}{\log_2\left(r+1\right)}$$

Top$_5$ = { 7 **3** 12 40 **9** }

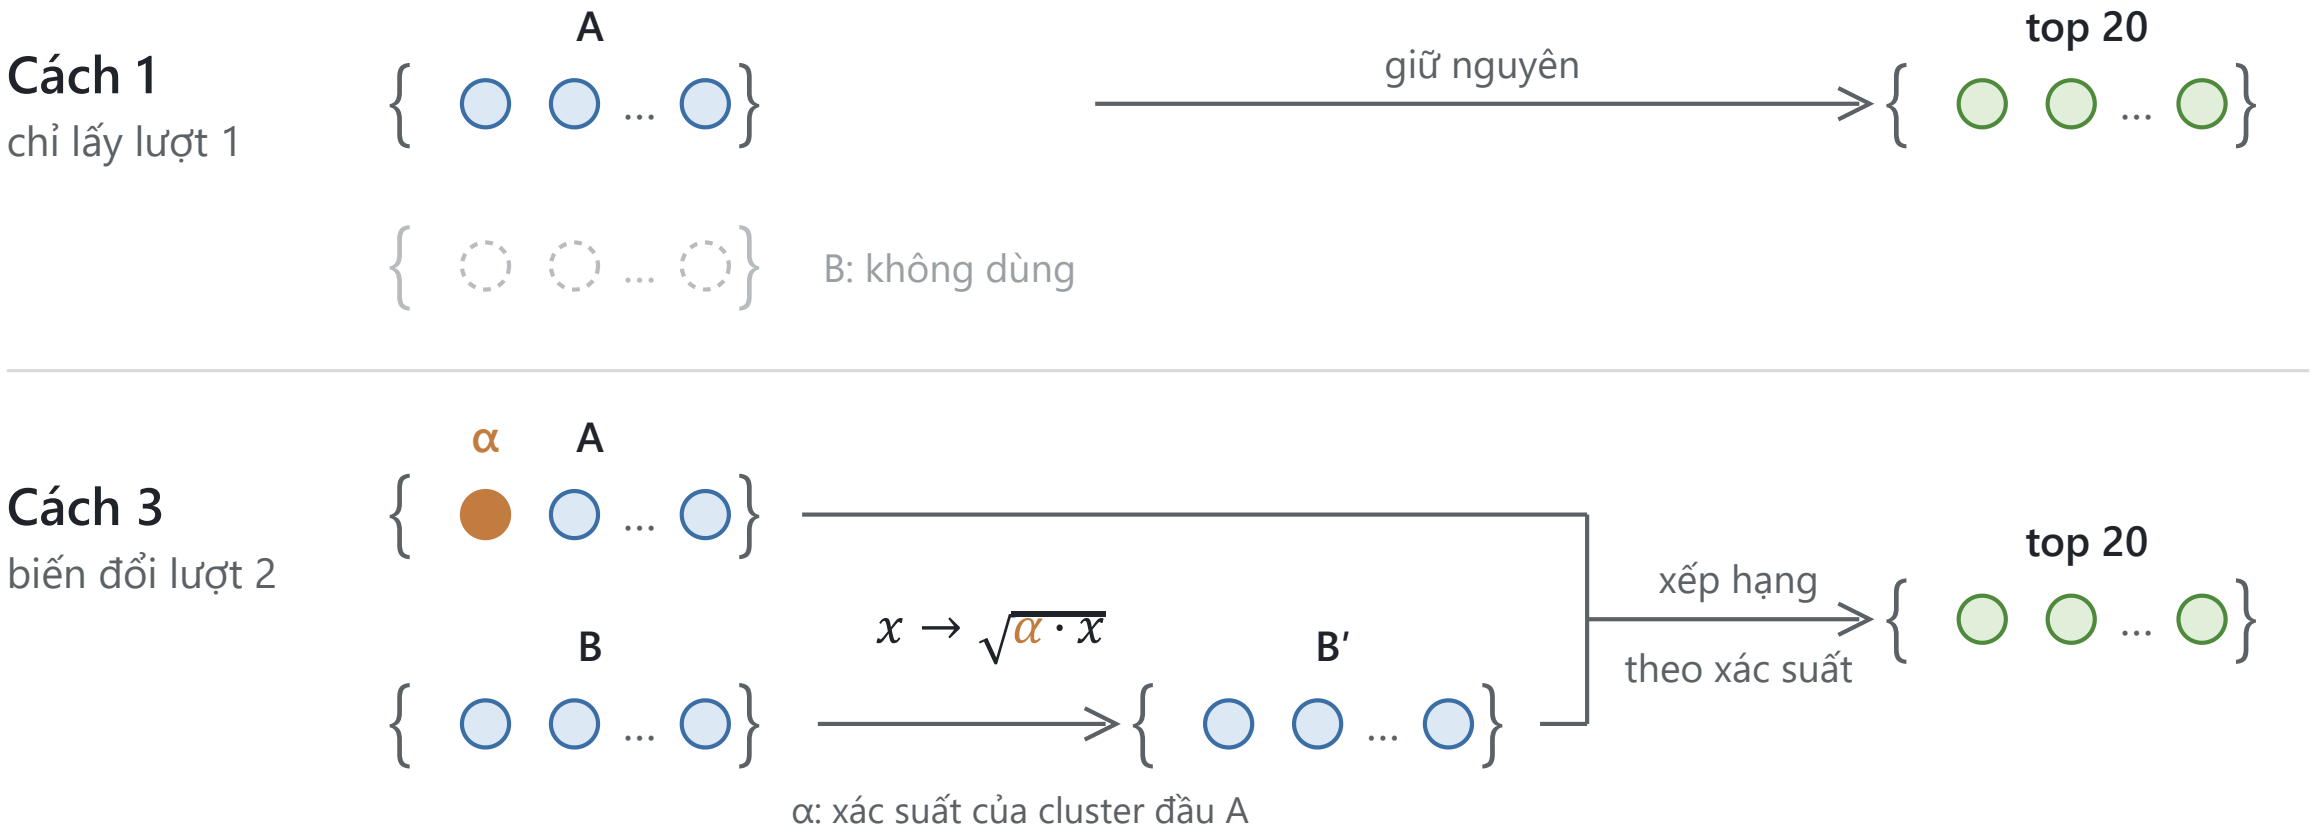
Actual = { **3** **9** 55 }

Đại lượng	Cách tính	Giá trị
Recall@5	$\frac{\lvert\{3,9\}\rvert}{\lvert\{3,9,55\}\rvert} = \frac{2}{3}$	0.667
DCG@5	$\frac{1}{\log_2\left(2+1\right)} + \frac{1}{\log_2\left(5+1\right)}$	1.018
IDCG@5	$\frac{1}{\log_2\left(1+1\right)} + \frac{1}{\log_2\left(2+1\right)} + \frac{1}{\log_2\left(3+1\right)}$	2.131
NDCG@5	$\frac{1.018}{2.131}$	**0.478**

← Quay lại

Phụ lục

Phụ lục A2.1. Hai cách gộp còn lại



← Quay lại

Phụ lục

Phụ lục A3. Công thức sameDest và điểm cuối cùng

B(*k*): các booking trước, tại điểm đến đang tìm, có cluster *k*. *p*: xác suất của mô hình.

$$\text{sameDest}(k) = \sum_{i \in B(k)} 0.7^{\text{lag}_i}$$

$$q_{\text{sameDest}}(k) = \frac{\text{sameDest}(k)}{\sum_j \text{sameDest}(j)}$$

$$q = (1-\alpha) \cdot p + \frac{\alpha}{100}$$

$$\text{điểm}(k) = \log q_{\text{mô hình}}(k) + w \cdot \log q_{\text{sameDest}}(k)$$

α = 0.1; w = 0.5 nếu điểm đến đã có trong lịch sử, w = 0 nếu không.

Ví dụ: lịch sử bốn booking, tìm kiếm tại điểm đến A (lag 0 = booking gần nhất).

Điểm đến	Cluster	Lag	Tính vào sameDest?	0.7^{lag}
A	7	3	có	0.343
B	9	2	không (khác điểm đến)	0
A	12	1	có	0.700
A	7	0	có	1.000

$$\text{sameDest}(7) = 0.7^3 + 0.7^0 = 0.343 + 1 = 1.343$$

$$\text{sameDest}(12) = 0.7^1 = 0.700$$

$$q_{\text{sameDest}}(7) = \frac{1.343}{1.343 + 0.700} = \frac{1.343}{2.043} = 0.657$$

$$q_{\text{sameDest}}(12) = \frac{0.700}{1.343 + 0.700} = \frac{0.700}{2.043} = 0.343$$

← Quay lại slide 18

Phụ lục