Gợi ý đặt phòng khách sạn trên Expedia

Next-best-product recommendation cho du lịch khách sạn

01 Bài toán

02 Dữ liệu

03 Hướng tiếp cận

04 Methodology

05 Thử nghiệm và cải tiến

06 Kết luận

Luồng tìm kiếm hiện tại của khách hàng



Giải pháp: Hệ gợi ý xếp hạng danh sách sản phẩm cá nhân hóa



Ăn uống, giải trí
user – món ăn, phim

Mua sắm
user – sản phẩm

Đề tài

Du lịch khách sạn
user – hạng phòng, gói

Đặc điểm của bài toán gợi ý trong du lịch – khách sạn

BÀI TOÁN NEXT-BEST-PRODUCT

Từ lịch sử tìm kiếm và đặt phòng của mỗi user, gợi ý top-K nhóm khách sạn (hotel cluster) user nhiều khả năng đặt ở lần tiếp theo.

Tần suất mua rất thấp

Khách chỉ đặt phòng 1–2 lần mỗi năm, nên tín hiệu tương tác giữa user và khách sạn cực thưa.

Ngữ cảnh chuyến đóng vai trò lớn

Đi một mình, cặp đôi, gia đình hay nhóm lớn: cùng một user nhưng nhu cầu đổi theo từng chuyến.

Hành vi mang tính khám phá

Mỗi chuyến thường là nơi đến, khách sạn mới; khách xem nhiều lựa chọn rồi mới đặt, nên cần gợi ý lựa chọn chưa từng đặt.

Cold-start phía user

User mới hoặc mới đặt 1–2 lần có quá ít lịch sử để model biết họ thích gì; chưa từng đặt thì chỉ gợi ý được theo độ phổ biến.

Mô hình cần học được từ tương tác rất thưa, tận dụng hành vi chung của nhiều user và vẫn gợi ý được cho user có ít lịch sử.

Bộ dữ liệu Expedia Hotel Recommendations

TOÀN BỘ FILE TRAIN.CSV

37.670.293 dòng

07/01/2013 → 31/12/2014

Click · 34.669.600 · 92,0% | **Booking · 3.000.693 · 8,0%**

Click không dùng làm nhãn

USER

1.198.786

813.985 có đặt phòng

CẦN XẾP HẠNG

100 cluster

hotel_cluster, id ẩn danh

Bài toán trên dataset: với mỗi user, dự đoán hotel_cluster của lần đặt tiếp theo, xếp top-K trong 100 cluster.

7 nhóm cột

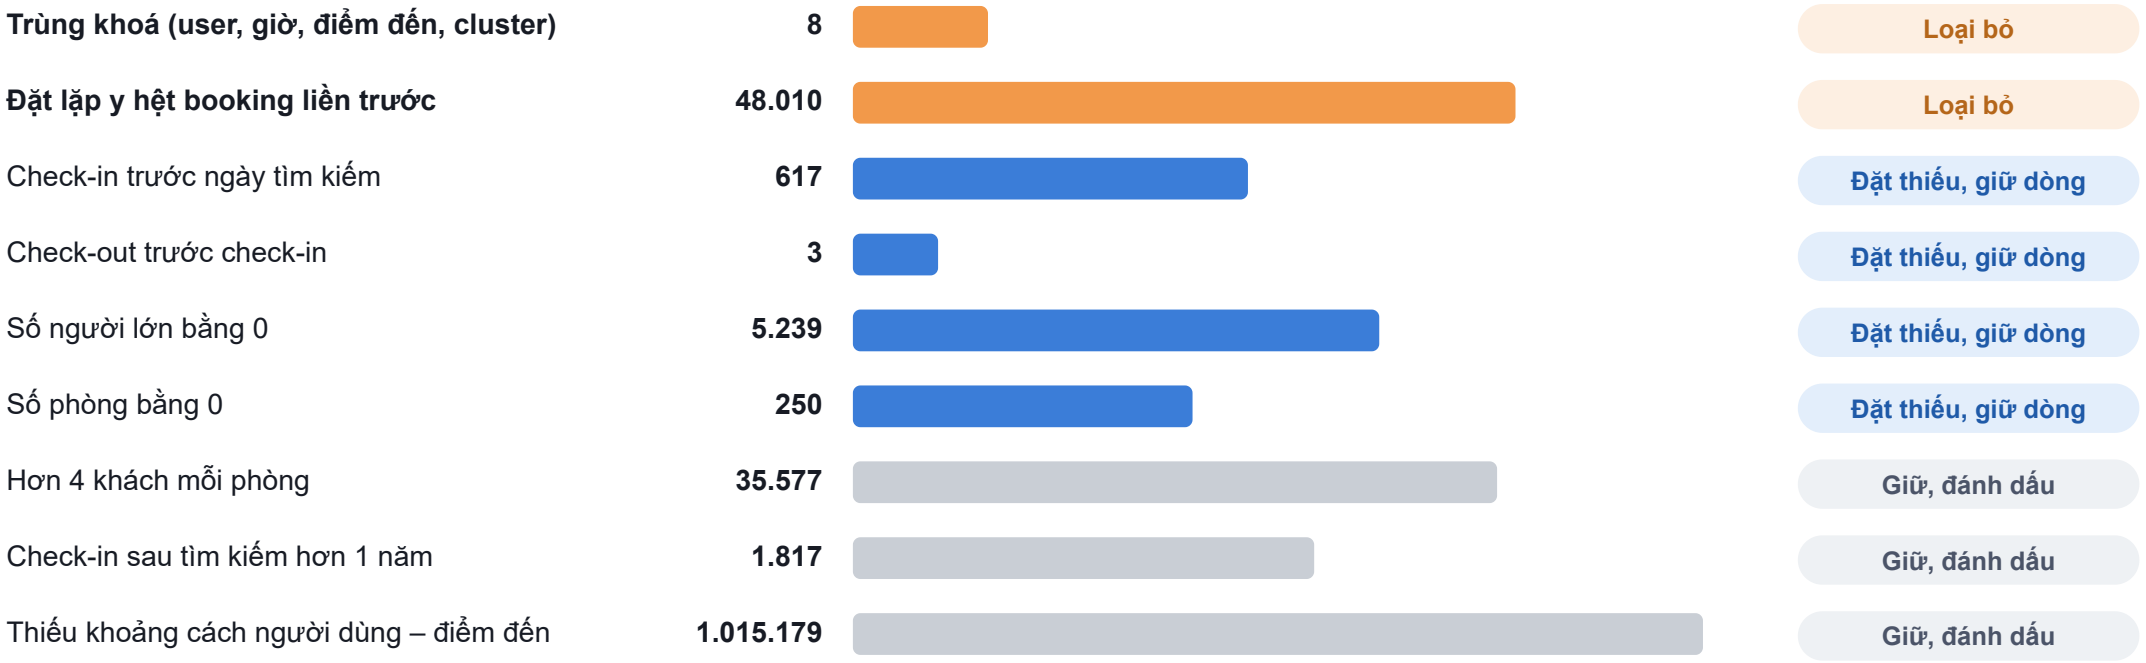
lần tìm kiếm | chứa nhãn

- **Tương tác, thời gian**
  cnt · date_time · is_booking
- **Người dùng**
  user_id
- **Ngữ cảnh chuyến đi**
  is_package · srch_adults_cnt · srch_children_cnt · srch_ci · srch_co · srch_rm_cnt
- **Tìm kiếm, điểm đến**
  srch_destination_id · srch_destination_type_id
- **Khách sạn, mục tiêu**
  hotel_cluster · hotel_continent · hotel_country · hotel_market
- **Vị trí người dùng**
  orig_destination_distance · user_location_city · user_location_country · user_location_region
- **Kênh, nền tảng**
  channel · is_mobile · posa_continent · site_name

Chất lượng dữ liệu

Số booking bị ảnh hưởng

thang log, trên 3.000.693 booking thô — loại bỏ; đặt thiếu, giữ dòng; giữ, đánh dấu

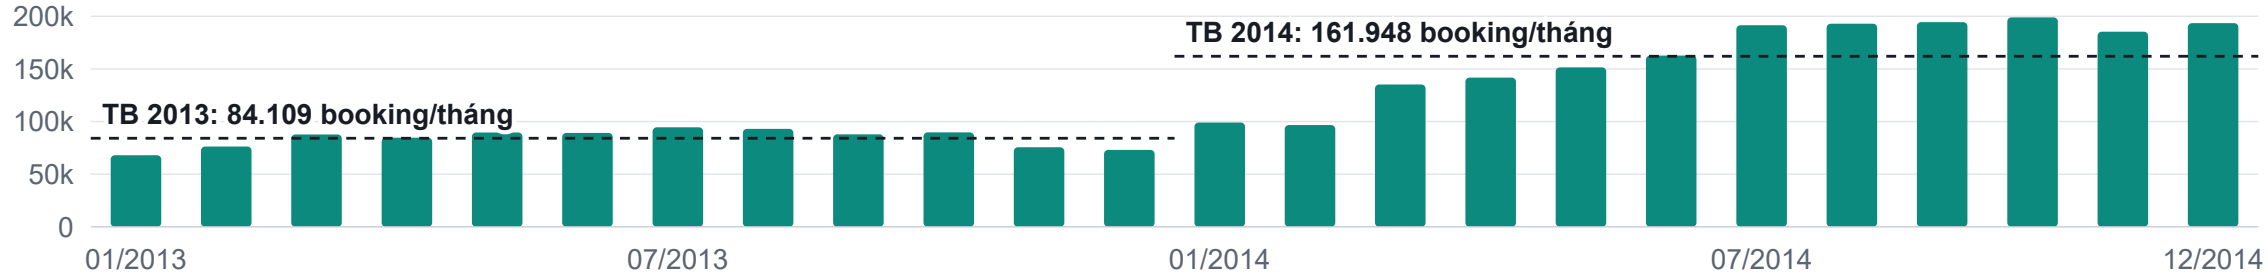


Chỉ **1,6% booking bị loại** (chủ yếu trùng lặp): dữ liệu đủ sạch để tin kết quả mô hình mà **không cần làm sạch nặng**.

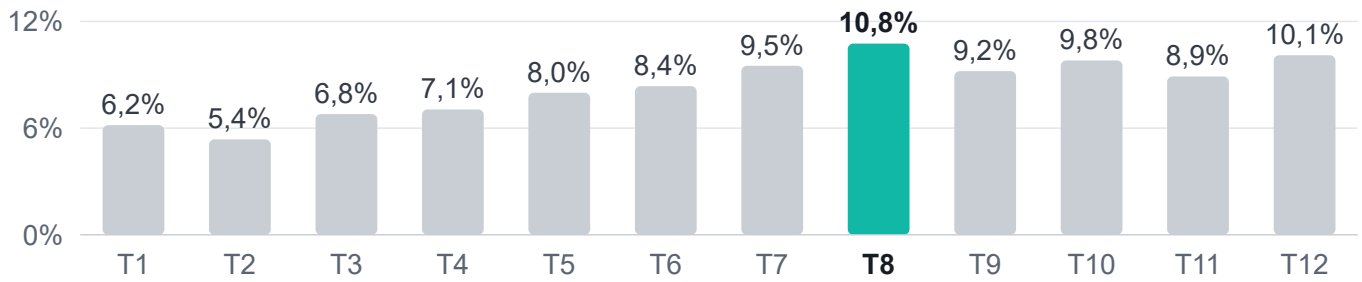
Khoảng cách người dùng – điểm đến **thiếu ~1/3 dòng** nên không đưa vào đầu vào; các lỗi nhỏ khác **giữ dòng, đặt thiếu** để không mất booking.

Quy mô và mùa vụ của booking

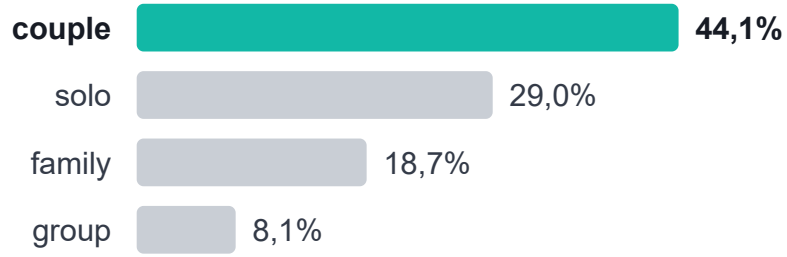
Số booking mỗi tháng (train.csv, đã bỏ booking trùng)



Tỷ lệ booking theo tháng check-in



Tỷ lệ booking theo nhóm khách



Nhóm khách: couple 2 người lớn · solo 1 người lớn · family có trẻ em · group từ 3 người lớn (không có trẻ em)

Booking mỗi tháng **gần gấp đôi** từ 2013 sang 2014 (84 nghìn → 162 nghìn): phân bố đổi theo thời gian, nên phải **chia tập theo thời gian** để đánh giá sát thực tế.

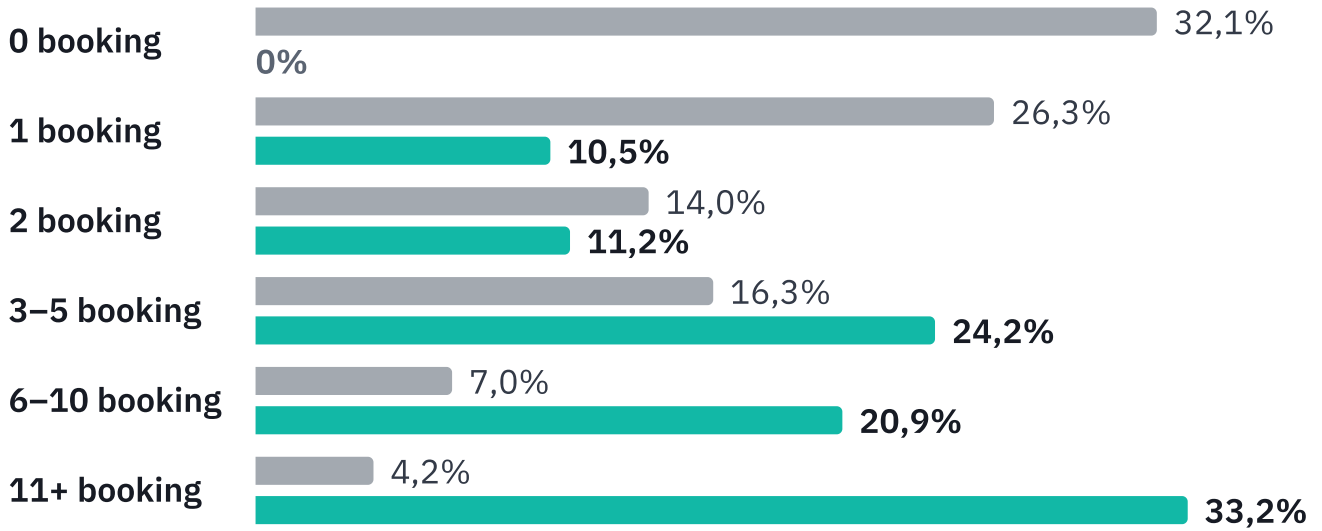
Check-in dồn vào **mùa hè** (T8 gấp đôi T2) và cặp đôi chiếm 44%: **thời điểm đi và loại nhóm khách** là những tín hiệu ngữ cảnh quan trọng.

Tần suất booking của khách hàng

8%
tỷ lệ booking so với click

58%
user có không quá 1 booking

32%
user chưa từng book



Phần lớn user chỉ có **0–1 booking**: lịch sử riêng của từng người **quá ít** để học chắc sở thích của họ.

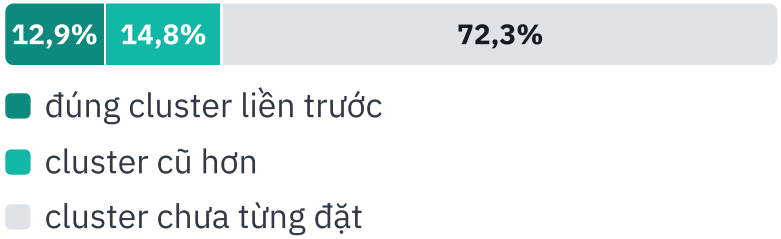
Chỉ **4,2% user** (từ 11 booking) tạo **33,2% booking**, trong khi 32% user chưa từng book: **không thể chỉ dựa vào lịch sử**, cần bổ sung thông tin khác.

Khách hàng và hành vi đặt lại

Đặt lại là hành vi phổ biến

27,7%

booking của user đã có lịch sử là đặt lại một cluster đã từng đặt

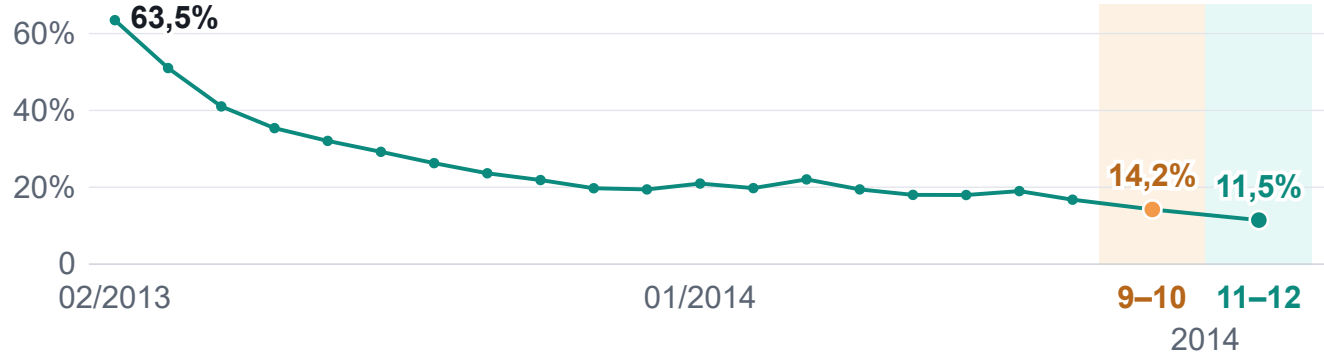


Tập user dần ổn định

89%

user hoạt động tháng 12/2014 đã xuất hiện từ các tháng trước

% user xuất hiện lần đầu theo tháng (9–10 và 11–12/2014: trung bình 2 tháng)



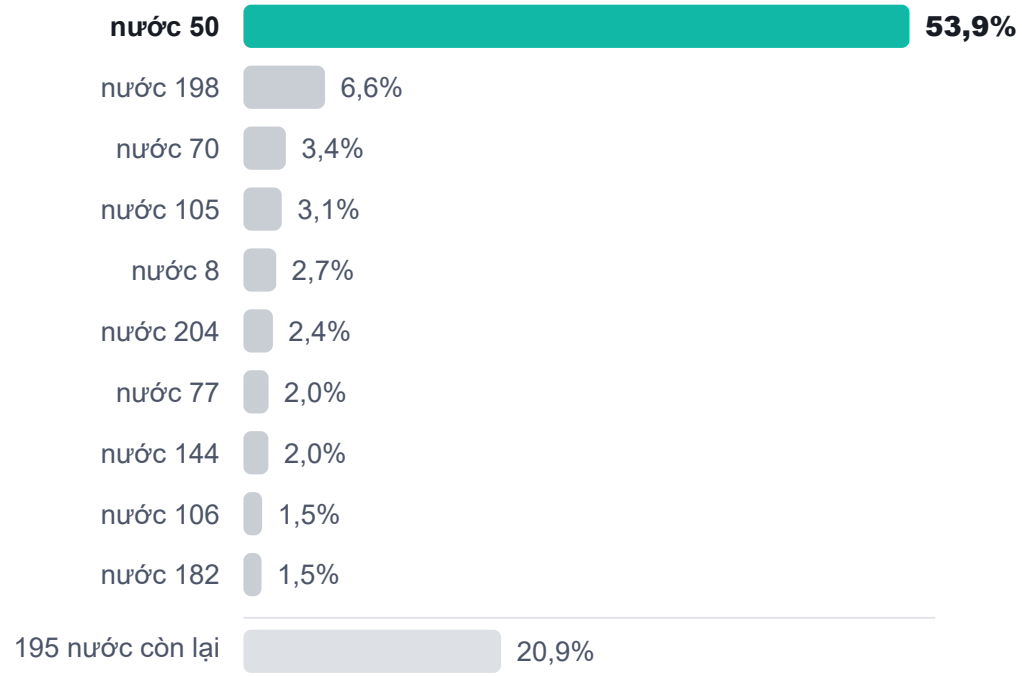
72% booking là cluster chưa từng đặt, nhưng 28% quay lại cluster cũ (gần một nửa là cluster liền trước): gợi ý phải **cân bằng giữa lặp lại và khám phá**.

Mỗi tháng cuối 2014 chỉ **khoảng 11–14% user xuất hiện lần đầu**: đa số user cần gợi ý đã có dấu vết để khai thác, nhưng vẫn còn nhóm user mới (cold-start).

Cluster và địa điểm

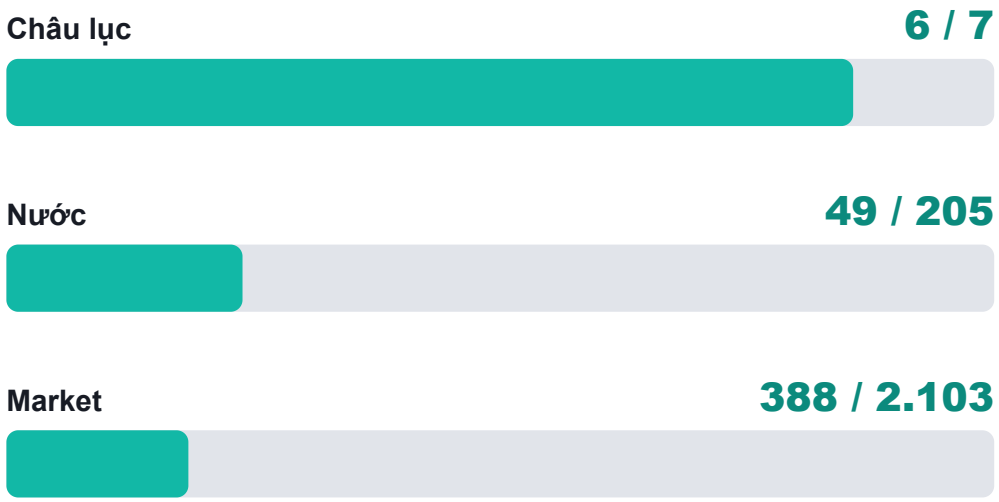
Tỷ trọng booking theo hotel country

10 nước đầu



Cluster có mặt ở bao nhiêu nơi

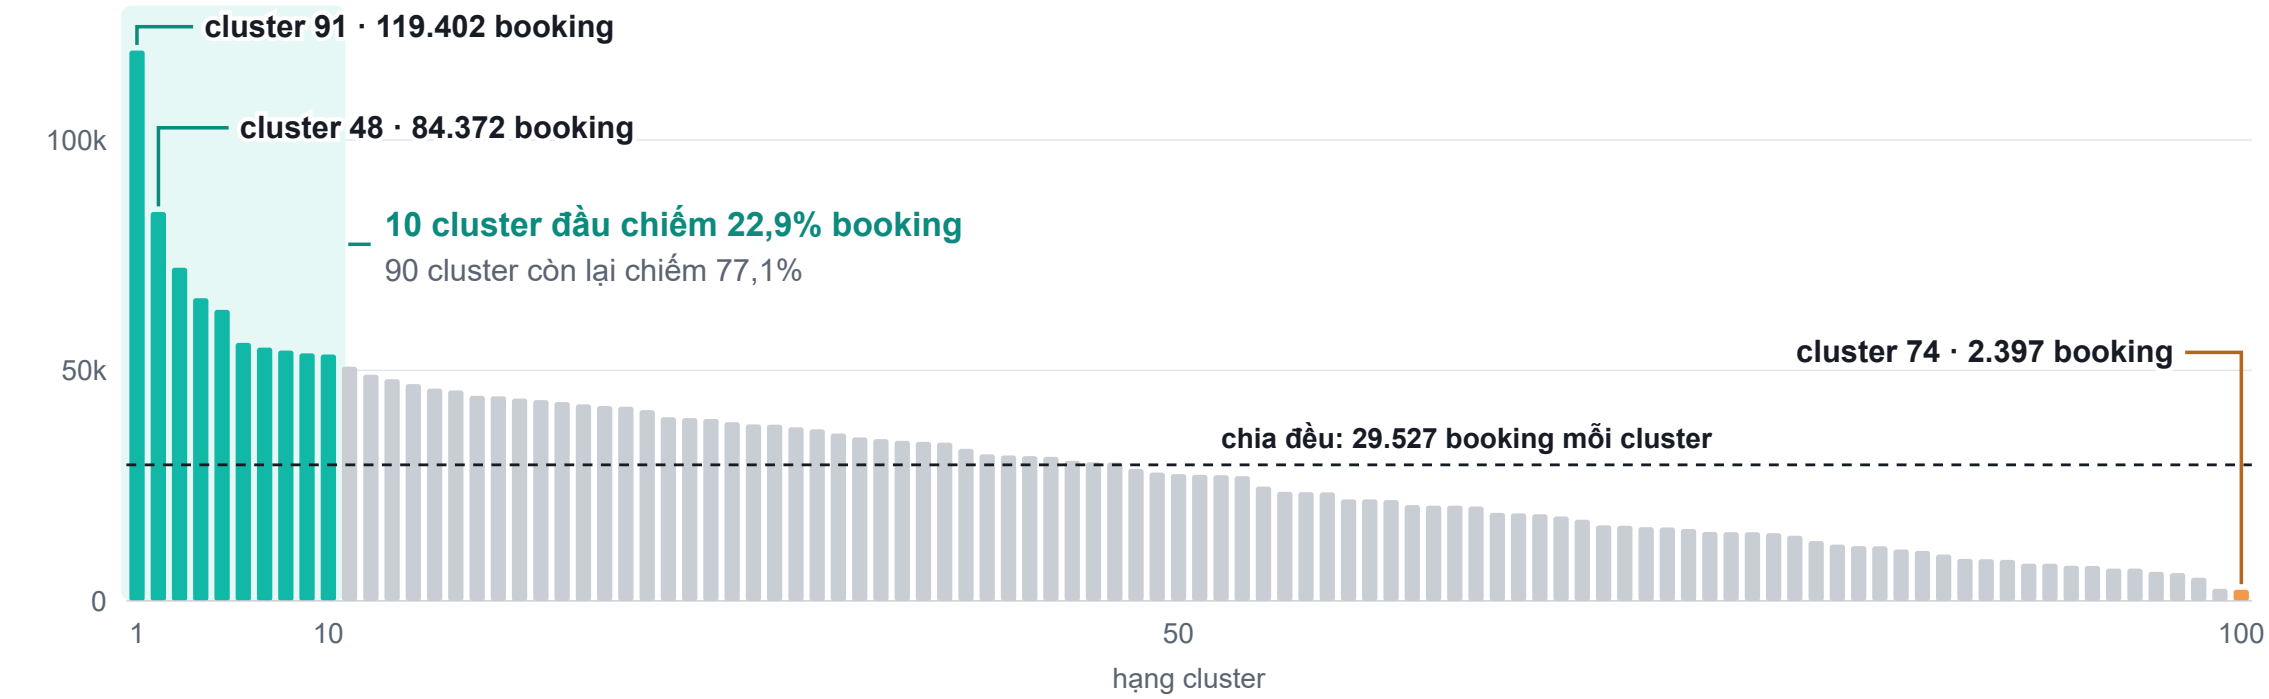
trung vị | tổng



Nước 50 chiếm **53,9% booking**: địa lý rất lệch, nên chỉ gợi ý theo điểm đến phổ biến sẽ **gần như giống nhau cho mọi khách**.

Mỗi cluster trải ở trung vị **49 nước và 388 market**: không suy được cluster từ địa điểm, mô hình phải **học từ hành vi và ngữ cảnh**.

Phân bố độ phổ biến của cluster



Booking **phân bố tương đối đều**: cluster đầu chỉ chiếm 4,0%, **10 cluster đầu chỉ 22,9%**, nên chỉ gợi ý cluster phổ biến là chưa đủ.

Cluster ít nhất vẫn có **hơn 2 nghìn booking**: độ thưa nằm ở **phía user**, không phải phía cluster, nên khó là học sở thích từng người.

Hướng tiếp cận

Content-based

Gợi ý item giống item khách đã chọn, dựa trên thuộc tính item

+ Không cần dữ liệu của khách khác
- Cần thuộc tính item đầy đủ

Collaborative filtering

Theo các khách có sở thích giống nhau (ma trận user × item)

+ Học sở thích chung của nhiều khách
- Cần nhiều tương tác; bỏ qua thứ tự và ngữ cảnh

Session-based

Theo chuỗi hành vi trong một phiên

+ Không cần lịch sử dài
- Ít tín hiệu trong phiên ngắn

Chọn

Sequential

Theo thứ tự các tương tác trong toàn bộ lịch sử

+ Nắm bắt xu hướng đổi theo thời gian
- Cần lịch sử đủ dài

Context-aware

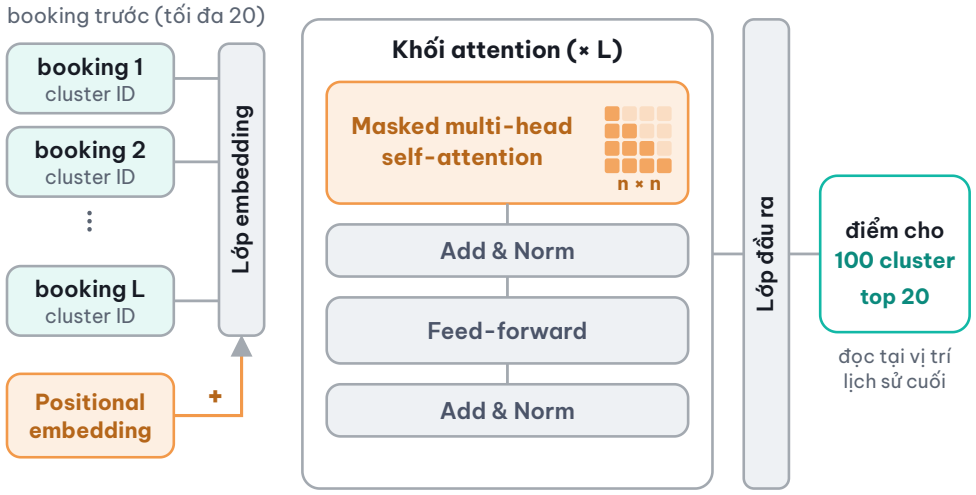
Theo ngữ cảnh của lần tìm kiếm hiện tại

+ Dùng được khi chưa có lịch sử
- Phụ thuộc chất lượng thông tin ngữ cảnh

Lịch sử mỏng nhưng vẫn có thứ tự: chọn **Sequential** làm nền, rồi bù phần thiếu bằng **ngữ cảnh lần tìm kiếm** ở cải tiến 1.

Từ attention đến MLP4Rec

Self-attention dạng SASRec

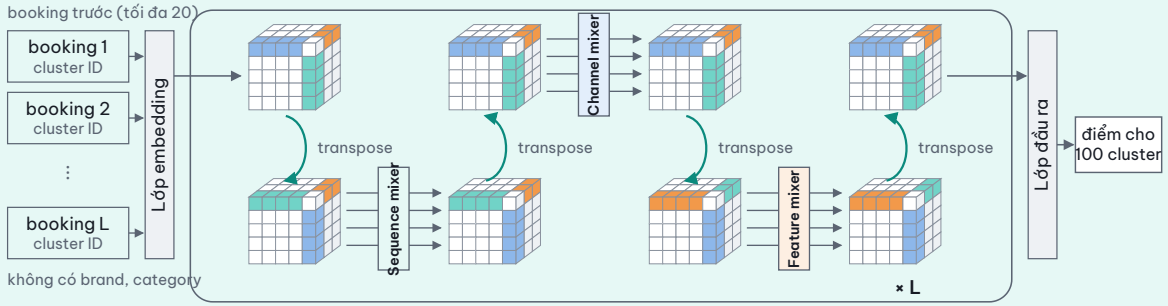


Cần positional embedding: dễ làm nhiễu item embedding

Chi phí bậc hai theo độ dài chuỗi

Nhiều tham số, dễ overfit

MLP4Rec thay attention bằng MLP

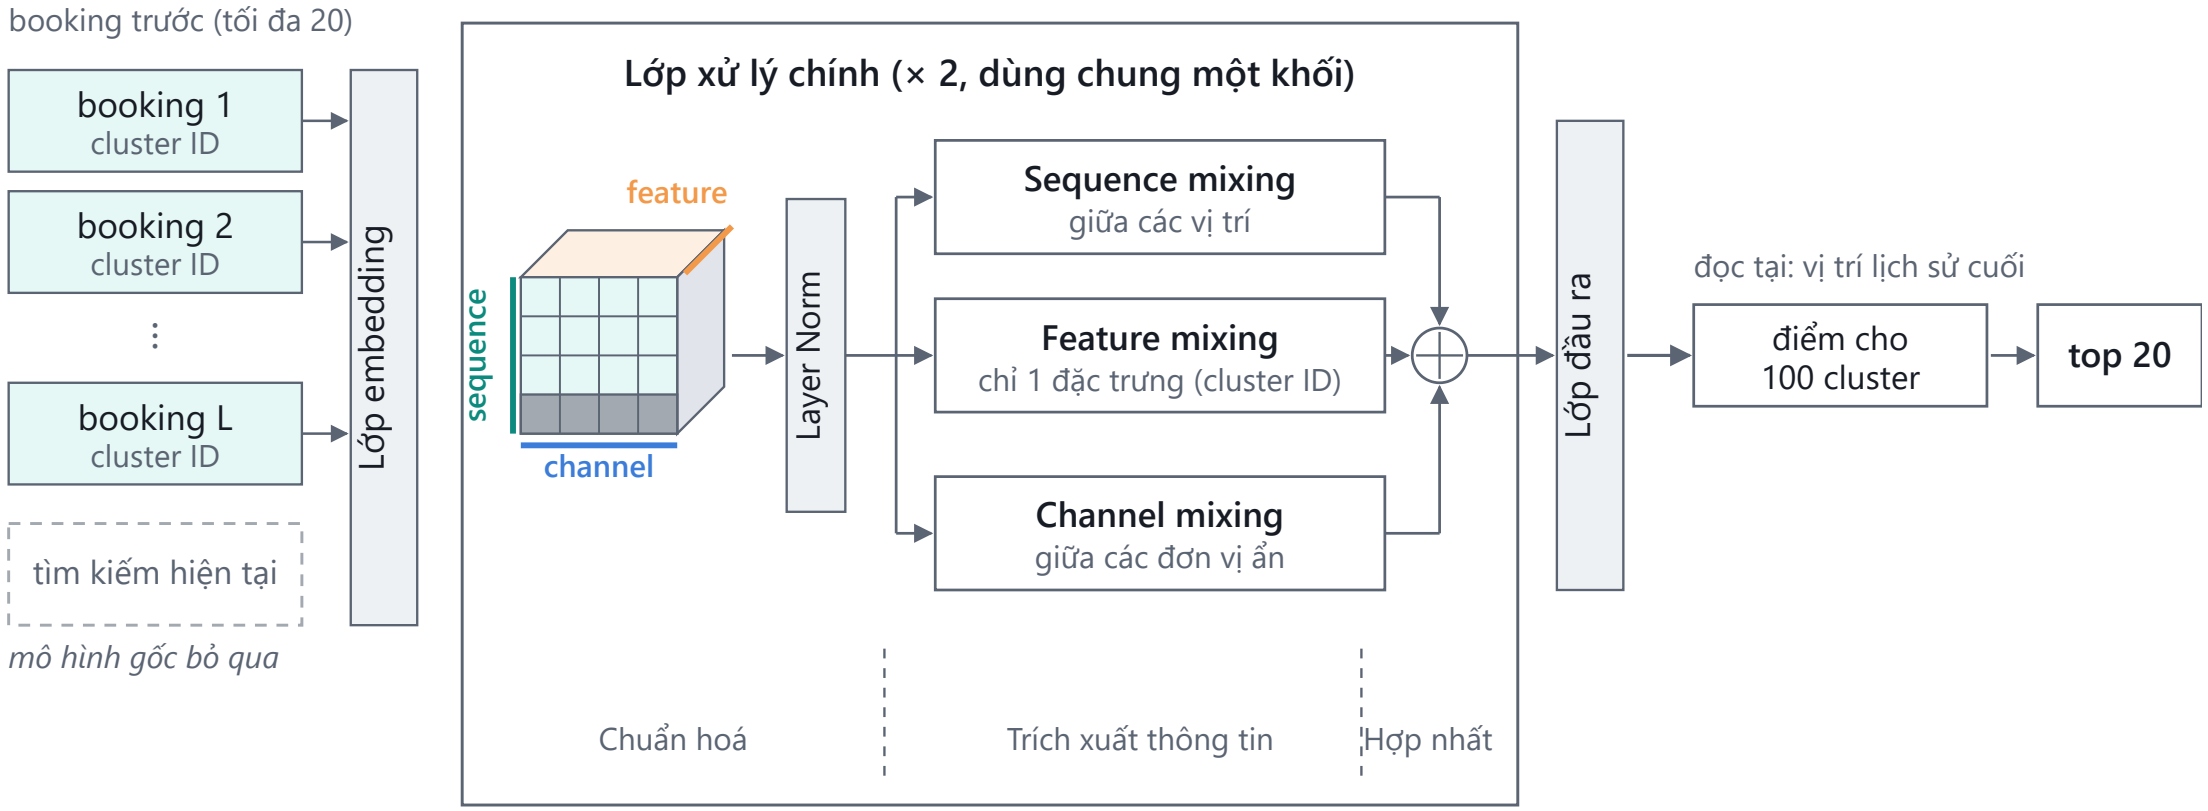


Nhạy thứ tự sẵn, không cần positional embedding

Chi phí tuyến tính, ít tham số

Hạn chế: mixer nối tiếp, nhiều lớp chuẩn hoá

SMLP4Rec

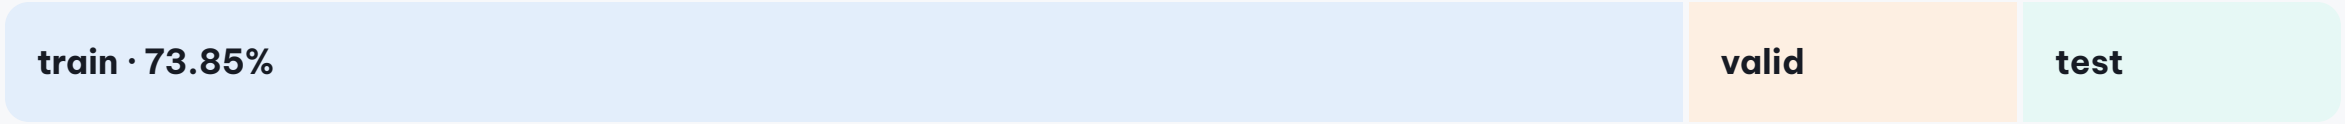


Khắc phục: song song, một Layer Norm

Còn thiếu: tìm kiếm hiện tại

Chia tập

CHIA THEO NGÀY ĐẶT PHÒNG (BOOKING DATE, KHÔNG PHẢI NGÀY CHECK-IN)



train
07/01/2013 – 31/08/2014

Booking	2,180,488 73.85%
User	664,727

valid
01/09 – 31/10/2014

Booking	393,399 13.32%
User	226,064

test
01/11 – 31/12/2014

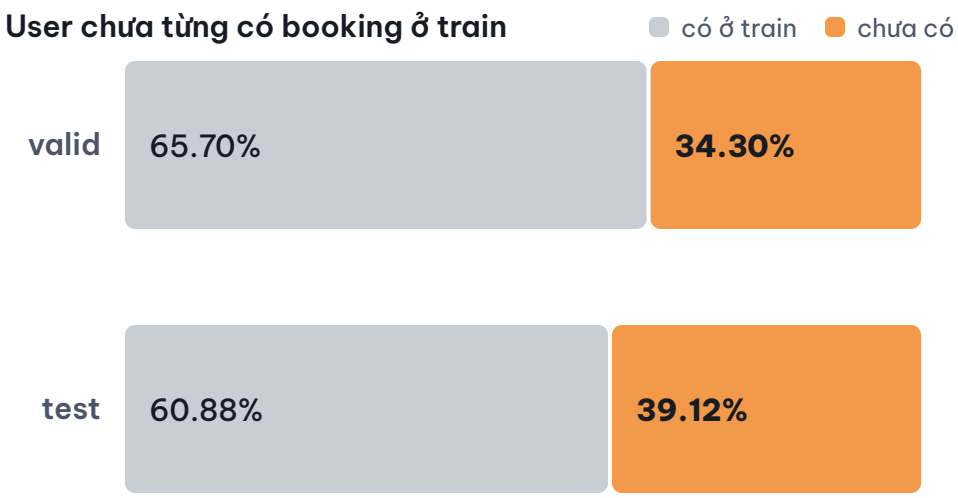
Booking	378,788 12.83%
User	222,428

Một user có thể thuộc nhiều tập

User tính trên 813,985 user của cả dataset

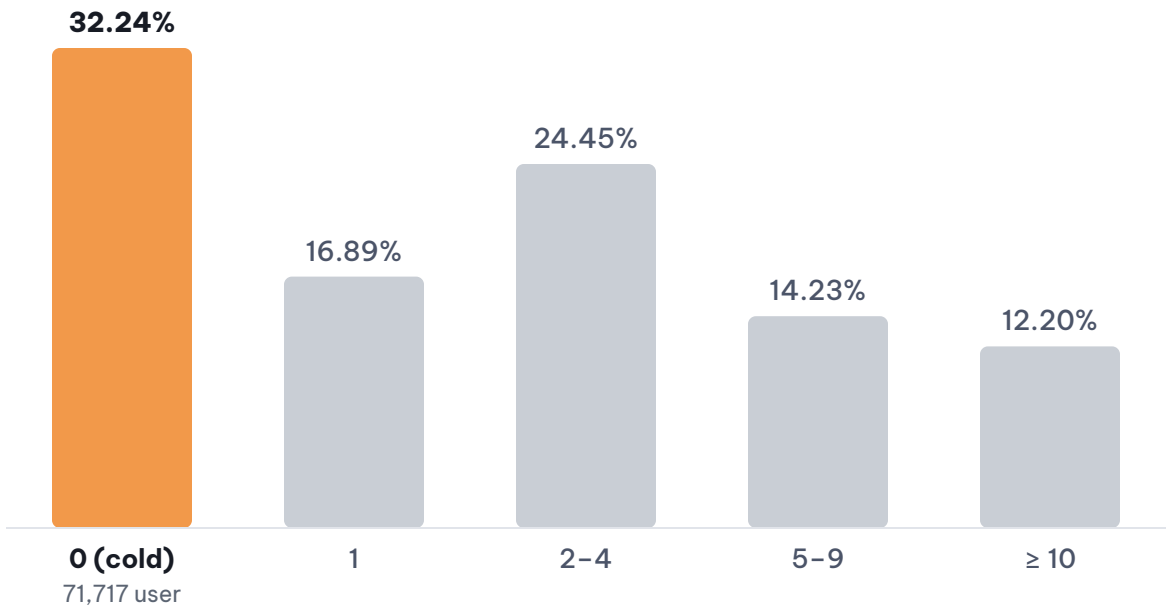
User mới ở valid và test

User chưa từng có booking ở train



Valid: 77,541 / 226,064 user
Test: 87,008 / 222,428 user

User test theo số booking trước 01/11/2014



Khoảng **một phần ba** user test không có lịch sử: mô hình chỉ đọc lịch sử sẽ không có gì để xếp hạng, cần đọc **lần tìm kiếm hiện tại**.

User mới xuất hiện **liên tục** ở cả valid và test: cold-start là tình huống thường xuyên, không phải ngoại lệ.

SMLP4Rec gốc: kết quả

SMLP4Rec gốc *

NDCG@10

0.1920

↑ +0.0068 (+3.7%) vs ItemKNN

↑ +42% vs độ phổ biến

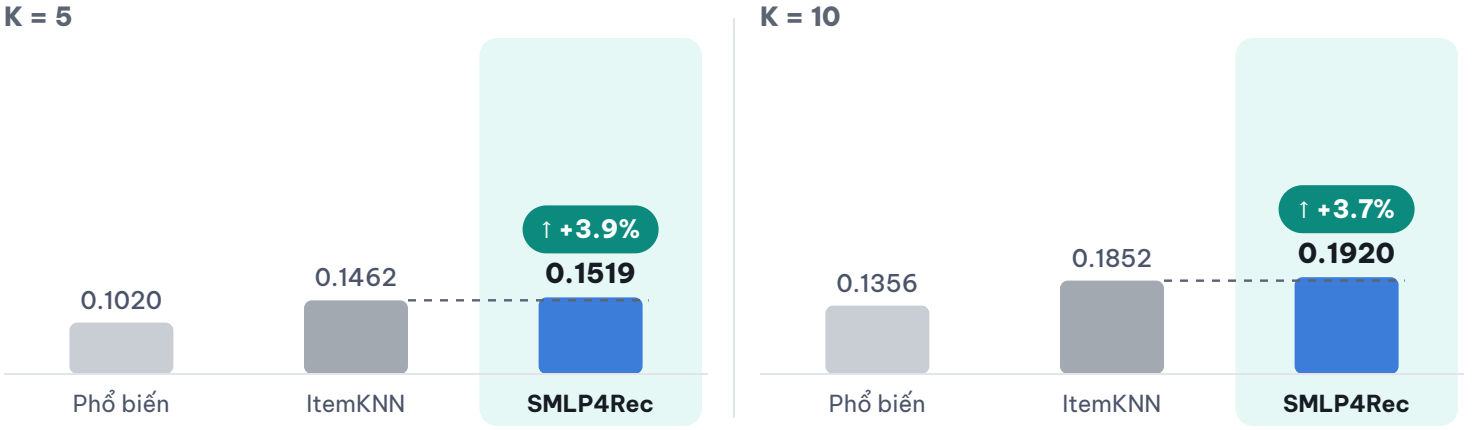
RECALL@10

32.2%

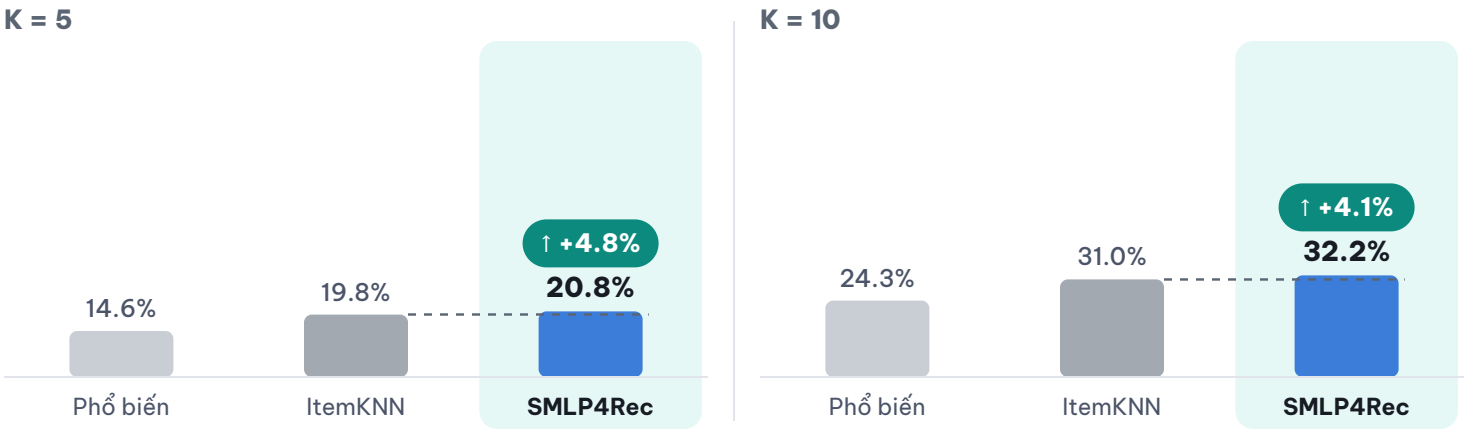
↑ +4.1% vs ItemKNN

K = 5: NDCG **0.1519** · Recall **20.8%**. Chỉ dùng lịch sử: **ngang ItemKNN**.

NDCG@K chất lượng xếp hạng



Recall@K tỷ lệ booking thật nằm trong top K

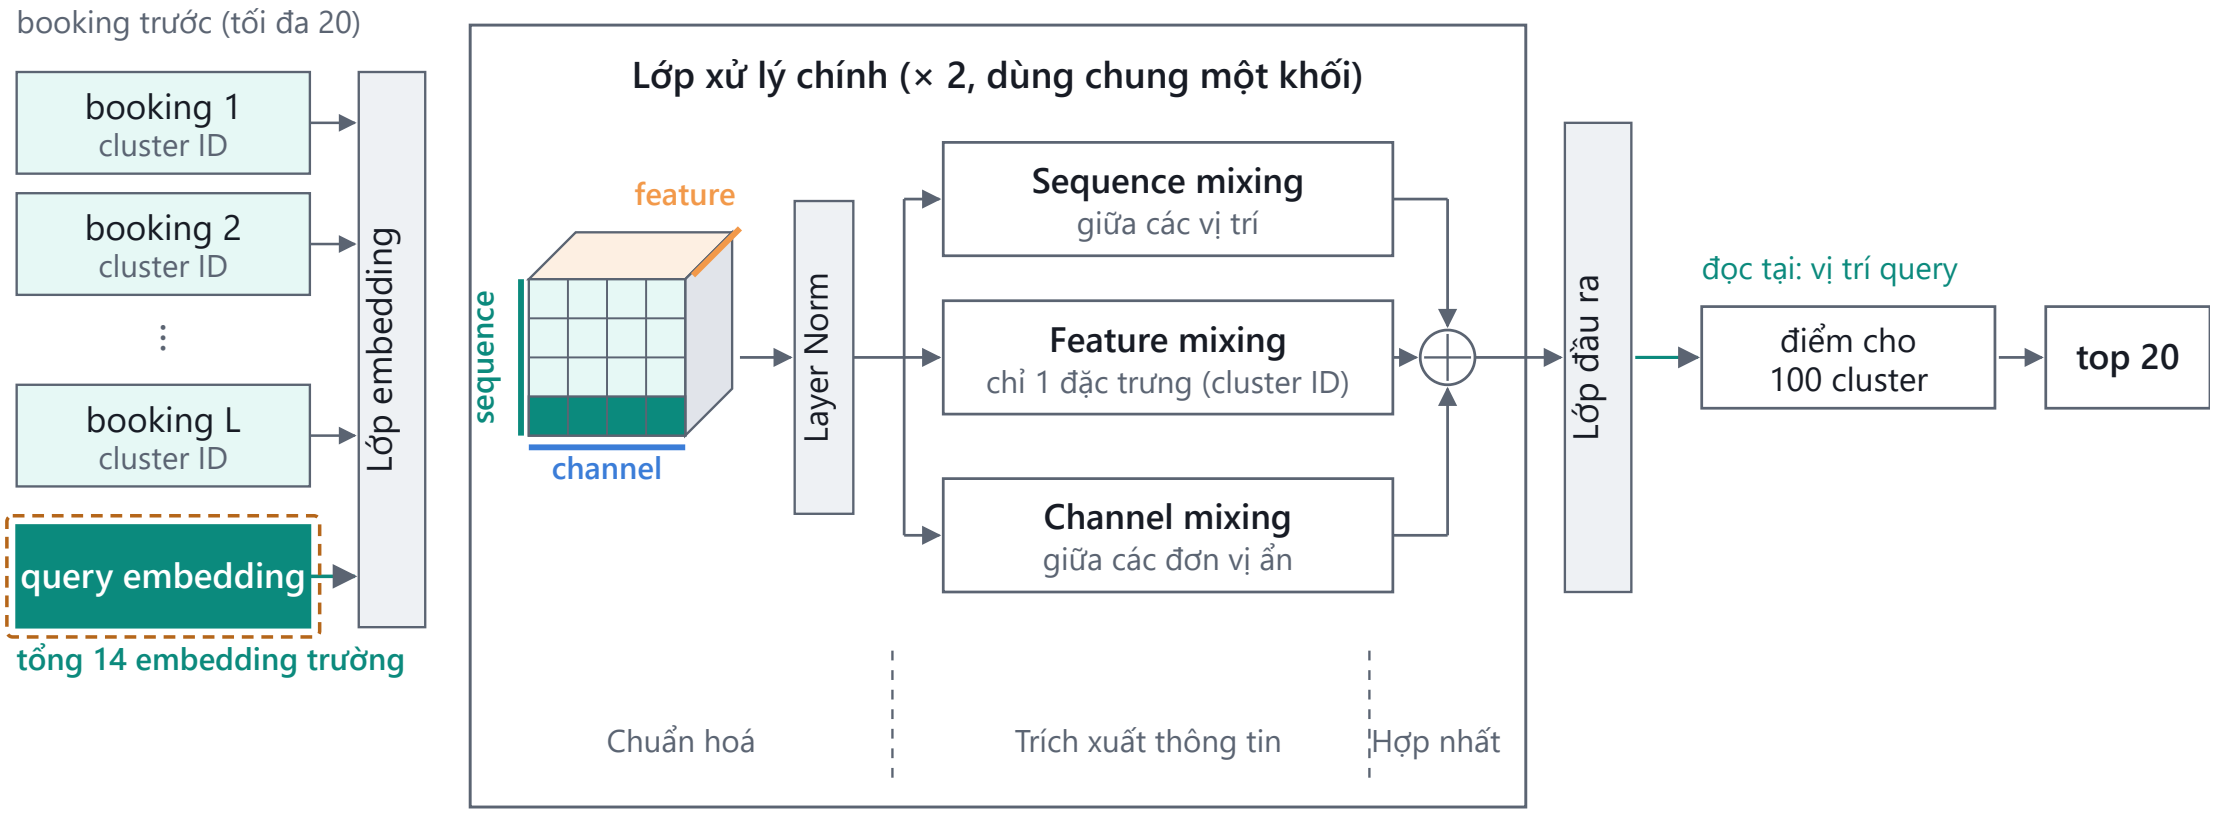


Test · 222,428 user · mỗi user một top 20 cố định · trung bình theo user · seed 2024

* SMLP4Rec gốc chỉ huấn luyện trên các booking có lịch sử

Cách test và eval →

Cải tiến 1: query embedding



14 trường tìm kiếm → 1 vị trí query

Chạy được khi lịch sử rỗng

Phụ lục A1: 14 trường →

Query embedding: kết quả

SMLP4Rec + query embedding

NDCG@10

0.4426

↑ +0.2506 (+130.5%)

so với SMLP4Rec gốc · KTC 95% +0.2491 đến +0.2521

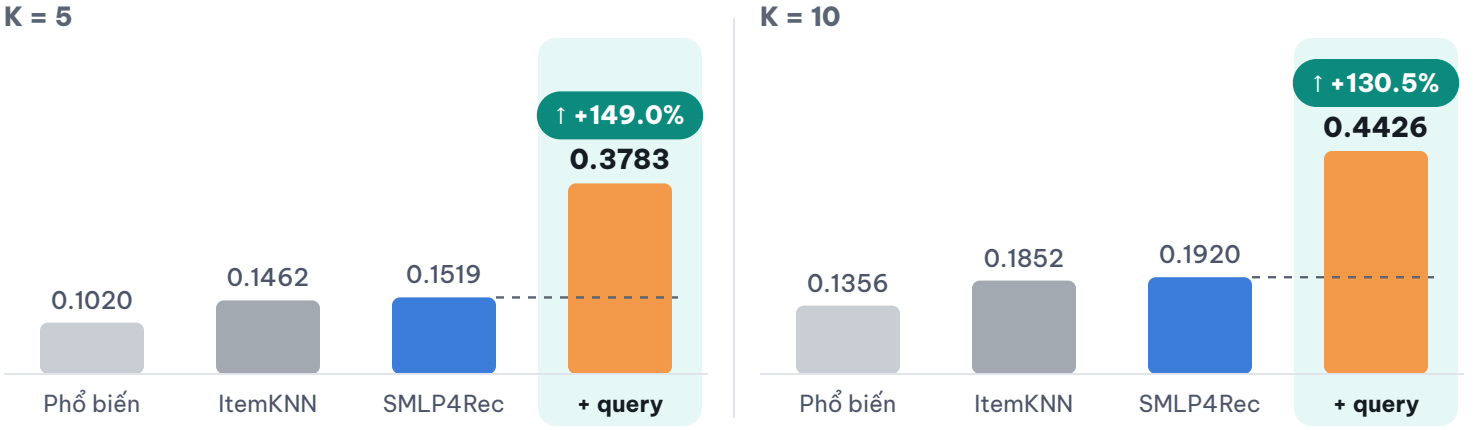
RECALL@10

69.5%

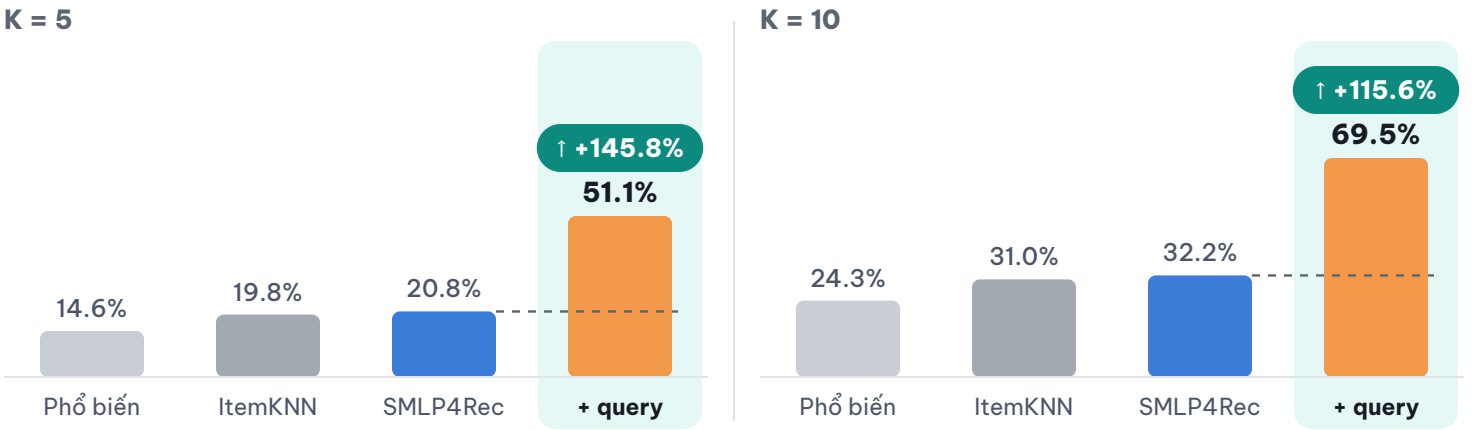
↑ +115.6%

K = 5: NDCG **0.3783** · Recall **51.1%**. Lần tìm kiếm hiện tại là **tín hiệu chính**.

NDCG@K chất lượng xếp hạng



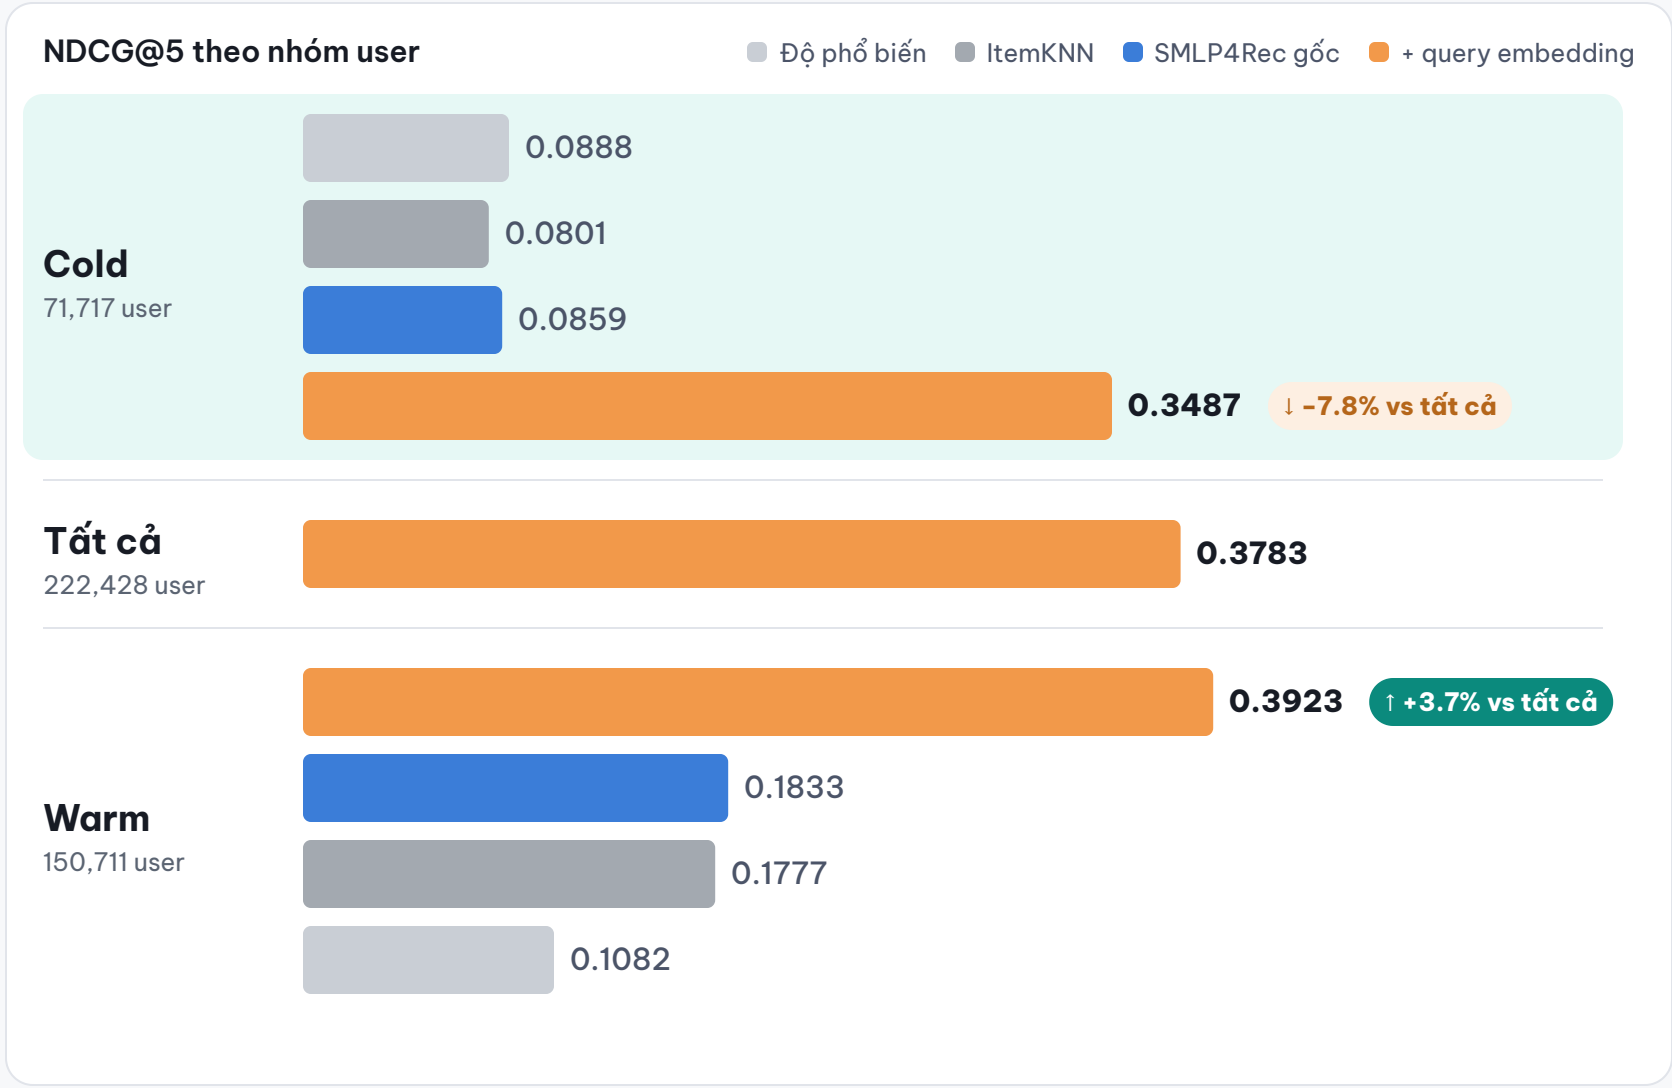
Recall@K tỷ lệ booking thật nằm trong top K



Test · 222,428 user · mỗi user một top 20 cố định · trung bình theo user · seed 2024

Cách test và eval →

Query embedding: user cold



USER COLD · NDCG@5

0.3487

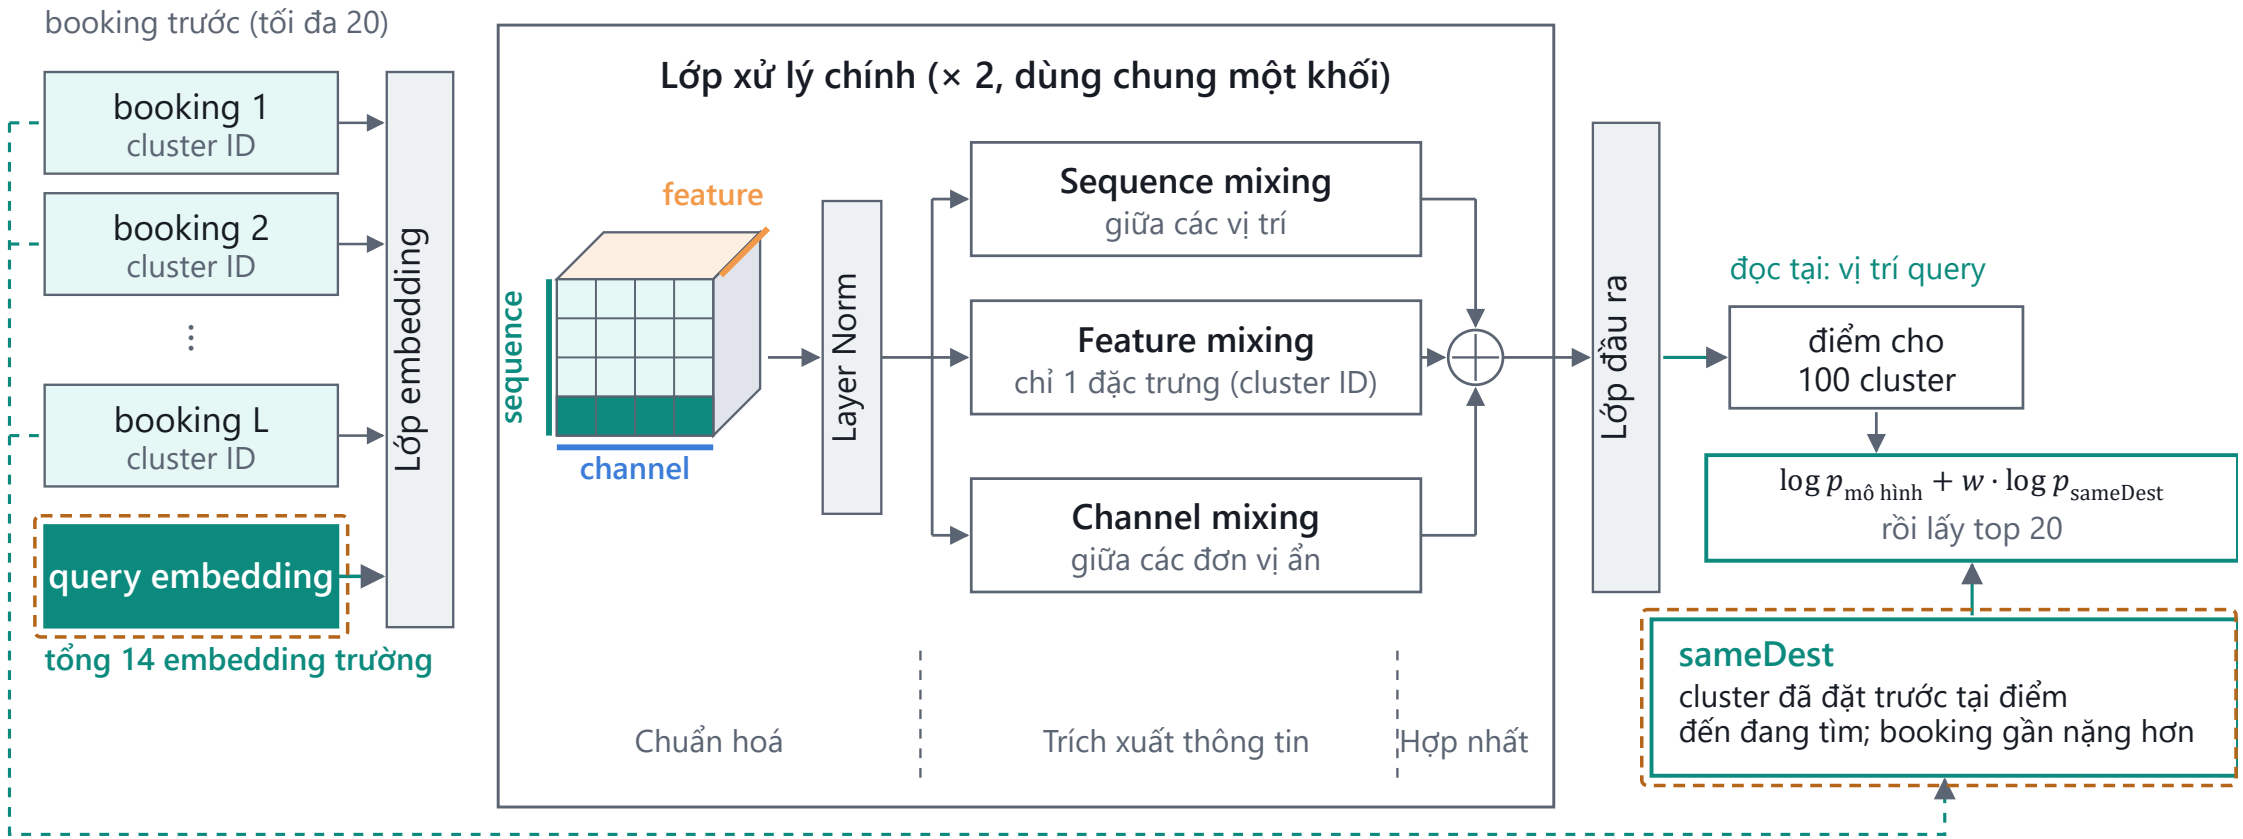
↑ 4.4× ItemKNN (0.0801)

↑ 3.9× độ phổ biến (0.0888)

Cold: chưa có booking nào trước 01/11/2014. Mô hình chỉ đọc lịch sử không có gì để xếp hạng; query embedding **đọc lần tìm kiếm hiện tại**.

Test · trung bình theo user · seed 2024

Cải tiến 2: sameDest



26.5% booking có lịch sử quay lại điểm đến đã từng đặt

Late-fusion · booking gần nặng hơn

Phụ lục A3: công thức →

sameDest: kết quả

Mô hình chính (+ sameDest)

NDCG@10

0.4474

↑ +0.0048 (+1.1%) vs + query embedding

KTC 95% +0.0045 đến +0.0052

↑ 3.3× độ phổ biến · 2.4× ItemKNN

RECALL@10

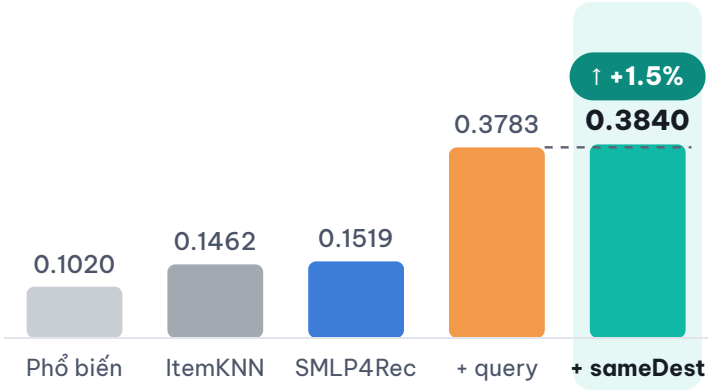
69.7%

↑ +0.2%

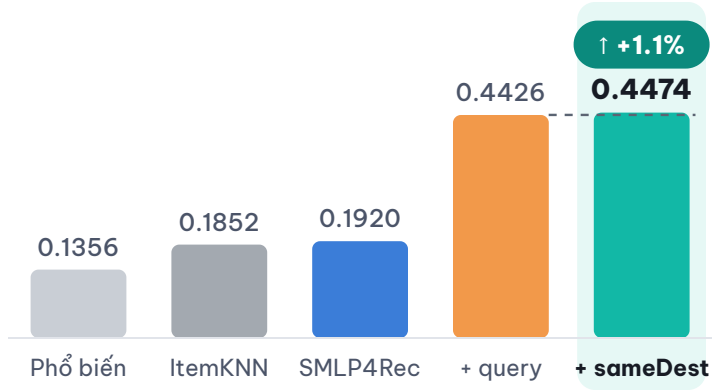
K = 5: NDCG **0.3840** · Recall **51.5%**. Recall gần như không đổi: mức tăng nằm ở **thứ hạng**.

NDCG@K chất lượng xếp hạng

K = 5

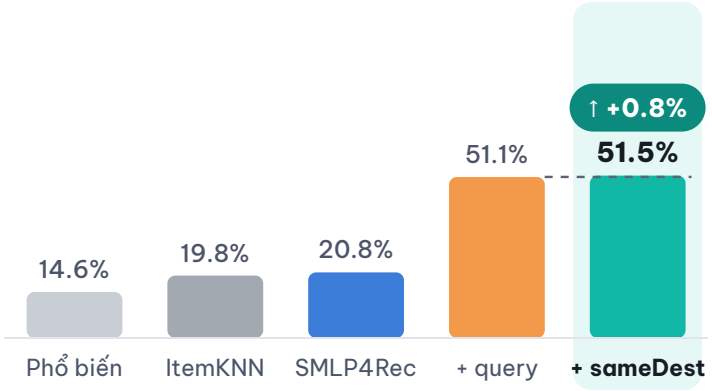


K = 10

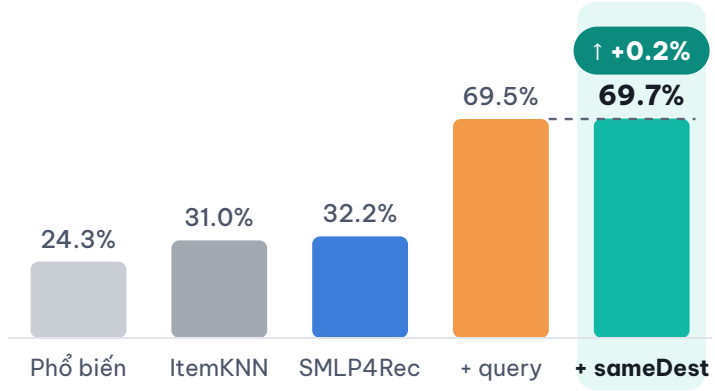


Recall@K tỷ lệ booking thật nằm trong top K

K = 5



K = 10



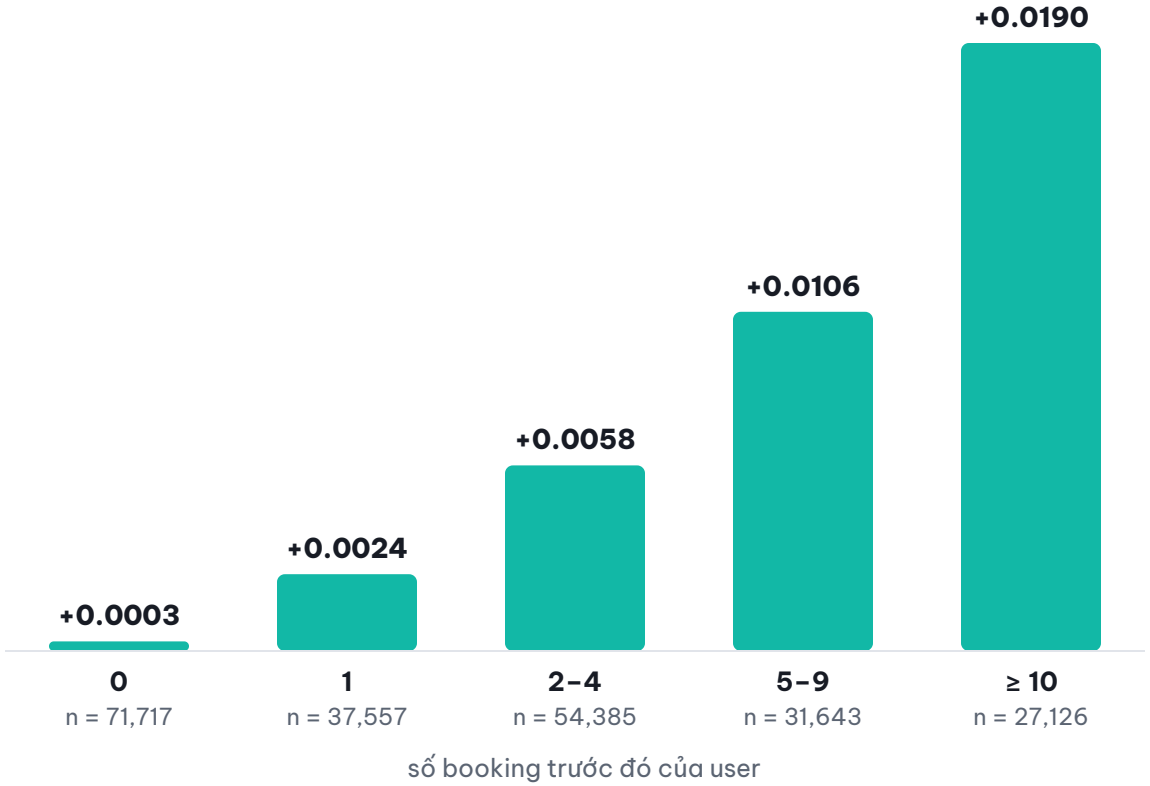
Test · 222,428 user · mỗi user một top 20 cố định · trung bình theo user · seed 2024

Theo mùa, nhóm khách, gói đặt (A4) → Cách test và eval →

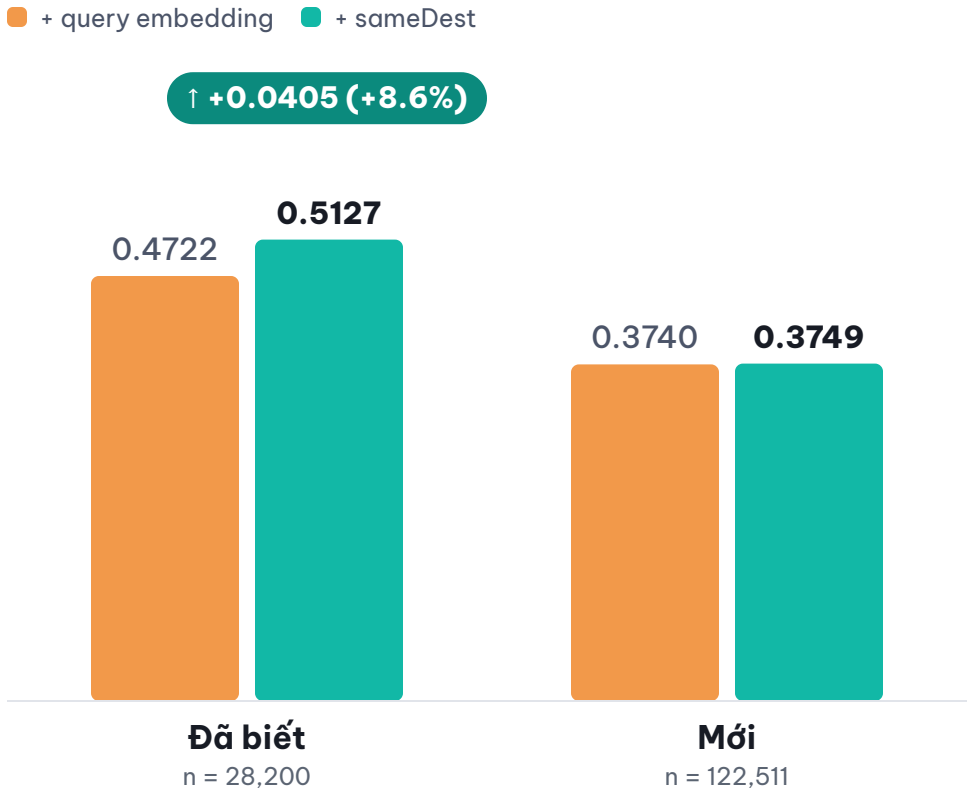
sameDest: giúp ở đâu

Mức tăng NDCG@5 theo số booking trước đó

chính – query embedding



NDCG@5 user warm theo điểm đến



sameDest chỉ giúp khi khách **quay lại điểm đến cũ**, và lịch sử càng dài càng có ích.

Với điểm đến mới, mô hình dựa vào ngữ cảnh tìm kiếm; sameDest **không làm hại**.

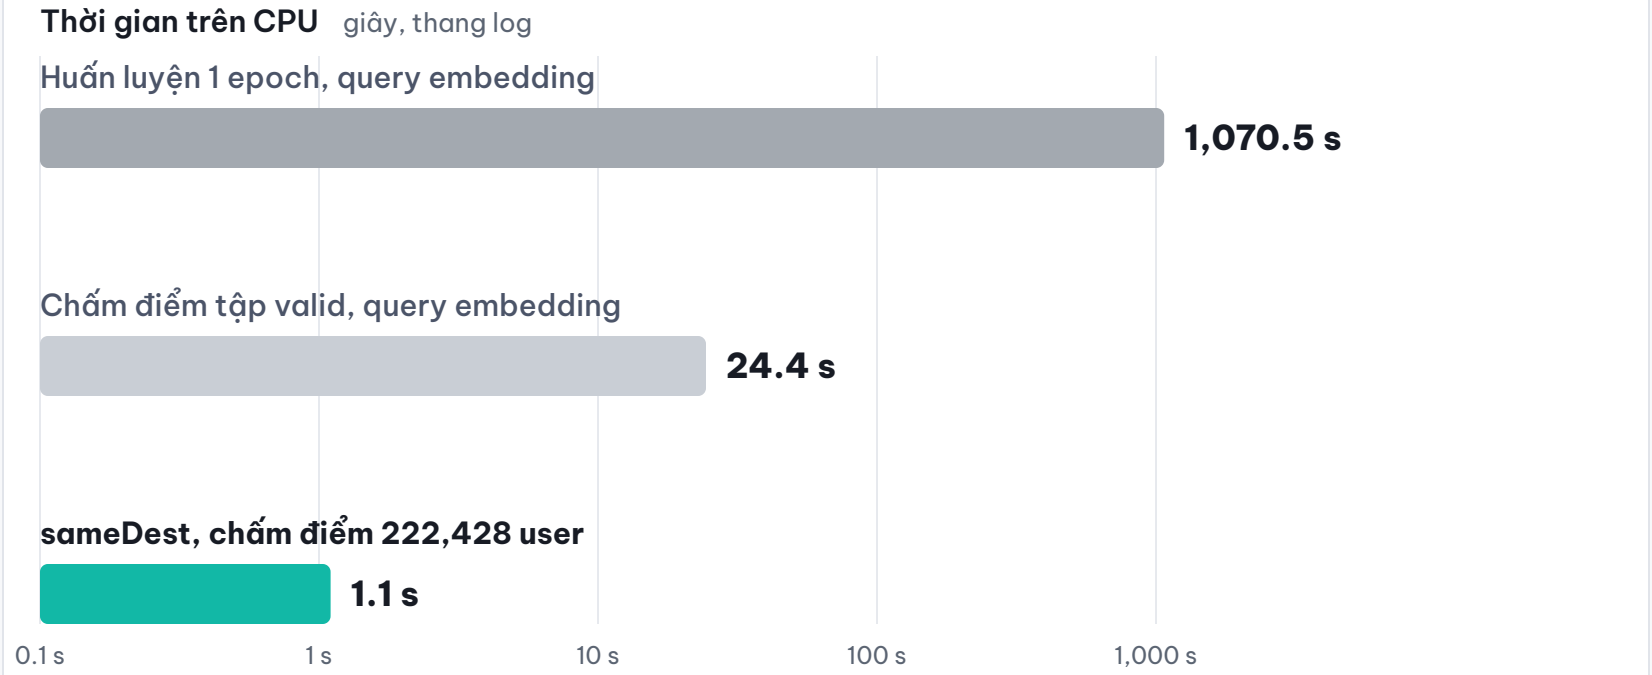
sameDest: chi phí

SAMEDEST · 222,428 USER

1.1 s

~4.8 µs mỗi user

Không huấn luyện lại



sameDest đo trên đầu vào mô phỏng cùng kích thước, không huấn luyện lại.

Lợi ích **tập trung** ở nhóm quay lại điểm đến cũ, không dàn đều toàn tập.

Chi phí **không đáng kể** so với huấn luyện, chạy ngay trên mô hình có sẵn.

Kết luận

1. **Lần tìm kiếm hiện tại là tín hiệu chính:** query embedding nâng NDCG@5 từ 0.1519 lên 0.3783 (+149%).

2. **Lịch sử cũ là phần bổ sung nhỏ nhưng có thật:** sameDest tăng 8.6% khi user quay lại điểm đến đã biết, chi phí khoảng 1 giây.

3. **User cold vẫn được xếp hạng tốt:** NDCG@5 đạt 0.3487, trong khi ItemKNN chỉ 0.0801.

4. **Không đánh đổi độ chính xác lấy độ phủ:** cluster phân bố khá đều (top 10 chỉ 22,9% booking) và item gắn chặt với ngữ cảnh chuyến đi, nên không cần đánh đổi, đẩy item ít phổ biến chỉ làm tăng rủi ro lệch ý khách.

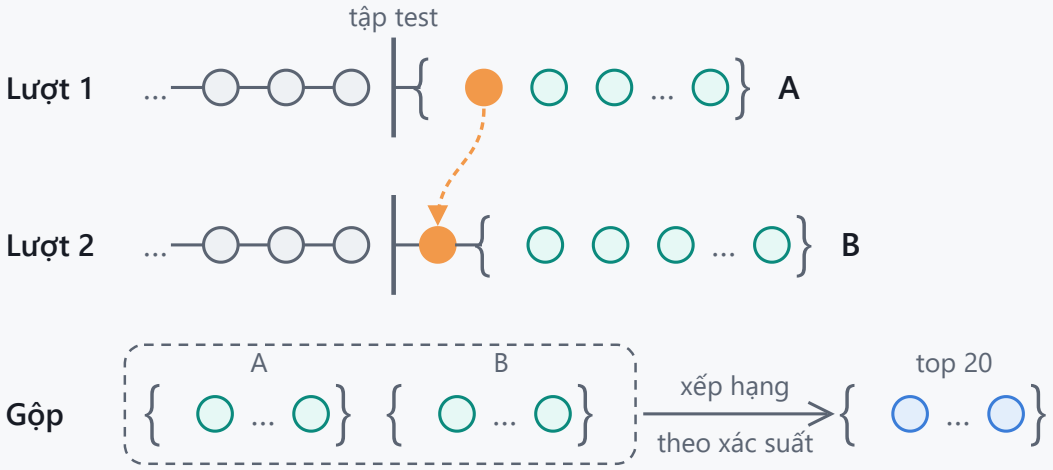
5. **Mô hình chính:** SMLP4Rec + query embedding + sameDest.

Phụ lục A1. 14 trường query embedding

Trường	Ý nghĩa	Cách mã hóa	Số giá trị
`dest`	Điểm đến đang tìm (srch_destination_id)	id gốc; điểm đến có dưới 5 booking ở train thành "ngoài từ vựng"	14,711
`dest_type`	Loại điểm đến	id gốc	9
`ci_month`	Tháng check-in	1 đến 12; 0 = không rõ	12
`lead`	Số ngày từ lúc tìm đến check-in	10 khoảng, từ 0 ngày đến từ 365 ngày; 0 = không rõ	11
`stay`	Số đêm lưu trú	0 đến 14 đêm, dài hơn gộp chung; 0 = không rõ	14
`adults`	Số người lớn	cắt ở 9; 0 = không rõ	10
`children`	Số trẻ em	cắt ở 9	10
`rooms`	Số phòng	cắt ở 8; 0 = không rõ	9
`package`	Đặt kèm gói (is_package)	0 hoặc 1	2
`mobile`	Tìm trên thiết bị di động	0 hoặc 1	2
`channel`	Kênh tiếp thị	id gốc	11
`site`	Website Expedia (site_name)	id gốc	39
`posa`	Châu lục điểm bán	id gốc	5
`country`	Quốc gia của người dùng	id gốc; dưới 5 booking ở train thành "ngoài từ vựng"	216

Phụ lục A2. Cách test và eval

Mỗi user một danh sách top 20 cố định



Chấm điểm, K = 5, 10, 20

$$\text{Recall@K} = \frac{\left|\text{Top}_K \cap \text{Actual}\right|}{|\text{Actual}|}$$

$$\text{NDCG@K} = \frac{\text{DCG@K}}{\text{IDCG@K}}$$

$$\text{DCG@K} = \sum_{r=1}^{K} \frac{\text{rel}_r}{\log_2\left(r+1\right)}$$

$$\text{IDCG@K} = \sum_{r=1}^{\min\left(K, |\text{Actual}|\right)} \frac{1}{\log_2\left(r+1\right)}$$

Top$_5$ = { 7 **3** 12 40 **9** }

Actual = { **3** **9** 55 }

Đại lượng	Cách tính	Giá trị
Recall@5	$\frac{\lvert\{3,9\}\rvert}{\lvert\{3,9,55\}\rvert} = \frac{2}{3}$	0.667
DCG@5	$\frac{1}{\log_2\left(2+1\right)} + \frac{1}{\log_2\left(5+1\right)}$	1.018
IDCG@5	$\frac{1}{\log_2\left(1+1\right)} + \frac{1}{\log_2\left(2+1\right)} + \frac{1}{\log_2\left(3+1\right)}$	2.131
NDCG@5	$\frac{1.018}{2.131}$	**0.478**

Phụ lục A2.1. Hai cách gộp còn lại

Cách 1

chỉ lấy lượt 1



Cách 3

biến đổi lượt 2



α: xác suất của cluster đầu A

Phụ lục A3. Công thức sameDest

B(*k*): các booking trước, tại điểm đến đang tìm, có cluster *k*. *p*: xác suất của mô hình.

$$\text{sameDest}(k) = \sum_{i \in B(k)} 0.7^{\text{lag}_i}$$

$$q_{\text{sameDest}}(k) = \frac{\text{sameDest}(k)}{\sum_j \text{sameDest}(j)}$$

$$q = (1-\alpha)\cdot p + \frac{\alpha}{100}$$

$$\text{điểm}(k) = \log q_{\text{mô hình}}(k) + w \cdot \log q_{\text{sameDest}}(k)$$

α = 0.1; w = 0.5 nếu điểm đến đã có trong lịch sử, w = 0 nếu không.

Ví dụ: lịch sử bốn booking, tìm kiếm tại điểm đến A (lag 0 = booking gần nhất).

Điểm đến	Cluster	Lag	Tính vào sameDest?	0.7^{lag}
A	7	3	có	0.343
B	9	2	không (khác điểm đến)	0
A	12	1	có	0.700
A	7	0	có	1.000

$$\text{sameDest}(7) = 0.7^3 + 0.7^0 = 0.343 + 1 = 1.343$$

$$\text{sameDest}(12) = 0.7^1 = 0.700$$

$$q_{\text{sameDest}}(7) = \frac{1.343}{1.343 + 0.700} = \frac{1.343}{2.043} = 0.657$$

$$q_{\text{sameDest}}(12) = \frac{0.700}{1.343 + 0.700} = \frac{0.700}{2.043} = 0.343$$

Phụ lục A4. Mô hình chính theo mùa, nhóm khách, gói đặt

NDCG@5 của mô hình chính tập test, theo thuộc tính của booking đầu tiên của user



Phụ lục A5. Ý nghĩa các trường dữ liệu

Cột	Ý nghĩa
`date_time`	thời điểm của lượt tìm kiếm hoặc đặt
`user_id`	mã người dùng
`is_package`	đặt kèm gói (1) hoặc không (0)
`srch_adults_cnt`	số người lớn
`srch_children_cnt`	số trẻ em
`srch_ci`	ngày check-in
`srch_co`	ngày check-out
`srch_rm_cnt`	số phòng
`srch_destination_id`	mã điểm đến tìm kiếm
`srch_destination_type_id`	loại điểm đến
`hotel_cluster`	cụm khách sạn đã đặt, mã ẩn danh: nhãn cần dự đoán

Cột	Ý nghĩa
`hotel_continent`	châu lục của khách sạn đã đặt
`hotel_country`	quốc gia của khách sạn đã đặt
`hotel_market`	thị trường của khách sạn đã đặt
`orig_destination_distance`	khoảng cách từ người dùng đến điểm đến, có thể thiếu
`user_location_country`	quốc gia của người dùng
`user_location_region`	vùng của người dùng
`user_location_city`	thành phố của người dùng
`channel`	kênh tiếp thị dẫn tới lượt tìm kiếm
`is_mobile`	dùng thiết bị di động (1) hoặc không (0)
`posa_continent`	châu lục của điểm bán
`site_name`	website Expedia dùng để tìm kiếm